

VYUŽITIE NEURÓNOVÝCH SIETÍ PRI BIOMETRICKOM ROZPOZNÁVANÍ OSÔB ODTLAČKAMI PRSTOV

Teória a aplikácie neurónových sietí

Skúšajúci: doc. Dr. Ing. Miloš Oravec

Ing. Pavol Marák

Školiteľ:

prof. RNDr. Otokar Grošek,
PhD.

Obsah

1 Úvod.....	2
2 Základné poznatky o neurónových sieťach.....	3
2. 1 Model neurónu a architektúry sietí.....	3
2. 2 Učenie neurónových sietí	6
2. 3 Mapovanie neurónovej siete.....	6
2. 4 Viacvrstvový perceptrón	8
2. 4. 1 Algoritmus spätného šírenia chyby s gradientovou technikou	8
3 Aplikácie neurónových sietí pri biometrickom rozpoznávaní osôb odtlačkami prstov	0
3. 1 Biometria, odtlačky prstov a neurónové siete	0
3. 2 Vhodnosť neurónových sietí na rozlišovanie vzorov v odtlačku	1
3. 3 Konkrétne aplikácie neurónových sietí	2
3. 4 Techniky extrakcie vybraných vlastností odtlačku pomocou NS.....	3
3. 4. 1 Extrakcia smeru papilárnych línií na báze neurónovej siete	3
3. 4. 2 Extrakcia markantov z kostry odtlačku využívajúca neurónové siete.....	6
3. 5 Techniky klasifikácie globálnych vzorov odtlačku pomocou NS	11
3. 5. 1 Klasifikácia odtlačkov podľa singulárnych bodov s využitím neurónových sietí.....	11
3. 6 Techniky porovnávania odtlačkov pomocou NS.....	17
3. 6. 1 Porovnávanie odtlačkov na báze daktyloskopických markantov	17
3. 6. 2 Porovnávanie odtlačkov pomocou lokálnej oblasti daktyloskopického stredu	20
3. 6. 3 Porovnávanie odtlačkov pomocou dvojrozmernej mapy markantov	24
Použitá literatúra.....	28

1 Úvod

Z pohľadu informačných technológií sú neurónové siete výpočtové modely inšpirované centrálnym nervovým systémom živých organizmov v prírode. Sú schopné strojového učenia a rozpoznávania vzorov v signáloch rôzneho druhu. Z hľadiska ich vnútornej architektúry sú reprezentované ako množina prepojených elementov, ktoré počítajú výstupné hodnoty siete závisiace na vstupných hodnotách šírených v takejto sieti. Ich kľúčovou vlastnosťou, ktorá ich odlišuje od tradičných výpočtových systémov je vnútorné usporiadanie jej pracovných prvkov a spôsob komunikácie medzi nimi.

Neurónové siete majú vlastnosti, ktoré prekonávajú schopnosti tradičných výpočtových metodík akými sú algoritmy počítačového videnia. Myšlienkou práce týchto sietí je aktivácia vstupných elementov siete vplyvom vstupného signálu. Hodnoty aktivovaných elementov sú potom prenášané sieťou, je im pridelovaná váha a sú transformované matematickými funkciami, ktoré návrhár siete zvolí pri jej konštrukcii. Elementy neurónovej siete sú nazývané aj neuróny. Ich spoločným prepojením sa napodobňuje biologický centrálny nervový systém. Sila týchto prepojení sa nazýva váha. Základnou výhodou neurónových sietí je schopnosť aproximácie ľubovoľnej funkcie na základe pozorovaní formou učenia sa. Učením sa nastavujú vnútorné parametre siete na hodnoty, pri ktorých je sieť schopná rozpoznávať vzory, na ktoré sa adaptovala počas učenia.

Jednou z úspešných domén, kde neurónové siete využívajú svoje schopnosti adaptácie, klasifikácie a rozlišovania vzorov je biometria. Rozpoznávanie vzorov v odtlačkoch prstov je problémom, ktorý nenašiel dodnes uspokojivé riešenie. Napriek rapídному vývoju automatizovaného rozpoznávania odtlačkami prstov v poslednej dobe sa stále očakáva ich ďalšie zlepšovanie hlavne kvôli zvýšeniu ich rýchlosti, presnosti pri komplikovaných podmienkach reálneho sveta a hlavne možnostiam ich používania bez akejkoľvek ľudskej interakcie. Neurónová sieť dokáže rozlišovať vzory a zároveň dokáže tolerovať variabilitu vzorov rovnakej triedy, ktoré môžu byť spôsobené procesom snímania alebo vplyvom rôznych faktorov obrazovej degradácie. Úspešnosť neurónových sietí pri rozpoznávaní globálnej štruktúry vzorov odtlačku bola preukázaná prácami mnohých autorov, avšak rozlišovanie detailov na lokálnej úrovni papilárnych línií je do značnej miery nezohľadnené a preto vzniká otázka, či sú neurónové siete vhodným nástrojom na porovnávanie odtlačkov vykonávané v režime identifikácie.

V tejto správe demonštrujeme príklady využitia schopností neurónových sietí pri rôznych úlohách v rámci biometrického systému na báze odtlačkov prstov. Vo všeobecnosti môžeme hovoriť o uplatnení neurónových sietí vo fáze klasifikácie globálneho vzoru odtlačku, extrakcie daktyloskopických markantov a rozhodovaní sa pri porovnávaní dvoch odtlačkov. Pri každom prípade využitia neurónovej siete prinášame opis technických aspektov týchto sietí, od ktorých závisí jej vhodnosť v konkrétnej aplikácii. Preto opisoch existujúcich techník v odbornej literatúre sa zameriavame na architektúru siete, proces učenia sa a testovania. Tieto faktory dávame do súvislosti so špecifickým výsledkom, ktorý od siete očakávame.

2 Základné poznatky o neurónových sieťach

Informácie v tejto kapitole boli z časti čerpané z literatúry [1].

Neurónová sieť je nástroj na *modelovanie činnosti*, ktorou mozog vykonáva niektoré činnosti. Analógiu s biologickým nervovým systémom je cítiť hlavne v *schopnosti učiť sa* a zapamätávať si poznatky a na základe nich vykonávať rozhodnutia. Neurónová sieť je zložená z masívnej siete prepojených elementov – *neurónov*. Poznatky neurónovej siete sú uchovávané vo forme *váh* synaptických prepojení medzi neurónmi. Procedúra, ktorou sa neurónová sieť učí sa volá algoritmus učenia.

Vlastnosti neurónovej siete

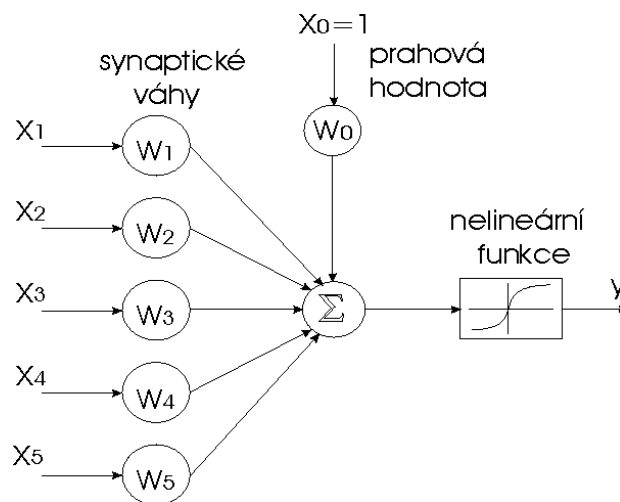
- Neurónové siete sú distribuované *nelineárne* systémy – neuróny obsahujú nelineárne aktivačné funkcie a preto sú schopné modelovať nelineárne zdroje informácií
- Neurónová sieť je masívne paralelný procesor, ktorý je *odolný voči chybám* – architektúra neurónovej siete umožňuje paralelizáciu výpočtov a silné prepojenie neurónov zasa umožňuje tolerovať určité variácie vzorov patriacich do rovnakej triedy
- Neurónová sieť má *schopnosť adaptácie* parametrov – neurónová sieť je schopná prispôbiť svoje vnútorné parametre špecifickým podmienkam na základe tréningu na vybranej vzorke, ktorá je typická pre daný účel
- Neurónová sieť *dokáže aproximovať ľubovoľné spojité funkcie* ak majú dostatočný počet skrytých neurónov

2.1 Model neurónu a architektúry sietí

Neurón je výpočtový a transformačný element neurónovej siete. Sieť obsahuje *vstupné prepojenia* (dendrity), *telo neurónu* a *výstupné prepojenie* (axóny). Body jednotlivých prepojení od neurónov v predchádzajúcej vrstve sa nazývajú *synapsy*. Signál j -tej synapsy spojenej s neurónom k je násobený *synaptickou váhou* $w_{k,j}$. V tele neurónu sa nachádza *sumačná funkcia*, ktorá sčítava vstupné signály váhované váhami. *Aktivačná funkcia* ohraničuje výstup neurónu, ktorý býva v intervale $[0,1]$ alebo $[-1,1]$. Model neurónu obsahuje aj *prah* $\theta_k = w_{k,0}$, čo je vlastne váha jedného synaptického prepojenia so signálom - 1. Hodnota do aktivačnej funkcie môže byť aj zvýšená pomocou *biasu* – záporná hodnota prahu. Sumovaný vstup do neurónu označujeme ako *vnútorná aktivita* v_k . $\varphi(\cdot)$ je aktivačná funkcia neurónu, y_k je výstup k -teho neurónu a x_j je vstupný signál j -tej synapsy.

$$v_k = \sum_{j=0}^p w_{k,j} x_j$$

$$y_k = \varphi(v_k)$$



Obrázok 1 Model neurónu

Najpoužívanější typy aktivačních funkcí $\varphi()$ sú:

- prahová funkcia
- po častiach lineárna funkcia
- sigmoidálna funkcia

Spomedzi vymenovaných býva sigmoidálna funkcia najčastejšie implementovanou funkciou v architektúrach neurónových sietí. Je definovaná ako monotónne rastúca, spojitá a ohraničená funkcia. Nasledovný predpis spĺňa podmienky sigmoidálnej funkcie:


$$\varphi(v) = \frac{1}{1 + \exp(-av)} \text{ a je parameter strmosti, ktorý mení tvar krivky funkcie}$$

Časom sa vyvinuli niektoré špecifické architektúry neurónových sietí podľa toho, akým spôsobom sa v nich šíria signály alebo prepájajú neuróny:

- dopredné vrstvové siete
- rekurentné siete
- mriežkové štruktúry

Dopredné vrstvové siete


Neuróny sú v nich organizované vo vrstvách. Majú vstupnú vrstvu prepojenú s výstupnou. Môžu mať aj skryté vrstvy h_i – potom je architektúra typu $p-h1-h2-...-q$. Ak je signál šírený len zo smeru vstupov k výstupom, potom tieto siete nazývame dopredné.



Obrázok 2 Viacvrstvá dopredná sieť

Rekurentná sieť


Líši sa od dopredných sietí tým, že má minimálne 1 spätnú väzbu z výstupu.



Obrázok 3 Rekurentná sieť

Mriežkové štruktúry

Pozostávajú z 1D, 2D alebo viacrozmerného poľa neurónov s korešpondujúcimi vstupnými prvkami, ktoré distribuujú signál do poľa neurónov. To, čo ich líši od predchádzajúcich dvoch typov sietí je, že vstupný signál je privedený na vstup všetkých neurónov a nie len na určitú vrstvu (podmnožinu) neurónov.



Obrázok 4 Mriežková architektúra neurónovej siete

2. 2 Učenie neurónových sietí

Učenie je proces adaptácie parametrov siete v interakcii s prostredím, v ktorom pracuje. Učenie je vlastne zmena synaptickej váhy k -teho neurónu a j -teho synaptického prepojenia v čase $n+1$ na základe určitej korekcie Δ . Matematický zápis adaptácie váh:

$$w_{k,j}(n+1) = w_{k,j}(n) + \Delta w_{k,j}(n).$$

Existujúce algoritmy učenia sa líšia spôsobom výpočtu $\Delta w_{k,j}(n)$.

Algoritmy učenia:

- Učenie korigujúce chybu
- Hebbovo učenie
- Súťažné učenie
- Boltzmannovo učenie

Paradigmy učenia:

- Učenie s učiteľom
- Známkové učenie
- Samoorganizácia

Algoritmy učenia hovoria o konkrétnom postupe, ktorý vedie k splneniu určitého cieľa. Paradigma učenia hovorí o tom, aké máme pri učení k dispozícii zdroje informácií o prostredí, v ktorom bude sieť pracovať. Pri učení s učiteľom sa siete poskytujú správne odpovede, aby vedela adekvátne prispôbovať svoje vnútorné parametre. Známkové učenie koordinuje sieť v zmysle známkovania jej výstupov. No a nakoniec samoorganizujúce sa siete nepotrebujú žiadneho učiteľa, vedľa svoje parametre meniť samé.

2. 3 Mapovanie neurónovej siete

NN predstavuje mapovanie z p -rozmerného priestoru (trénovacích vzoriek) do q -rozmerného priestoru rozhodnutí. Učenie pritom poskytuje sieti príklady (x_1, y_1) , (x_2, y_2) ... atď. Ak má sieť k dispozícii správny výstup, môže byť overovaná jej chybovosť. Jedno vyhodnotenie siete pre konkrétny vektor x_k nazveme *iterácia*. Ak má neurónová sieť očakávaný výstupný vektor $f(x_k)$ a skutočný výstupný vektor $Y(x_k, w)$ potom môžeme definovať *strednú kvadratickú chybu* siete:

$$J(w) = \frac{1}{N} \sum_{k=1}^N |f(x_k) - Y(x_k, w)|^2$$

Stredná kvadratická chyba je funkcia váhového vektora – jej výška závisí od aktuálnej hodnoty váh. Vykreslenie hodnoty chybovej funkcie od aktuálnej konfigurácie váh sa nazýva *chybový povrch*. Cieľom je nájsť také váhy, ktoré minimalizujú chybový povrch. $J(w)$ nikdy nie je nulová pretože neurónová sieť nie je schopná dokonale presného mapovania. Úlohou je teda nájsť takú konfiguráciu váh, pri ktorej dosiahne $J(w)$ počas tréningu globálne minimum.

Pretrénovanie

Schopnosť siete vyhodnocujeme testovacou množinou. Tá by mala obsahovať čo najviac príkladov, ktoré sa môžu vyskytnúť. Na tejto množine nebola sieť trébovaná – vyžadujeme tu schopnosť *generalizácie*. Počas tréningu zároveň testujeme schopnosť generalizácie siete a zaujímajú nás dve chybové charakteristiky.

Pri návrhu siete sledujeme ako sa vyvíja J_{tren} a J_{test} s rastúcim počtom trébovacích cyklov. J_{tren} počas trébovania stále klesá aj keď stále nižším tempom, ale chyba J_{test} začne v určitom okamihu rásť – tu treba trébovanie zastaviť. Tento jav sa nazýva pretrénovanie.

Optimálny počet skrytých neurónov a cross-validácia

Zdanlivo sa môže zdať, že čím viac neurónov má sieť vo svojich skrytých vrstvách, tým rýchlejšie sa bude učiť resp. bude svoju funkciu, na ktorú bola trébovaná vykonávať presnejšie. Zvyčajná voľba počtu skrytých neurónov závisí od viacnásobného trébovania siete pri rôznych počtoch skrytých neurónov. Zároveň sa vyhodnocuje chyba J_{test} a vyberie sa tá konfigurácia siete, pre ktorú je J_{test} minimálna.

Korektným štatistickým postupom na voľbu správnej konfigurácie siete je tzv. cross-validácia:

1. Množinu biometrických údajov A rozdelíme na k disjunktných množín $A_{test}^1, A_{test}^2, \dots, A_{test}^k$. Tieto množiny by mali obsahovať rovnaké zastúpenie tried ako pôvodná množina A .
2. Každý model siete (určitá konfigurácia skrytých vrstiev) sa tréboje k -krát na všetkých trébovacích množinách, ktoré získame ako $A_{train}^i = A \setminus A_{test}^i$. Učenie pri každej trébovacej množine zastavíme, keď J_{test} začne rásť.
3. Po skončení všetkých trébovaní, vypočítame pre každý model siete cross-validačný odhad presnosti klasifikácie tak, že:

$$CV = \frac{1}{k} \sum_{i=1}^k V^i$$

Člen V^i je početnosť chybných klasifikácií pre testovaciu množinu A_{test}^i .

4. Vyberieme ten model siete, ktorý má minimálny CV .

2. 4 Viacvrstvový perceptrón

Je najviac využívaný typ neurónovej siete. Je to dopredná sieť s úplným prepojením vrstiev a voliteľným počtom skrytých vrstiev. Trénujú sa s učiteľom a používajú algoritmus spätného šírenia chyby, ktorý je založený na pravidle učenia korigujúcom chybu.

Charakteristiky perceptrónu:

- Každý neurón obsahuje nelineárnu aktivačnú funkciu
- Komplexné zobrazenia (mapovania) sa vie sieť naučiť pomocou jednej alebo viacerých skrytých vrstiev
- Každý neurón je prepojený so všetkými neurónmi v nasledujúcej vrstve

2. 4. 1 Algoritmus spätného šírenia chyby s gradientovou technikou

Chybový signál na výstupe j -teho výstupného neurónu v n -tej iterácii vyjadrujeme:

$$e_j(n) = d_j(n) - y_j(n)$$

Jedná sa o algoritmus učenia s učiteľom a preto musíme mať k dispozícii očakávanú hodnotu výstupu neurónu $d_j(n)$. Reálny výstup neurónu je $y_j(n)$.

Okamžitá hodnota kvadratickej chyby pre neurón je:

$$\frac{1}{2} e_j^2(n)$$

Keď spočítame chyby všetkých výstupných neurónov vo vrstve V , dostaneme sumu okamžitých hodnôt kvadratických chýb pre n -tú iteráciu :

$$\varepsilon(n) = \frac{1}{2} \sum_{j \in V} e_j^2(n)$$

Priemerná kvadratická chyba siete je:

$$\varepsilon_{priem.} = \frac{1}{N} \sum_{n=1}^N \varepsilon(n)$$

Cieľom učenia je minimalizovať priemernú kvadratickú chybu vzhľadom na váhy. Využíva sa učenie, v ktorom sa váhy adaptujú vzorku po vzorke. Algoritmus spätného šírenia upravuje váhu $w_{ji}(n)$ o hodnotu $\Delta w_{ji}(n)$, ktorá je úmerná okamžitému gradientu $\partial \varepsilon(n) / \partial w_{ji}$. Tento gradient so znamienkom mínus určuje smer najstrmšieho zostupu v chybovom povrchu pre danú váhu. Opätovne pripomíname, že j označuje konkrétnu vrstvu a i označuje konkrétne synaptické prepojenie daného neurónu, ktoré prichádza od neurónu v predchádzajúcej vrstve.

$$\frac{\partial \varepsilon(n)}{\partial w_{ji}(n)} = -e_j(n) \phi_j(v_j(n)) y_i(n)$$

Pravidlo delta

Hovorí, ako sa adaptuje konkrétna váha.

$$\Delta w_{ji}(n) = -\eta - e_j(n) \phi_j(v_j(n)) y_i(n) = \eta \delta_j(n) y_i(n)$$

Toto pravidlo do korekcie váhy zavádza konštantu η , čo je konštanta predstavujúca rýchlosť učenia a δ_j je lokálny gradient.

Adaptovanie váh skrytých neurónov

Skryté neuróny nesú zodpovednosť za presnosť siete. Požadovanú odpoveď máme k dispozícii len pri výstupných neurónoch. Otázka je ako vypočítať lokálny gradient pre skrytý neurón j .

$$\delta_j(n) = \phi_j(v_j(n)) \sum_k \delta_k(n) w_{kj}(n)$$

Suma vo vzťahu predstavuje súčet lokálnych gradientov v neurónoch, s ktorými je neurón j spojený. Takto je možné vypočítať korekciu váhy pre ľubovoľný neurón v sieti.

3 Aplikácie neurónových sietí pri biometrickom rozpoznávaní osôb odtlačkami prstov

3. 1 Biometria, odtlačky prstov a neurónové siete

Biometria prichádza ako riešenie kľúčového problému dnešnej spoločnosti a služieb poskytovaných elektronicky alebo štandardnou cestou. Tým problémom je *spol'ahlivé rozpoznanie človeka*. Komerčné a civilné aplikácie si vyžadujú, aby mala každá osoba svoju unikátnu identitu, ktorá sa dá kedykoľvek preukázať. Vzniká celý rad aplikácií ako komunikácia s vládnyimi alebo bankovými inštitúciami, kde je nutné si overiť, či je služba poskytovaná legitímnej osobe. Niektoré krajiny začínajú biometrické riešenie rozpoznávania identity vnímať skôr ako nutnosť a nie komfort. Napríklad India, kde žije približne 1,25 miliardy obyvateľov má 25 % negramotného obyvateľstva, 60 % veľmi chudobných ľudí a až 80 % obyvateľstva nevlastní postačujúce identifikačné dokumenty, ktoré by spoľahlivo preukazovali ich identitu a k nej prislúchajúce informácie. Biometria pomáha zabezpečovať sociálne a zdravotné služby pre chudobných ľudí v núdzi, pomáha pri evidencii uchádzačov o prácu a vo všeobecnosti bojuje proti falšovaniu identifikačných dokumentov.

Biometria je automatická detekcia telesných znakov, ktoré sú ľahko merateľné a zároveň jedinečné pre každého jedinca a ich využitie na účely rozpoznávania osôb. Telesný znak je zosnímaný a automatizovane spracovaný biometrickým systémom, ktorý využíva výpočtovú silu informačných technológií. Od tohto znaku sa očakáva, že bude jedinečný, univerzálny v populácii a nebude meniť obsah charakteristických vlastností. Práve *odtlačky prstov*, ktoré sú jednou z najvyspelejších foriem biometrie zažívajú svoj rozmach a ich penetrácia do rôznych aspektov života je v poslednej dobe naozaj markantná. Biometrické rozpoznávanie odtlačkami prstov je široko akceptované kvôli tomu, že odtlačky spĺňajú niektoré kritériá ako jedinečnosť, univerzálnosť, nemennosť a kvantifikovateľnosť. Okrem toho existuje množstvo cenovo prístupných snímacích zariadení, snímanie nie je invazívne, technológia má svoje zázemie už takmer sto rokov a existujú štandardy, ktoré musia spĺňať biometrické systémy, ktoré plnia úlohu vo vládnej alebo forenznej oblasti.

Rozpoznávanie osoby prostredníctvom odtlačku je vo svojej podstate *problémom rozpoznávania komplexného vzoru*, ktorý obsahuje desiatky lokálnych charakteristických zvláštností. Odtlačky prstov obsahujú vzory, ktoré sú ľahko rozpoznateľné aj pri nižšej obrazovej kvalite, no na druhej strane obsahuje aj významné vlastnosti, ktoré sú vplyvom nedostatočnej kvality odhaliteľné len veľmi ťažko. Ďalším problémom, ktorý vystupuje pri odtlačkoch prstov do popredia je nestabilná reprezentácia odtlačku, ktorý je reprodukciou vzoru prítomného na jednom prste. Pri každom snímaní získame mierne odlišnú podobu odtlačku rovnakého prsta, čo môže spôsobiť, že automatizovaný systém nemusí rozpoznať legitímnu osobu a na druhej strane môže omylom rozpoznať osobu, ktorá nie je v databáze. Rozpoznávanie osoby odtlačkami prstov je úloha, ktorej cieľom je extrahovať z obrazca odtlačku len charakteristické črty skryté v detailoch papilárnych línií a porovnať ich s existujúcou biometrickou vzorkou uloženou v databáze.

Neurónové siete sú výpočtové modely, ktoré sú úspešné pri rozpoznávaní komplikovaných vzorov a preto si svoje miesto našli aj v tejto oblasti biometrie. Sú schopné adaptovať svoje rozhodovacie schopnosti na špecifickú množinu vzorov, v ktorej dokážu správne klasifikovať vzory aj napriek spomínanej vnútrotriednej variabilite. Táto miera tolerancie odchýlok robí neurónové siete excelentným klasifikátorom s možnosťou implementácie umožňujúcej paralelné výpočty.

3. 2 Vhodnosť neurónových sietí na rozlišovanie vzorov v odtlačku

Existuje zopár dôvodov prečo sú neurónové siete vhodné na riešenie problému rozpoznávania osôb odtlačkami prstov.

1. Odtlačok prsta je špecifický vzor, ktorý z biologického hľadiska umožňuje formácie len určitých daktyloskopických vzorov. V porovnaní s premenlivosťou tvarov písaného textu v rôznych jazykoch je odtlačok vzorom, ktorý na globálnej úrovni topológie vykazuje len obmedzený počet tvarov. Naopak, tvarová variabilita je prítomná až na lokálnej úrovni. Plocha odtlačku je charakteristická tým, že každá jej časť obsahuje konkrétne zakrivenia papilárnych línií, ktoré sú pre danú časť plochy typické. Čiže *odtlačok je dobre definovaný vzor, ktorý neobsahuje ľubovoľné tvary, ale len tvary, ktoré sú prípustné pre daktyloskopický vzor.*
2. Neurónové siete sa vyhýbajú niektorým nástrahám, ktorými sú poznačené konvenčné metódy. Je dlhodobo známym faktom, že *odtlačky prstov môžu byť porovnávané len na základe daktyloskopických markantov*, čo sú drobné tvarové zvláštnosti v priebehu papilárnych línií. Môžeme si pod nimi predstaviť ukončenia, rozdvojenia, premostenia, prekríženia a ďalšie topológie papilárnych línií. *V ich rozmiestnení a orientácii je skrytá neopakovateľnosť každého odtlačku*, nakoľko v globálnej štruktúre odtlačku rozlišujeme len 3 základné vzory. Klasifikácie daktyloskopických markantov sa líšia, no viaceré zdroje uvádzajú klasifikáciu do 10 až 15 tvarov. Kompletný odtlačok prsta obsahuje v priemere okolo 100 daktyloskopických markantov. Na spoľahlivé určenie identity potrebujeme nájsť zhodu vo väčšom počte týchto tvarov, viaceré zdroje hovoria o počte 10 a viac.

Porovnávanie odtlačkov na základe daktyloskopických markantov má dve nevýhody:

- citlivosť na šum a iné degradácie kvality obrazu
- výpočtová náročnosť porovnávania markantov (sú reprezentované vo forme grafu)

Tým, že *neurónová sieť spracúva odtlačok ako celok*, vyhýba sa problematickému odhaľovaniu daktyloskopických markantov.

3. Neurónové siete *sú adaptívne a dokážu sa učiť z príkladov*. Toto je mimoriadne výhodná vlastnosť pretože, ak prispôbime neurónovú sieť na špecifické prostredie

a v procese tréovania zahrnieme medzi vzorky rôzne kvalitatívne degradované verzie odtlačku jedného prsta, sieť sa naučí tieto deformácie rozpoznávať. Odtlačok je vzor, ktorý vzniká reprodukciou pokožky na povrchu senzora a nedá sa dosiahnuť dokonale rovnaká reprezentácia pri jednotlivých snímaníach. Navyše, v kriminalistike sa pracuje s odtlačkami, ktoré sú snímané z rôznych povrchov, kde dochádza značnému znehodnoteniu a niekedy nie je možné získať celú plochu odtlačku, ale len jej fragment.

4. Tradičné prístupy rozpoznávania osôb odtlačkami prstov pri každom porovnaní dvoch odtlačkov musia vykonávať výpočtovo náročné úlohy ako sú normalizácia vstupných údajov, predspracovanie a extrakcia charakteristických znakov. Pri neurónových sieťach je kritickým bodom tréovanie siete, kde sa očakáva vhodná tréovacia vzorka a vhodný algoritmus učenia sa. *Potom ako máme neurónovú sieť natrénovanú na špecifickú vzorku je jej použitie veľmi rýchle.*

3.3 Konkrétne aplikácie neurónových sietí

Z technického hľadiska existujú tri základné oblasti, kde je možné využiť neurónovú sieť pri spracovaní odtlačkov prstov:

- Extrakcia vybraných vlastností odtlačku
- Klasifikácia globálneho vzoru odtlačku
- Porovnávanie odtlačkov

Extrakcia markantov je popis odtlačku obmedzeným počtom parametrov, ktoré modelujú jedinečnosť každého odtlačku. Týmito parametrami sú zväčša polohy rôznych konfigurácií papilárnych línií. Na ich odhalenie je používaná komplikovaná štruktúrna analýza s pravidlami, ktoré musia zohľadňovať prirodzenú premenlivosť hľadaných tvarov. Okrem markantov je každý odtlačok definovaný aj špecifickými smermi v rôznych častiach odtlačku. Spoločná extrakcia týchto vlastností býva návrhovo aj výpočtovo zložitá. Neurónové siete ponúkajú alternatívny prístup, v ktorom sú schopné tieto parametre rozpoznávať na základe vopred naučených podobných vzorov.

Klasifikácia databázy odtlačkov do viacerých tried výrazne zrýchľuje proces prehľadávania databázy pri hľadaní zhodného odtlačku. Najčastejšie používaná je klasifikačná schéma, ktorá rozlišuje 3 vzory globálneho usporiadania papilárnych línií v odtlačku (slučka, vír a oblúk). Pre neurónové siete klasifikačný problém tohto charakteru vhodný pretože každý z troch spomínaných vzorov je daný polohou ľahko rozpoznateľných singulárnych bodov, ktoré sa od okolitého obrazu líšia smerovou turbulenciou.

Či sa jedná o verifikačný alebo identifikačný biometrický systém, vždy by mal takýto systém jasne definovať kritériá kedy dva odtlačky pochádzajú z rovnakého prsta. Neurónová sieť zohráva v tomto prípade špecifickú úlohu nakoľko prezentuje osobitný systém rozhodovania, ktorý závisí od miery adaptácie siete na tréovaciu vzorku a stavu vnútorných parametrov. Teda základným rozdielom medzi neurónovou sieťou a konvenčnými porovnávacími

algoritmami je, že v prípade neurónovej siete výsledok porovnania závisí od jej vnútorných parametrov a v prípade konvenčných technik závisí od ad-hoc vyhodnotenia podobnosti dvoch reprezentácií odtlačku na základe pevných pravidiel.

3. 4 Techniky extrakcie vybraných vlastností odtlačku pomocou NS

3. 4. 1 Extrakcia smeru papilárnych línií na báze neurónovej siete

Zdroj: [2] *Fingerprint Ridge Orientation Estimation Based on Neural Network*. ZHU, E.et al.

Súhrn

Orientácia papilárnych línií je fundamentálnou vlastnosťou každého odtlačku. Od jej spoľahlivého modelovania prostriedkami obrazového spracovania závisia mnohé činnosti, bez ktorých nie je práca biometrického systému možná. Na mape orientácie papilárnych línií stojí celý rad algoritmov počnúc odhadom kvality, cez extrakciu osobitných vlastností, kontextové filtrovanie, klasifikáciu odtlačkov až po samotné porovnávanie. Väčšina tradičných metód na softvérové odhalenie smeru pracuje s intenzitami obrazových bodov v malom hypotetickom bloku obrazu. Pravdepodobne najznámejšia konvenčná metóda vychádza z výpočtov smeru lokálnych gradientov intenzity obrazu. Metóda z článku vychádza z iného prístupu, konkrétne sa prezentuje neurónová sieť schopná naučiť sa smery v odtlačku. Opisovaná sieť v článku má vlastnosť odpovedať na skutočné orientácie papilárnej línie vysokou výstupnou hodnotou a naopak pri falošných smeroch odpovedá nízkou výstupnou hodnotou. Originálny odtlačok je rozdelený do blokov a neurónová sieť odpovedá na príslušné smery, ktoré sa postupne zaznamenávajú a tvoria tak smerovú mapu odtlačku.

Architektúra siete, tréning a testovanie

Modelovanie orientácie papilárnych línií je témou, ktorou sa zaoberalo viacero autorov. Existuje mnoho prístupov ako tento problém riešiť. Okrem známej gradientovej techniky existujú metódy, ktoré modelujú celkovú orientáciu podľa singulárnych bodov. Tieto však zlyhávajú pri odlišení odtlačkov, ktoré majú rovnaké typy a polohy singulárnych bodov. Odhad smeru papilárnej línie v poškodenom odtlačku nie je úplne vyriešeným problémom. Dominantná gradientová technika tu dosahuje neuspokojivé výsledky, pretože sa spolieha na zreteľné okraje papilárnych línií, v ktorých sa dá jednoducho detegovať smer najstrmšieho klesania intenzity obrazových bodov. Nejasné a falošné okraje papilárnej línie sú problémom. Namiesto spoliehania sa na lokálne tvary, predložená metóda využíva techniku strojového učenia sa, kde sa extrahuje orientácia na základe väčšej plochy papilárneho terénu.

Odhad smeru papilárnych línií

Sieť má podľa návrhu autorov 11 vstupných neurónov, 11 neurónov v skrytej vrstve a 1 neurón vo výstupnej vrstve. Sieť má za úlohu odhadovať prostredníctvom výstupnej hodnoty kvalitu obrazu v odtlačku. Výstupný neurón odpovedá na korektnú orientáciu papilárnej línie vysokou hodnotou. Korektná orientácia je taká orientácia, ktorá prislúcha bloku, kde sú jasne rozlíšiteľné papilárne línie. Na obrazový blok, ktorý neobsahuje žiadne papilárne línie alebo obsahuje neobnoviteľnú časť odtlačku odpovedá nízkou hodnotou. Pre každý obrazový blok sa vypočíta vektor charakteristík $\langle C_1, C_2, \dots, C_{11} \rangle$. Tento vektor je vstupom do siete. Autori síce priamo v článku nevysvetľujú proces získania týchto charakteristík, no tvrdia, že elementy C_5 až C_{11} majú úzky súvis práve s orientáciou papilárnych línií v bloku.

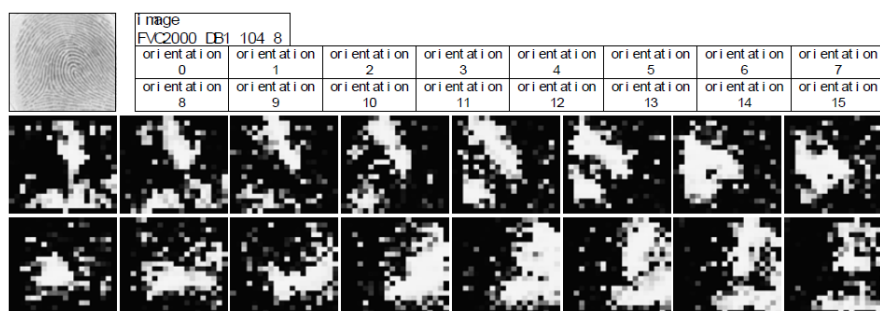
Predstavme si, že máme obraz odtlačku rozdelený na neprekrývajúce sa bloky a blok zacentrovaný v bode (i,j) označme ako $W(i,j)$. Orientáciu rozlišujeme v diskretnom priestore 16 preddefinovaných orientácií, pričom k -tu orientáciu označujeme ako:

$$\text{Orientácia}(k) = k \cdot \frac{\pi}{16} \quad (0 \leq k < 16)$$

Pre každý blok sa vypočíta 16 vektorov $\langle C_1, C_2, \dots, C_{11} \rangle^k$, ktoré vyjadrujú silu orientácie odtlačku v jednotlivých k smeroch v danom bloku. Pre každý blok sa spracuje neurónovou sieťou všetkých 16 vektorov a vypočíta sa tak 16 odpovedí siete. Sieť odpovie s vysokou hodnotou na ten vektor, ktorý reprezentuje správnu orientáciu bloku. Z odpovede siete sa odvodí smer nasledovne:


- V každom bloku obrazu sa vytvorí spomínaných 16 vektorov reprezentujúcich 16 základných smerov od 0 po π . Pre každý vektor sa vypočíta odpoveď siete.
- Výstupné hodnoty siete sa prefiltrujú v smerovej doméne pomocou nízko-priepustného filtra.
- Výstupné hodnoty sa opäť prefiltrujú v obrazovej doméne rovnakým typom filtra.
- Selekcia orientácie

Na obr. 5 vidíme vizuálnu podobu výstupných hodnôt siete na všetkých 16 vektorov. Biele body indikujú, že je vysoko pravdepodobné, že prislúchajúci blok v odtlačku má korektnú orientáciu.



Obrázok 5 Obrazy výstupných hodnôt siete na jednotlivé orientácie

Na vylúčenie falošných orientácií sa aplikovalo na obraz výstupných hodnôt siete nízko-priepustné filtrovanie, najprv v smerovej doméne a následne v obrazovej. Cieľom bolo vylúčiť izolované biele body a dosiahnuť plynulé zmeny v orientácii medzi blokmi. Výsledok filtrovania obrazu odpovedí siete je na obr. 6.




Obrázok 6 Filtrovanie obrazov odpovedí siete pomocou nízko-priepustného filtra

Majme vektor odpovedí siete $R[k](i,j)$ pre všetkých k orientácií pre blok zacentrovaný v bode (i,j) . Za charakteristický smer v bloku sa zvolí ten, ktorý prislúcha najväčšej odpovedi siete zo všetkých 16 orientácií. Ak je k -ta odpoveď siete maximálna, potom príslušný smer v bloku sa vypočíta vzťahom:

$$O(W(i,j)) = k \cdot \frac{\pi}{16}$$


Výsledky

Na obr. 7 vidíme výsledok odhadu orientácie v odtlačku neurónovou sieťou. Boli porovnané výsledky opisovanej metódy (B) s výsledkami známej techniky založenej na smere gradientov v jednotlivých obrazových bodoch (A). Referenčnými smermi v procese tréningu boli smery vyznačené ručne v jednotlivých blokoch. Nakoľko je takýto postup zdĺhavý, databáza obsahuje len malý počet vzoriek.



Obrázok 7 Výsledok odhadu orientácie papilárnych línií odtlačku

Spomínané metódy boli porovnané na základe početnosti blokov, v ktorých metóda nesprávne odhadla smer. Testovanie bolo uskutočnené na 5 obrázkoch. V tabuľke na obr. 8 vidíme výsledky spoločne s ukázkovým odtlačkom a smerovou mapou odhadnutou oboma metódami. Navrhnutá metóda dosiahla približne 5-násobne menší počet nesprávne odhadnutých smerov v blokoch.



	the number of ridge blocks of incorrect orientation	
	method A	method B
image 1	25	0
image 2	18	3
image 3	10	2
image 4	60	15
image 5	62	0

Obrázok 8 Odhad smerovej mapy (vrchná časť) a počty blokov s nesprávne odhadnutou orientáciou (spodná časť)

3. 4. 2 Extrakcia markantov z kostry odtlačku využívajúca neurónové siete

Zdroj: [3] *Neural Network Based Minutiae Extraction From Skeletonized Fingerprints.*
BARTŮŇEK, J. S. et al.

Súhrn

Odtlačky prstov sú plné detailov, ktoré sú využiteľné pri rozpoznávaní osôb. Tieto detaily slúžia biometrickým systémom na automatizované rozpoznávanie identity, kde nie je nutný zásah človeka. Odtlačok prsta obsahuje mnohé grafické tvary, ktoré sú rôznorodo orientované. Ak považujeme odtlačok za dvojrozmerný signál, môžeme ho transformovať prostredníctvom matematických funkcií do iných ako priestorových vyjadrení, v ktorých môžeme odhaľovať voľným okom ťažko merateľné charakteristiky. Aplikáciou rôznych filtrov, dokážeme z obrazu odtlačku odstrániť niektoré rušivé vplyvy a obnoviť tak jeho pôvodnú štruktúru. Jednou z alternatívnych reprezentácií odtlačku je kostra. Tá obsahuje odtlačok v pôvodnej štruktúre, avšak papilárne línie majú hrúbku 1 obrazového bodu. Na

rozpoznanie markantov papilárnych línií autori navrhli a natrénovali neurónovú sieť. Markanty sú najvýznamnejšie vlastnosti odtlačku, v ktorých sa každé dva odtlačky líšia. Vstupom do neurónovej siete je priamo obraz kostry. Extrahované markanty môžu byť ďalej využité v etape porovnávania dvoch odtlačkov.

Architektúra siete, tréovanie a testovanie

Najfrekvencovanejšie a najjednoduchšie tvary markantov sú ukončenia a rozdvojenia papilárnych línií. Ich tvar ani poloha sa počas života jednotlivca nemení. Existuje veľký priestor na vytvorenie rôznych kombinácií týchto tvarov, čo sa týka ich polohy, usporiadania, orientácie, vzájomnej vzdialenosti a ďalších atribútov, pri ktorých je malá šanca, že sa zopakujú u nejakého jedinca v populácii.

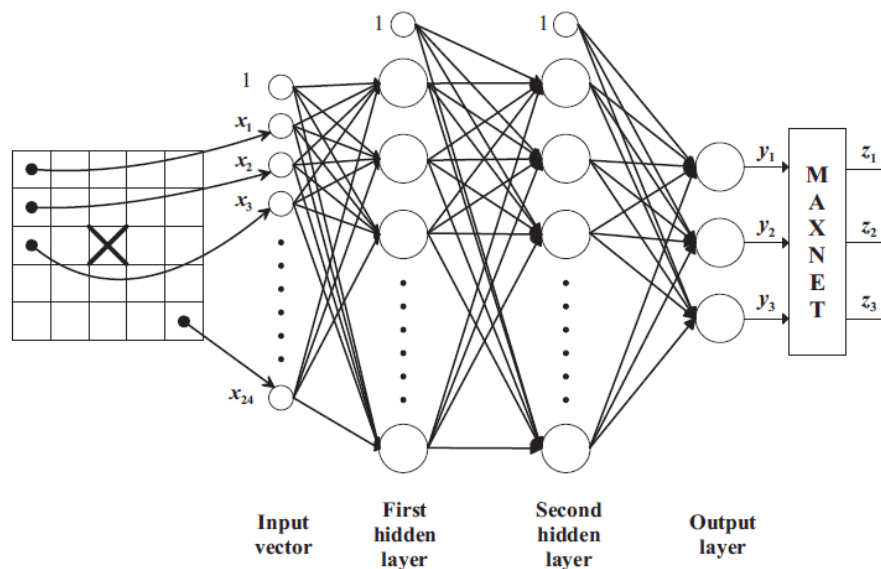
Keďže odtlačky sa líšia svojou kvalitou, obvykle sa pred extrakciou markantov vykonáva fáza predspracovania. Úsporná reprezentácia odtlačku, ktorá šetrí miesto v databáze a zároveň stále dostatočne charakteristická je cieľom každej techniky extrakcie charakteristických znakov. Zúžením hrúbky papilárnych línií na úroveň 1 obrazového bodu získavame kostru odtlačku. V nej sa dá jednoduchou analýzou obrazových bodov určiť, kde sa nachádzajú body rozdvojenia a ukončenia. Rizikom, ktoré prináša kostra odtlačku je, že v procese jej tvorby sú do obrazu zavádzané niektoré falošné informácie a rovnako sú z obrazu skutočné detaily odstraňované. Bez ohľadu na to, o ktorej technike extrakcie markantov sa rozprávame, všetky sú založené na vyhodnocovaní určitých kritérií, ktoré sa testujú počas analýzy reprezentácie odtlačku, s ktorou pracujú. Je ťažké, navrhovať pravidlá, ktoré majú zohľadniť premenlivosť konkrétnych tvarov. Protipólom je strojové učenie sa rôznych tvarov a následná klasifikácia, kde možno očakávať určitý stupeň zovšeobecnenia naučeného tvaru. Toto je záležitosťou neurónových sietí. Pri tréovaní neurónových sietí je obzvlášť dôležité zloženie databázy a počet vzoriek.

Neurónová sieť ako klasifikátor markantov

Na rozlišovanie tvarov markantov bola navrhnutá viacvrstvová dopredná sieť na obr. 9. Táto sieť má 24 vstupov doplnených o jeden vstup, ktorý zastupuje predpätie (z angl. bias). Má dve skryté vrstvy s 25 neurónmi v každej. Výstupná vrstva má 3 neuróny, pričom každý reprezentuje špecifickú triedu vzoru. Bipolárna sigmoidálna funkcia bola zvolená za aktivačnú funkciu neurónov. Táto funkcia má aj kladné aj záporné funkčné hodnoty. Na určenie, do ktorej triedy patrí vstupný vzor, za výstupné neuróny sa zaradil výpočtový blok s názvom MAXNET. Tento blok porovnáva trojprvkový výstupný vektor y . Ten neurón, ktorý má najvyššiu hodnotu je aktivovaný neurón. Výstupom z MAXNET-u je vektor $z = [z_1 \ z_2 \ z_3]$.

- Ak je aktivovaným neurónom y_1 , vektor z bude mať zloženie $z = [1 \ 0 \ 0]$ a znamená to, že vstupný vzor je ukončenie papilárnej línie

- Ak je aktivovaným neurónom y_2 , potom $z = [0 \ 1 \ 0]$ a znamená to, že vstupný vzor je rozdvojenie papilárnej línie
- Nakoniec, ak je aktivovaný posledný neurón y_3 , potom $z = [0 \ 0 \ 1]$ značí, že vzor nie je markantom



Obrázok 9 Vrstvy neurónovej siete, ktorá klasifikuje markanty v kostre odtlačku

Trénovanie siete

Neurónová sieť ovplyvňuje svoje váhy učením. Algoritmus spätného šírenia chyby je najobvyklejším princípom učenia a bol použitý aj v tejto sieti. Učenie je vtedy založené na výpočte chybového signálu e , ktorý získame ako rozdiel medzi očakávaným výstupným vektorom d a skutočným výstupným vektorom y . Táto chyba sa postupne oznámi všetkým neurónom v predchádzajúcich vrstvách a váhy ich synaptických prepojení sa nastavujú tak, aby chyba neurónu klesala po chybovom povrchu, čo najstrmšie. Váhy sa nastavili náhodne výberom z normálneho rozdelenia v rozpätí $[-0.5, 0.5]$. Ako aktivačná funkcia bola použitá nasledovná bipolárna sigmoidálna funkcia:

$$f(u) = \alpha \tanh(\beta u)$$

$$\alpha = 1.7159$$

$$\beta = \frac{2}{3}$$


Pri zvolených parametroch platí, že $f(-1) = -1$ a $f(1) = 1$. Váhy sa aktualizujú po každej tréningovej vzorke. Tréningové vzorky sú volené náhodne, aby si sieť nezapamätala poradie. Parameter rýchlosti učenia sa η nie je konštantný, ale mení sa. Predpis zmeny tohto parametra je daný vzťahom:

$$\eta(epoch) = \frac{\eta_0}{1 + epoch/\tau}$$

epoch predstavuje poradové číslo trénovacej iterácie, po ktorej boli všetky trénovacie vzory spracované sieťou. Po každej epoche sa rýchlosť učenia η znižuje podľa rovnice. $\tau = 5\,000$ a $\eta_0 = 0.01$, sú experimentálne zvolené konštanty. Fenomén pretrénovania siete znamená, že sieť je príliš adaptovaná na trénovacie vzorky a tak dosahuje pri testovacích vzorkách nízku úspešnosť. Aby sme zabránili pretrénovaniu, musíme ho včasne zastaviť. Na zastavenie trénovania sa používa výstup z bloku MAXNET, podľa ktorého si vieme overiť počet správne klasifikovaných vzorov. Keď počet nesprávne klasifikovaných vzorov v epoche dosiahne úroveň 0, trénovanie sa zastaví.

Trénovacia databáza

Trénovacie vzorky odtlačkov sú rozdelené do troch tried: ukončenie, rozdvojenie a bod, ktorý nepredstavuje žiadny markant. Ukázalo sa, že okno veľkosti 3×3 nezahŕňa dostatočné množstvo informácie a okno 7×7 môže v niektorých prípadoch obsahovať viac ako 1 markant. Preto sa použilo okno veľkosti 5×5 . Tieto okná sú centrovane v bodoch papilárnych línií kostry. Nepárna veľkosť okna pomáha pri jednoduchom stanovení centrálného bodu.




Obrázok 10 Vplyv veľkosti okna na zachytenie podstatných rysov markantu

Trénovacia vzorka obsahovala celkovo 23 kostier odtlačkov. Tie vzory, ktoré sieť nedokázala správne zaradiť zostali po epoche v trénovacej databáze a tie vzory, ktoré sieť zaradila správne boli z trénovacej množiny po epoche odstránené. V 23 kostrách bolo zaregistrovaných 1951 odlišných vzorov v okne 5×5 . Celkovo bolo odhalených 84 vzorov ukončení, 388 vzorov rozdvojení a 1479 vzorov bodov, ktoré neboli markantmi. Tieto vzory boli manuálne vybrané tak, aby sa nachádzal markant v strede okna 5×5 . Neurónová sieť bola natrénovaná na manuálne vybraných vzoroch a testovaná takým spôsobom, že sa postupne prechádzali čierne body kostry a ich okolie veľkosti 5×5 bolo vstupom do neurónovej siete.

Kostra odtlačku obsahovala v priemere iba 30 % čiernych obrazových bodov a teda nebolo treba vyšetrovať celú kostru. Keďže v okne 5×5 je stredový bod vždy čierny a neprináša sieti novú informáciu je ignorovaný a vstupný vektor tak obsahuje namiesto 25 prvkov len 24 prvkov. Ak pri testovaní neurónová sieť rozhodne, že je neznámy vzor markantom, zapamätajú sa jeho súradnice.


Výsledky

Navrhnutá metóda extrakcie markantov bola testovaná integráciou do existujúceho biometrického systému. V testovacom procese sa pracovalo so 40 odtlačkami prstov (2 odtlačky od každého z 20 ľudí). Odtlačky pochádzali z verejnej databázy FVC2002 Db1_a. Každý odtlačok bol binarizovaný a „skeletonizovaný“ tak, aby sme z pôvodného odtlačku získali čiernobielu kosť. Odtlačky sú porovnávané markantmi, ktoré rozpozná v kostre neurónová sieť.



Obrázok 11 Výsledky siete pri rozpoznávaní identických a neidentických párov odtlačkov

Vykonal sa 2 testy. Porovnávali sa identické odtlačky a všetky kombinácie odtlačkov rôznych osôb. Výsledky sú kvantifikované grafom, na ktorom je vidieť závislosť strednej kvadratickej chyby od relatívneho počtu zhodných markantov v odtlačku. Vidno, že neidentické páry odtlačkov sa zhodovali v menšom počte markantov a zhodné dvojice markantov sa výrazne líšili v polohách. Na druhej strane, identické páry odtlačkov sa zhodovali vo väčšom počte markantov a tie markanty boli minimálne polohovo rozdielne. Takto sa vytvorili dva zhluky, ktoré jasne odlišujú odtlačky z rôznych prstov od odtlačkov z rovnakého prstu. Spomínaný graf je na obr. 11. Ukážka lokalizovaných bodov v kostre odtlačku je na obr. 12.



Obrázok 12 Výsledok extrakcie markantov

3. 5 Techniky klasifikácie globálnych vzorov odtlačku pomocou NS

3. 5. 1 Klasifikácia odtlačkov podľa singulárnych bodov s využitím neurónových sietí

Zdroj: [4] *Classification of Fingerprint Images Using Neural Networks Technique.*
ALSHEMMARY, E. N. A.

Súhrn

Na efektívne prehľadávanie veľkých databáz odtlačkov prstov je nutná rýchla a spoľahlivá technika klasifikácie odtlačkov do základných tried daktyloskopických vzorov. Tieto vzory sa zvyknú nazývať aj ako Level-1 vzory. Level-1 vzory predstavujú celkový vzor odtlačku so špecifickým rozložením a zakrivením papilárnych línií na celej ploche odtlačku. Veľké množstvo automatizovaných klasifikačných techník bolo navrhnutých, avšak len niektoré z nich boli využité v počítačových systémoch daktyloskopickej evidencie v prostredí kriminalistiky. Klasifikácia odtlačkov podľa ich globálnej topológie je ideálna úloha pre neurónovú sieť. Metóda klasifikácie markantov popísaná v článku využíva polohu singulárnych bodov na klasifikáciu odtlačku. Prítomnosť šumu sťažuje detekciu singulárnych bodov, jadra a delty. Článok prezentuje výsledky klasifikácie navrhnutou neurónovou sieťou, ktorá vykonáva funkciu rozhodovania.


Architektúra siete, tréovanie a testovanie

Pravidlá klasifikácie konvenčných techník

Klasifikácia odtlačkov na úrovni Level-1 vzorov bežne vychádza z Henryho klasifikačného systému, ktorý zaraďuje vzory odtlačkov do 5 tried:

- Oblúk bez delty
- Oblúk s deltou
- Ľavá slučka
- Pravá slučka
- Vír

Každý z týchto tvarov je určený špecifickým rozmiestnením singulárnych bodov: jadro a delta. Na obr. 13 vidíme počty jednotlivých singulárnych bodov v každej triede vzoru odtlačku a vizuálnu reprezentáciu týchto vzorov v rovnakom poradí ako v tabuľke.



Pattern Class	Core	Delta
Arch	0	0
Tented Arch	1	1 (middle)
Left Loop	1	1 (right)
Right Loop	1	1 (left)
Whorl	2	2

Obrázok 13 Triedy vzorov odtlačku a prislúchajúce počty singulárnych bodov

Jadro odtlačku je definované ako najvyšší bod v najvnútornejšej papilárnej línii. Delta je miesto, kde sa stretávajú toky papilárnych línii troch odlišných smerov. Tieto body sú odolné voči rotácii a deformácii. Niekedy prítomnosť jaziev alebo čiastočné odtlačky znemožňujú odhalenie polohy singulárneho bodu a preto štandardné klasifikačné techniky v týchto prípadoch zlyhávajú.

Neurónové siete sú známe svojou schopnosťou generalizácie a tolerovania chýb na vstupe a preto sa javia ako vhodný nástroj na klasifikáciu. Neurónové siete sa učia z príkladov a môžu byť adaptované na špecifické podmienky, kde môžu dosahovať veľmi dobré výsledky. Pred konečným použitím neurónovej siete je v článku opis techniky, ktorá vypočíta smerovú mapu odtlačku na základe dobre známeho algoritmu, ktorý využíva smer gradientu

obrazových bodov. Zo smerovej mapy sú odvodené polohy singulárnych bodov na základe Poincarého indexu. Poincarého index v bode (i,j) je vypočítaný nasledovne:

$$Poincare(i, j) = \frac{1}{2\pi} \sum_{k=0}^{N-1} \Delta(k)$$

$$\Delta(k) = \begin{cases} \delta(k) & \text{if } |\delta(k)| < \frac{\pi}{2} \\ \pi + \delta(k) & \text{if } \delta(k) < -\frac{\pi}{2} \\ \pi - \delta(k) & \text{otherwise} \end{cases}$$

$$\delta(k) = \theta(x_{(k+1) \bmod N_p}, y_{(k+1) \bmod N_p}) - \theta(x_k, y_k)$$


N je počet bodov krivky, ktorá obkolesuje daný bod (okolitých N susedných bodov) a θ je orientácia bodu. Na základe odhalených singulárnych bodov sa dá odtlačok zaradiť do jednej z troch tried:

- Oblúk bez delty (0 jadier a 0 delta bodov)
- Oblúk s deltou, ľavá a pravá slučka (1 jadro a 1 delta bod)
- Vír (2 jadrá a 2 delta body)

Na odlišenie viacerých singulárnych bodov v 1 triede sa používa orientácia úsečky, ktorá spája jadro s deltou.

Model neurónovej siete

Článok prezentuje typ reprezentácie odtlačku, ktorý zachytáva globálnu štruktúru odtlačku spolu s detailmi markantov. Na odtlačok sa najprv aplikujú 2D Gaborove filtre s rotáciami $0, \frac{\pi}{4}, \frac{\pi}{2}$ a $\frac{3\pi}{4}$. Vytvorí sa tak 4 obrazové komponenty. Vektor charakteristických znakov tak má veľkosť 4×100 . Tieto komponenty zachytávajú väčšinu informácií o smere papilárnych línií. Neurónový klasifikátor opísaný v článku je trojvrstvový perceptrón trénovaný na základe algoritmu delta pravidla. Zvolená topológia siete je na obr. 14. Obrázok je ilustračný, počet neurónov vo vrstvách bol odlišný.



Obrázok 14 Topológia neurónovej siete určenej na klasifikáciu vzorov odtlačku

Prvou vrstvou je vstupná vrstva, ktorej výstupom sú prvky vektora charakteristických znakov, ktoré boli extrahované v predchádzajúcej etape spracovania odtlačku. Veľkosť vstupnej vrstvy je preto rovná dimenzii vektora charakteristických znakov s pridaním jedného neurónu navyše. V testoch bola veľkosť vstupnej vrstvy 400 neurónov, ktoré korešpondovali prvkom filtrovaného odtlačku Gaborovým filtrom. Druhá vrstva je skrytá vrstva a tretia je výstupná. Každý neurón v skrytej vrstve vypočíta sumu všetkých vstupných spojení a predá ju ako vstup do aktivačnej funkcie. Voľba počtu neurónov v skrytej vrstve je otvorenou otázkou a správny počet sa dá určiť na základe opakovaných experimentov s rôznymi počtami neurónov v skrytej vrstve. Experimentálne sa ukázal počet 20 neurónov skrytej vrstvy ako optimálny. Výstupná vrstva má jeden neurón pre každú triedu Level-1 vzoru odtlačku a keďže sme vychádzali z Henryho klasifikačnej schémy, výstupná vrstva obsahuje 5 neurónov. Pre neuróny skrytej aj výstupnej vrstvy sa použila sigmoidálna aktivačná funkcia. Ak niektorý neurón výstupnej vrstvy odpovie na daný vstupný vektor vysokou výstupnou hodnotou, tak sa tento vektor označí ako patriaci do triedy danej aktivovaným neurónom. Sieť je úplne prepojená a každé synaptické prepojenie má asociovanú váhu. Počas tréningu neurónovej siete sa váhy adaptujú na optimálne hodnoty, tak aby bola chyba siete na požadovanej úrovni. Váhy sa na začiatku procesu tréningu nastavujú na náhodné s požiadavkou, aby neboli príliš veľké alebo príliš malé. V prípade odtlačkov sa neurónová sieť ukazuje ako vhodná technika klasifikácie z dôvodu dobrej generalizácie natrénovaných schopností na vzorkách, kde neexistuje lineárny vzťah medzi vstupmi a výstupmi.

Výsledky

Dosiahnutá presnosť klasifikácie do 5 tried počas testovania neurónovej siete bola na úrovni 92,7 %. Klasifikácia do 4 tried dosahovala presnosť 95,9 %. Tabuľky presnosti klasifikácie (z angl. confusion matrices) pre jednotlivé scenáre sú na obr. 15.

True Class	Assigned Class				
	A	T	L	R	W
A	27 (96.4)	1 (3.6)	0 (0.0)	0 (0.0)	0 (0.0)
T	3 (17.6)	12 (70.6)	2 (11.8)	0 (0.0)	0 (0.0)
L	1 (3.8)	1 (3.8)	23 (88.5)	0 (0.00)	1 (3.8)
R	0 (0.0)	0 (0.0)	0 (0.0)	22 (100.0)	0 (0.0)
W	0 (0.0)	0 (0.0)	0 (0.0)	0 (0.0)	30 (100.0)
Overall accuracy 92.7%					

True Class	Assigned Class			
	A	L	R	W
A	43 (95.6)	2 (4.4)	0 (0.0)	0 (0.0)
L	2 (7.7)	23 (88.5)	0 (0.0)	1 (3.8)
R	0 (0.0)	0 (0.0)	22 (100.0)	0 (0.0)
W	0 (0.0)	0 (0.0)	0 (0.0)	30 (100.0)
Overall accuracy 95.9%				

Obrázok 15 Úspešnosť klasifikácie do 5 a 4 tried

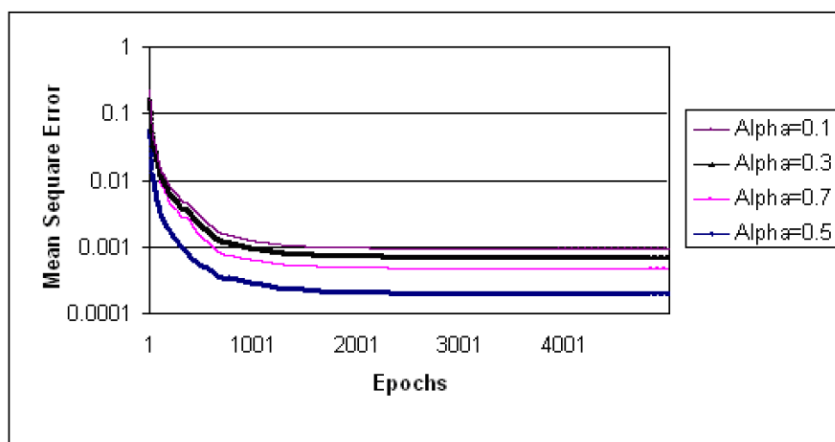
Z výsledkov v tabuľkách možno dospieť k záveru, že neurónová sieť vo všetkých prípadoch správne klasifikovala vzor pravá slučka a vír. Pri klasifikácii do 5 tried mala sieť najnižšiu úspešnosť pri triede oblúk s deltou. Pri klasifikácii do 4 tried, mala sieť najväčšie problémy s rozpoznaním vzoru ľavá slučka.

Epoch	$\alpha = 0.1$	$\alpha = 0.3$	$\alpha = 0.5$	$\alpha = 0.7$
1000	0.000279	0.000309	0.000282	0.000347
2000	0.000234	0.000238	0.000209	0.000281
3000	0.000227	0.000231	0.000202	0.000248
4000	0.000224	0.000229	0.000201	0.000227
5000	0.000222	0.000227	0.0002	0.000206

Obrázok 16 Stredná kvadratická chyba pri rôznych rýchlostiach učenia a pri rôznych počtoch tréningových iterácií


Trénovanie bolo realizované na vzorke 277 odtlačkov vybraných z databázy NIST-4. 123 odtlačkov bolo použitých na testovanie. Autor bližšie neuviedol detaily tejto vzorky ako počet odtlačkov na osobu alebo pomer zastúpenia jednotlivých Level-1 vzorov. Vývoj strednej kvadratickej chyby počas tréningovania je na obr. 17. Tento graf znázorňuje 4 krivky, pričom každá zodpovedá osobitnému parametru α , ktorý predstavuje rýchlosť učenia sa. Na základe zmien tohto parametra sa autor snažil zistiť, či tempo konverencie chyby nejakým spôsobom závisí od tohto parametra. Trénovanie siete bolo rozdelené do 5 fáz, pričom každá fáza

obsahovala 1 000 iterácií. Po každej iterácii sa zaznamenala výsledná stredná kvadratická chyba. Toto vyhodnocovanie siete je na obr. 16.



Obrázok 17 Vývoj strednej kvadratickej chyby počas tréningu navrhutej siete

Ako bolo naznačené vyššie, počet neurónov skrytej vrstvy sa stanovil experimentálne. Na obr. 18 vidíme zmeny strednej kvadratickej chyby siete pri rozličných počtoch neurónov v skrytej vrstve. Najlepšie výsledky sa dosiahli pri počte 12 a 20.



Obrázok 18 Stredná kvadratická chyba siete v závislosti od počtu neurónov v skrytej vrstve

Klasifikácia bola akceptovateľná aj v prípadoch, keď v odtlačku chýbali singulárne body alebo keď obsahoval falošné. Avšak klasifikácia si na upevnenie svojej úspešnosti vyžaduje kvalitnú techniku smerového filtrovania. Detekcia singulárnych bodov je potrebná nielen pri klasifikácii odtlačkov, ale aj pri ich porovnávaní napríklad na zarovnanie dvoch vyšetřovaných odtlačkov. Očakáva sa, že sieť by dosiahla vyššiu úspešnosť ak by bol odtlačok reprezentovaný charakteristickejšími parametrami, napríklad smermi papilárnych línii alebo ich hrúbkami.

3. 6 Techniky porovnávania odtlačkov pomocou NS

3. 6. 1 Porovnávanie odtlačkov na báze daktyloskopických markantov

Zdroj: [5] *Neural Networks Applied to Fingerprint Recognition*. GONZÁLEZ, A. et al.

Súhrn

Biometrický systém na báze odtlačkov prstov je systém zložený z viacerých komponentov. Niektoré z týchto komponentov vykonávajú úlohy, ktoré sú efektívne riešiteľné práve neurónovými sieťami. Neurónové siete môžu byť použité na extrakciu vzorov, klasifikáciu globálnych vzorov a porovnávanie odtlačkov. Autori v tomto článku opisujú nasadenie viacvrstvového perceptrónu pri rozpoznávaní osôb odtlačkami so špeciálnym zreteľom na úspešnosť siete pri nekompletných odtlačkoch. Použitý bol algoritmus učenia sa so spätným šírením chyby. Navrhnutá neurónová sieť nespracovávala pôvodný obraz odtlačku, ale jeho reprezentáciu prostredníctvom daktyloskopických markantov a ich atribútov. Atribútom každého daktyloskopického markantu bola vzdialenosť markantu od iných markantov, orientácia markantu, jeho poloha v odtlačku a tvarový typ. Takáto reprezentácia odtlačku je charakteristická a podobná tej, s ktorou pracujú experti na daktyloskopickú identifikáciu. Daktyloskopické markanty boli extrahované z odtlačku externým špecializovaným softvérovým systémom, ktorý nevyužíval navrhnutú sieť. Testovanie pri premenlivom počte týchto bodov vyjadrovalo účinnosť siete pri identifikácii odtlačkov, ktoré nie sú kompletne, čo je jedna z výziev tejto technológie. Navrhla sa špecifická architektúra siete a sledovala sa úspešnosť siete vzhľadom na početnosť daktyloskopických markantov prítomných v odtlačku. Úspešnosť začína klesať pri 12 markantoch, ale naopak je vyššia pri počte 10, 8 a 5. Tento spôsob testovania bol obzvlášť výhodný pretože ukazuje schopnosti siete správne identifikovať osobu pri rôznej kvantite znakov jeho jedinečnosti a zároveň tak odhaľuje do akej miery ovplyvňujú daktyloskopické markanty úspešnosť rozhodnutia.

Architektúra siete, tréning a testovanie

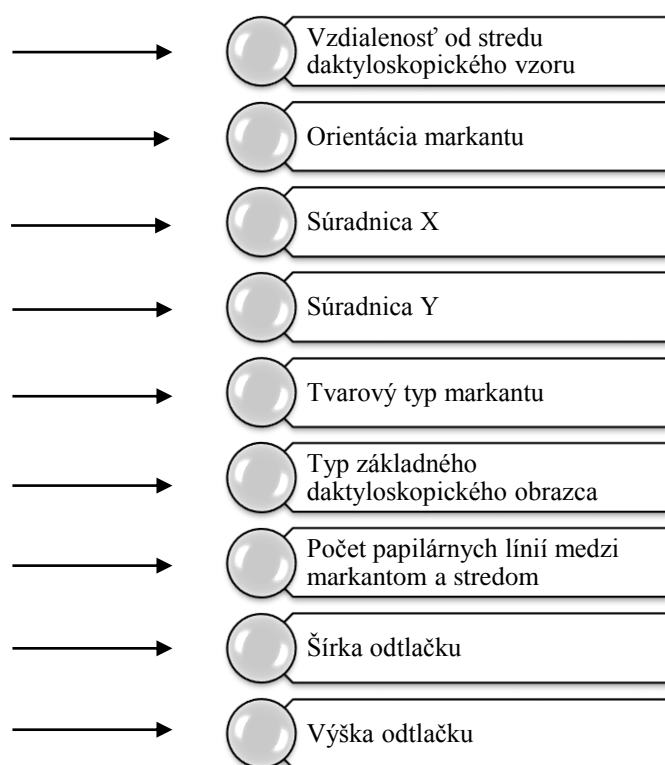
Táto metóda vychádza z faktu, že každý odtlačok je neopakovateľným vzorom z dôvodu existencie daktyloskopických markantov. Toto je záver, ku ktorému sa dopracovalo množstvo výskumníkov. Práve pozorovania jedinečnosti a vzácnej premenlivosti daktyloskopických markantov sú ústredným dôvodom, prečo sú odtlačky vôbec používané na odlišovanie jedincov, v takých serióznych aplikáciách akou je kriminalistika. Autori si uvedomili, že na porovnávanie odtlačkov je nutné vyjadriť odtlačok vo forme spomínaných markantov a rozlišovať ich atribúty. Z pohľadu kriminalistiky je potrebné nájsť zhodu v stanovenom minimálnom počte markantov. Tento počet sa z krajiny na krajinu líši. Na Slovensku je to 10 markantov. Rovnako Španielsko považuje za dostatočné 10 až 12 markantov.

Neurónová sieť je inšpirovaná biologickým ekvivalentom centrálného nervového systému. Je schopná sa učiť na príkladoch a má schopnosť zovšeobecnenia. Využíva sa na klasifikačné účely, rozpoznávanie vzorov signálov a predikciu. Navrhnutá sieť vychádza z predpokladu, že

odtlačok prsta bol predspracovaný a markanty boli extrahované. Následne sa pracuje už len s množinami informácií o markantoch, ktoré patria viacerými osobám.

V prvej fáze postupu sa autori zamýšľali nad tým, ktoré údaje budú používať na vyjadrenie jedinečnosti každého odtlačku. Vytvorili dve tabuľky charakteristických údajov. V prvej tabuľke sú zaznamenané okolia každého jedného daktyloskopického markantu vo forme počtu papilárnych línií, ktoré sa nachádzajú medzi dvomi skúmanými markantmi. V druhej tabuľke boli zaznamenané detaily každého markantu: súradnice, orientácia a tvarový typ. Tieto dve tabuľky tvorili trénovaciu množinu.

Z pohľadu architektúry, sieť využíva viacvrstvový perceptrón. V procese učenia bol použitý algoritmus spätného šírenia chyby. Sigmoidálna aktivačná funkcia bola jadrom neurónov v skrytej vrstve. Vo výstupnej vrstve bola použitá lineárna funkcia. Výber týchto funkcií bol výsledkom experimentov. Celková sieť pozostávala z 9 neurónov vo vstupnej vrstve. Každý vstupný neurón reprezentoval jednu charakteristiku daktyloskopického markantu.



Obrázok 19 Vizualná reprezentácia vstupnej vrstvy navrhnutej siete

Ďalej sieť obsahovala 2 skryté vrstvy s 11 neurónmi. Výstupná vrstva bola zložená z 11 neurónov, ktoré predstavovali ľudí v databáze. Každý neurón výstupnej vrstvy nadobudol hodnotu 0 alebo 1. Ak sa veľkosť skrytých vrstiev zvýšila nad hranicu 15 neurónov, sieť dosahovala globálne horšie výsledky.

Autori vytvorili 4 verzie takto skonštruovanej siete, pričom každá z nich sa líšila spôsobom tréningu.

1. verzia neurónovej siete bola trénovaná týchto charakteristikách:
 - vzdialenosť od stredu daktyloskopického vzoru
 - súradnica x
 - súradnica y
 - tvarový typ
2. verzia neurónovej siete bola trénovaná s rovnakými údajmi ako prvá len do tréningových charakteristík bola zaradená orientácia markantu
3. verzia neurónovej siete bola trénovaná s rovnakými údajmi ako druhá len do tréningových charakteristík bol zaradený počet papilárnych línií medzi markantom a stredom daktyloskopického vzoru
4. verzia neurónovej siete mala tréningovú množinu doplnenú šírkou a výškou odtlačku

Postupným testovaním takto natrénovaných sietí sa odhaľovala charakteristika, ktorá vnášala do výsledkov nepresnosť. V tabuľke na obr. 20 vidíme výsledky testov. Tabuľka bola autormi prezentovaná v španielčine a preto pod tabuľkou uvádzame aj vysvetlenia niektorých termínov.

Características	121	20	18	16	14	12	10	8	5	%
Todas	86.77	75.00	72.22	75.00	71.43	75.00	90.00	87.50	80.00	79.21
Sin ang.direccion	86.77	75.00	72.22	75.00	71.43	75.00	90.00	87.50	80.00	79.21
Sin ang.direccion y sin N_crestas	86.77	75.00	72.22	100	71.43	75.00	90.00	87.50	80.00	81.99
Sin ang.direccion, sin N_crestas, sin Cuad_x, sin Cuad_y	77.68	70.00	66.67	68.75	64.29	58.33	80.00	62.50	80.00	69.80
Sin ang.direccion, sin N_crestas, sin Cuad_x, sin Cuad_y, sin codigo_huella	86.77	80.00	77.78	81.25	78.57	75.00	90.00	75.00	80.00	80.48

Obrázok 20 Výsledky testov 4 verzií neurónovej siete

Vysvetlivky	
Španielsky výraz	Preklad
<i>características</i>	charakteristiky
<i>todas</i>	všetky charakteristiky
<i>ang_direccion</i>	orientácia markantu
<i>N_crestas</i>	počet papilárnych línií medzi markantom a stredom
<i>cuad_x</i>	šírka odtlačku
<i>cuad_y</i>	výška odtlačku
<i>ang_direccion</i>	orientácia markantu
<i>codigo_huella</i>	typ základného daktyloskopického vzoru

Výsledky

Z výsledkov v tabuľke je vidieť, že postupným znižovaním počtu daktyloskopických markantov mierne klesala aj úspešnosť rozpoznávania sieťou. Zaujímavosťou je, že pri počte 10, 8 a 5 bola sieť úspešnejšia než pri inom vyššom počte markantov. Z toho možno usúdiť, že presnosť neurónovej siete pri klasifikácii odtlačkov nie je závislá od počtu markantov, ako sa dalo predpokladať. Zároveň sa javí neurónová sieť ako schopný klasifikátor odtlačkov, pri ktorých máme obmedzenú množinu daktyloskopických markantov (10, 8 alebo 5 markantov). To je typické pri poškodených odtlačkoch alebo latentných stopách a výskum algoritmov, ktoré sú schopné vysporiadať sa s týmito faktormi je aktívnym poľom výskumu. Avšak na potvrdenie tohto tvrdenia potrebujeme testovanie na omnoho väčších vzorkách. Zahrnutím charakteristík ako orientácia markantu, počet papilárnych línií medzi stredom a markantom, výška a šírka odtlačku spolu s typom základného daktyloskopického vzoru sa nedosiahla vyššia úspešnosť. Preto je kľúčovým zistením tohto experimentu poznatok, že neurónová sieť môže byť úspešne použitá na menšej množine odtlačkov prstov a zároveň na zaručenie akceptovateľných výsledkov stačí, aby bol odtlačok vyjadrený množinou charakteristických bodov, ktoré sa líšia súradnicami, tvarovým typom a vzdialenosťou od daktyloskopického stredu.

3. 6. 2 Porovnávanie odtlačkov pomocou lokálnej oblasti daktyloskopického stredu

Zdroj: [6] *Neural Networks for Fingerprint Recognition*. BALDI, P. et al.

Súhrn

Publikácia autorov hovorí o zozbieraní obrázkov odtlačkov, z ktorých sa vytvorili prislúchajúce trénovacie a testovacie množiny a následne o architektúre prezentovanej neurónovej siete, ktorá vyčísluje pravdepodobnosť zhody dvoch odtlačkov prstov. Vstupom do siete tentoraz nie je jeden odtlačok, ale dvojica odtlačkov, pri ktorej nás zaujíma miera ich podobnosti. Neurónová sieť je trénovaná na stovkách párov odtlačkov a úspešnosť siete je testovaná na tisícoch párov odtlačkov, ktoré patria 20 osobám. Chybovosť siete dosiahla úroveň menej než 0,5 %. Porovnávanie odtlačkov nie je celé v režii neurónovej siete. Porovnávací algoritmus pozostáva z 2 krokov: predspracovanie a rozhodovanie. Predspracovanie je v podstate zarovnanie dvoch odtlačkov podľa ich daktyloskopického stredu a následná extrakcia centrálnej oblasti odtlačku, ktorá je vstupom do rozhodovacej fázy. Rozhodovanie je riadené neurónovou sieťou, ktorá implementuje Bayesovský pravdepodobnostný model rozhodovania, ktorý odhaduje pravdepodobnosť zhody p medzi dvomi odtlačkami. Sieť je trénovaná algoritmom učenia založenom na gradientovom zostupe. Trénovaciú vzorku tvorilo 300 párov obrazov z 5 prstov (5 obrazov pripadajúcich na jeden prst). Úspešnosť siete je testovaná na 4650 pároch obrazov, ktoré pochádzajú z ďalších 15 prstov (5 obrazov z každého prsta).

Architektúra siete, tréovanie a testovanie

Obmedzením pre tréovanie neurónovej siete navrhutej pre rozpoznávanie odtlačkov prstov je nedostupnosť vhodných databáz na účely tréovania a testovania. Vo verejných databázach je každý odtlačok zastúpený len jednou obrazovou reprezentáciou. Avšak tréovanie neurónovej siete si vyžaduje zopár modifikovaných verzií jedného odtlačku. Na účely experimentovania si autori vytvorili vlastnú zbierku odtlačkov v rozmeroch 512 x 464 obrazových bodov s 8 bitovou farebnou hĺbkou. Pri tejto mierke bola priemerná hrúbka jednej papilárnej línie približne 6 obrazových bodov. Celková databáza obsahovala viac než 200 obrazov odtlačkov z rôznych prstov zosnímaných 30 osobám. Odtlačky prstov rovnakej osoby boli zosnímané v rôznych časoch, aby si tak modelovali realistické podmienky. Odtlačky jednej osoby sa líšili v polohe, tlaku a stave povrchu pokožky. Tieto činitele spôsobujú vnútrotriednu variabilitu.

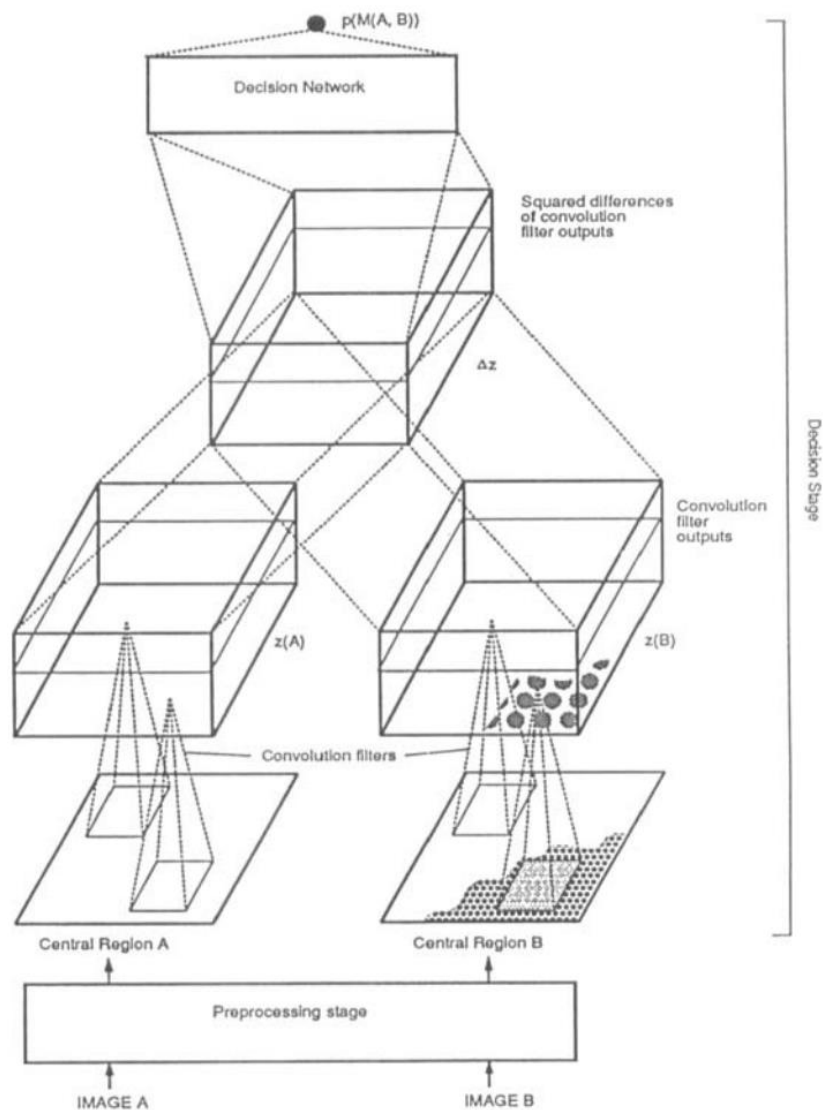
Trénovacia databáza obsahovala odtlačky 5 rôznych osôb, pričom každý prst bol zastúpený 5 obrazmi. Vytvorili sa všetky možné kombinácie dvojíc $\binom{25}{2} = 300$ párov odtlačkov. Testovacia databáza obsahovala odtlačky 20 osôb, 5 obrázkov na každú osobu. Opätovne sa vytvorili všetky možné kombinácie dvojíc $\binom{100}{2} = 4650$ párov odtlačkov. Testovacia databáza sa použila na overenie zovšeobecňovacej schopnosti siete. Cieľom bolo navrhnúť neurónovú sieť, ktorá vypočíta pravdepodobnosť zhody dvoch ľubovoľných odtlačkov p .

Krok predspracovania

Ako bolo spomenuté porovnávanie odtlačkov prebieha v 2 krokoch. V prvom kroku sa vykonáva predspracovanie aplikáciou nízko-priepustných filtrov, ohračením oblasti odtlačku a zarovnaním oboch vyšetrovaných odtlačkov. Zarovnanie sa dosiahne výberom centrálnej oblasti odtlačku A veľkosti 65 x 65 obrazových bodov a postupným posúvaním tohto bloku nad odtlačkom B a výpočtom korelácie obrazových bodov. Konečná centrálna oblasť odtlačku sa vyberie ako blok 65 x 65 korešpondujúci pozícii s najvyššou koreláciou. Následne sa redukuje rozmer tohto bloku na 32 x 32 konvolúciou s Gaussovým filtrom veľkosti 5 x 5. Výsledný obrazový blok zodpovedá približne 10 papilárnym líniám. Hodnoty odtieňov sivej farby sú normalizované do rozsahu 0 až 1. Takýmto spôsobom sa pripravia obrazové vstupy do neurónovej siete.

Krok rozhodovania

Neurónová sieť autorov má pyramídovú architektúru. Vstupom do siete sú dva obrazové bloky veľkosti 32 x 32 obrazových bodov. Výstupom siete je číslo p udávajúce pravdepodobnosť zhody medzi nimi. Na spodnej úrovni pyramídovej architektúry sa nachádza vrstva s rôznymi filtermi a detektormi príznakov. Nasledujúce vrstvy implementujú Bayesovský pravdepodobnostný model. Z uvedeného vidíme, že sieť má vrstvu konvolúcie filtrov a vrstvu rozhodovania.



Obrázok 21 Architektúra neurónovej siete pozostávajúca z vrstvy konvolúcie filtrov a rozhodovacej vrstvy

- *konvolúcia obrazových blokov s filrami*

V implementácii autorov má každý filter veľkosť 7 x 7 a aplikuje sa na obraz s prekryvom 2 obrazových bodov. Výstupom filtra je matica veľkosti 6 x 6. Môže sa použiť viacero filtrov. Výstup j -teho filtra na súradniciach (x,y) v matici 6 x 6 obrazového bloku A je daný nasledujúcim vzťahom

$$z_{x,y}^j(A) = f\left(\sum_{r,s} w_{x,y,r,s}^j I_{r,s}(A) + t^j\right)$$

kde $I_{r,s}(A)$ je hodnota intenzity stredového bodu v bloku A so súradnicami (r,s). Funkcia f je sigmoidálna funkcia $f(x) = (1 + e^{-x})^{-1}$. Hodnota $w_{x,y,r,s}^j$ je váhou spojenia bodu so súradnicami (r,s) v obrazovom bloku A s bodom so súradnicami (x,y) vo výstupe filtra. t^j je prahová hodnota tohto spojenia platná pre filter j . Vzhľadom na veľkosť použitého filtra, každý filter obsahuje maticu váh s veľkosťou 7 x 7. Pre každý typ filtra sa dá vypočítať matica $\Delta z^j(A, B)$. Táto matica predstavuje štvorec rozdielu výstupov filtrov aplikovaných na blok A a B. Jeden element tejto matice je daný nasledovným vzťahom:

$$\Delta_i^j(A, B) = [z_i^j(A) - z_i^j(B)]^2$$

- *rozhodovanie*

Označme zhodu dvoch odtlačkov daných obrazovými blokmi A a B ako $M(A, B)$. Potom cieľom rozhodovacej časti neurónovej siete je odhadnúť pravdepodobnosť p .

$$p = p[M(A, B)/\Delta z(A, B)]$$

Jedná sa o podmienenú pravdepodobnosť zhody dvoch odtlačkov pri špecifickej úrovni rozdielu výstupov filtrov pri bloku A a B. Pomocou Bayesovho vzorca môžeme danú pravdepodobnosť zapísať v tvare:

$$p(M/\Delta z) = \frac{p(\Delta z/M)p(M)}{p(\Delta z/M)p(M) + p(\Delta z/\bar{M})p(\bar{M})}$$

Hodnota $p(M)$ je stanovená empiricky na základe pozorovaní na úrovni $p(M) = 0,1$ a obdobne $p(\bar{M}) = 0,9$. Pozorovaná hodnota $p(M)$ bola v prípade trénovacej množiny 16 % a v prípade celej databázy 4 %. Preto sa výsledná $p(M)$ stanovila ako priemer z týchto dvoch hodnôt. Problémom je odhad $p(\Delta z/M)$ a $p(\Delta z/\bar{M})$. Tieto pravdepodobnosti boli autormi článku odhadnutá nasledovne:

$$p(\Delta z_i^j/M) = p_j^{1-\Delta z_i^j} (1 - p_j)^{\Delta z_i^j}$$

$$p(\Delta z_i^j/\bar{M}) = q_j^{\Delta z_i^j} (1 - q_j)^{1-\Delta z_i^j}$$

V procese tréovania sa nastavujú a adaptujú tieto parametre:

- váhy $w_{x,y,r,s}^j$
- prahové hodnoty t^j
- parametre p_j a q_j

V implementácii autorov je to spolu $7 \times 7 \times 2 + 2 \times 2 = 104$ parametrov. Všetky parametre sú náhodne inicializované výberom z normálneho rozdelenia so strednou hodnotou 0 a odchýlkou 0,5.

Výsledky

Pri testovaní sa použilo 4650 párov odtlačkov. 99 % všetkých zhodných párov spôsobilo výstup siete na úrovni $p = 0,8$. Podobne ten istý podiel nezhodujúcich sa párov dosiahol $p < 0,2$. Chybnosť rozhodnutia siete bola na úrovni 0,5 %, kde malo rovnaký podiel falošné zamietnutie aj prijatie. Zovšeobecňovacia schopnosť siete, ktorá bola natrénovaná s odtlačkami 5 osôb bola pri 20 osobách dostatočne vysoká, avšak na to, aby mohla byť sieť používaná v rôznych prostrediach musí byť testovaná na oveľa väčšej databáze. Test demonštrovaný autormi tak poukazuje na praktickú využiteľnosť siete, kde sa verifikuje identita menšieho počtu osôb.

3. 6. 3 Porovnávanie odtlačkov pomocou dvojrozmernej mapy markantov

Zdroj: [7] *Fingerprint Matching Using Multi-dimensional ANN*. KUMAR, R. – DEVA VIKRAM, B. R.

Súhrn

Metodika identifikácie odtlačkami prstov je v práci autorov založená na koncepte jedinečnosti odtlačku danej priestorovou distribúciou daktyloskopických markantov. V článku od uvedených autorov je prezentovaná nová metóda rozpoznávania vzorov, ktoré tvoria markanty na ploche odtlačku. Rozpoznanie je realizované neurónovou sieťou, ktorej autori dali prívlastok viacrozmerná (z angl. multi-dimensional). Táto technika využíva dvojrozmernú mapu lokalizovaných markantov odtlačku, ktorej rozmery sú redukované tak, aby mohla byť vstupom do neurónovej siete. Markanty sú komplexným vyjadrením osobitosti každého odtlačku. Táto metóda dosahuje výborné výsledky, nakoľko pracuje priamo s polohami markantov a nie charakteristikami, ktoré nie sú pre odtlačok jedinečné. Technika sľubuje vyššiu efektívnosť rozpoznávania a takisto aj vyššiu rýchlosť v porovnaní s konvenčnými technikami.

Architektúra siete, tréning a testovanie

Manuálne spracovávanie odtlačkov prstov na účely spoľahlivého rozpoznania osoby je časovo náročné a kvôli povahe práce aj náchylné na chyby. FBI vložilo veľké množstvo úsilia do rozvoja automatizovaných systémov na rozpoznávanie osôb odtlačkami, čo otvorilo cestu odtlačkom aj do komerčných oblastí. Všeobecný biometrický systém postavený na odtlačkoch prstov vykonáva dve fázy činnosti: extrakcia charakteristických znakov a klasifikácia odtlačku podľa extrahovaných znakov. Porovnávanie odtlačkov pomocou extrahovaných znakov môže byť vykonané prostredníctvom analýzy singulárnych bodov, celkovej štruktúry

odtlačku, daktyloskopických markantov alebo použitím umelej inteligencie neurónovej siete. Najdominantnejšou technikou porovnávania odtlačkov, ktorá je osvedčená aj pri manuálnom spôsobe vyšetrovania odtlačku je porovnávanie daktyloskopických markantov. Daktyloskopické markanty sú lokálne znaky, v ktorých odtlačky líšia. Sú to malé tvarové zvláštnosti, no súčasnými snímacími technológiami ich nie problematické zachytiť. Tradičné techniky porovnávania markantov sú Delaunayova triangulácia, využitie lokálnej štrukturálnej podobnosti alebo využitie architektúr neurónových sietí.

Redukcia mapy markantov

Z článku autorov, ktorý obsahuje aj teoretické pokrytie základných postupov predspracovania obrázkov odtlačkov a extrakcie markantov sa zameriavame výlučne na kapitolu s predstavením architektúry neurónovej siete. Predspracovanie je dôležitý krok na zvýšenie celkovej zreteľnosti papilárnych línií, ktoré obsahujú potrebné detaily na rozlišovanie vzorov, ktorých spoľahlivá detekcia je základným predpokladom úspešného rozpoznávania. Markanty sú odhalené v obraze s pôvodnými rozmermi. Tento obraz obsahuje papilárne línie s hrúbkou 1 obrazového bodu a nazýva sa kostra. Počet markantov je vzhľadom na celkový počet obrazových bodov odtlačku zanedbateľný a preto nie je úsporné ich vyjadrovať v obraze s pôvodnými rozmermi 512 x 512. Je nutnosťou redukovať mapu markantov do kompaktnej formy so zachovaním všetkých potrebných informácií. Mapa markantov v kostre sa rozdelí na bloky 15 x 15 obrazových bodov a v každom bloku sa sčítajú intenzity obrazových bodov. Takto sa vytvorí matica veľkosti 15 x 15, v ktorej sú polohy markantov reprezentované bielymi bodmi a nepodstatné okolie je čierne.




Obrázok 22 Kostra odtlačku, vyznačené markanty a redukovaná mapa markantov

Trénovanie a testovanie

Sieť prezentovaná článkom používa algoritmus spätného šírenia chyby, kde sa na adaptáciu váh využíva technika gradientového zostupu. Sieť obsahuje 20 neurónov a bola navrhnutá na akceptovanie maticového vstupu. Štruktúra tejto siete je na obr. 23. Výhodou maticovej

reprezentácie vstupov je možnosť automatického zahrnutia smerov markantov do procesu tréningu siete.



Obrázok 23 Štruktúra viacrozmernej neurónovej siete

V procese tréningu bolo každému unikátnemu odtlačku pridelené jedinečné číslo. Potom sa sieť trénovala na rôznych vzorkách rovnakého odtlačku, ktorým bolo pridelené rovnaké číslo. Algoritmus tréningu pokračuje pokiaľ nie je výstup siete zhodný s prideleným číslom odtlačku. Odtlačky prstov boli zosnímané 3500 osobám. Každý odtlačok bol zosnímaný 3-krát. Odtlačky 500 osôb boli použité na testovanie (z každej osoby 1 odtlačok) a odtlačky 3000 osôb boli použité na tréning (z každej osoby 2 odtlačky). Odtlačky prešli najprv fázou predspracovania, kde sa odstránili narušenia štruktúry odtlačku a potom sa vytvorila redukovaná mapa markantov. Táto mapa je vstupom do neurónovej siete.

Výsledky

Pre proces tréningu bola charakteristická chybová krivka na obr. 24. Priemerná kvadratická chyba je definovaná ako štvorec rozdielu medzi výstupom siete a požadovanou hodnotou. Priemerná chyba je vykreslená pre jednotlivé iterácie. Vývoj tejto chyby v jednotlivých iteráciách značí tempo učenia sa siete.




Fig. 6. Performance vs. number of iterations.

Obrázok 24 Vývoj chyby siete počas tréningu

Úspešnosť rozpoznávania siete bola porovnaná s inými algoritmami v tabuľke na obr. 25. Z pozorovaní sa zistilo, že v databáze, ktorá obsahuje viac ako 3500 unikátnych odtlačkov, natrénovaná neurónová sieť začína dosahovať výrazne horšie výsledky úspešnosti rozpoznávania. Takisto sa zistilo, že slabšia redukcia rozmerov pôvodnej mapy markantov zvyšuje úspešnosť rozpoznávania, no na druhej strane spôsobuje dlhší čas výpočtu.

Algorithm	Recognition rate (%)	False acceptance rate (FAR) (%)	False rejection rate (FRR) (%)
Zhang's (Wang and Zhang, 2000) algorithm	91.3	3.1	4.4
G. Aguilar's (Aguilar et al., 2007) algorithm	94.1	2.3	3.6
Proposed algorithm	97.37	1.13	1.5

Obrázok 25 Porovnanie úspešnosti verifikácie osôb odtlačkami pomocou viacerých metód

Použitá literatúra

- [1] ORAVEC, M. 2012. *Metódy strojového učenia na extrakciu príznačkov a rozpoznávanie vzorov*. Slovenská technická univerzita v Bratislave: Nakladateľstvo STU. 150 s. ISBN 978-80-227-3691-6.
- [2] ZHU, E. et al. 2006. *Fingerprint Ridge Orientation Estimation Based on Neural Network* [online]. In: Proceedings of the 5th WSEAS Int. Conf. on Signal Processing, Robotics and Automation, Madrid, Spain. p. 158 – 164. Dostupné na:
http://www.researchgate.net/publication/234826396_Fingerprint_ridge_orientation_estimation_based_on_neural_network
- [3] BARTŮŇEK, J. S. et al. 2006. *Neural Network based Minutiae Extraction from Skeletonized Fingerprints* [online]. In: TENCON 2006, IEEE Region 10 Conference, Hong Kong. p. 1 – 4. ISBN 1-4244-0548-3. Dostupné na:
http://ieeexplore.ieee.org/xpls/abs_all.jsp?arnumber=4142219&tag=1
- [4] ALSHEMMARY, E. N. A. 2012. *Classification of Fingerprint Images Using Neural Networks Technique* [online]. In: Journal of Engineering, Vol. 1, No. 3, 2012, p. 40 – 48. Dostupné na:
<http://worldsciencepublisher.org/journals/index.php/JOE/article/view/991>
- [5] GONZÁLEZ, A. et al. 2009. *Neural Networks Applied to Fingerprint Recognition* [online]. In: IWANN 2009, Part II, LNCS 5518, p. 621 – 625, 2009. Dostupné na:
http://link.springer.com/chapter/10.1007%2F978-3-642-02481-8_91
- [6] BALDI, P. – CHAUVIN, Y. 1993. *Neural Networks for Fingerprint Recognition* [online]. In: Neural Computation 5, p. 402 – 418. Dostupné na:
<http://authors.library.caltech.edu/12477/1/BALnc93.pdf>
- [7] KUMAR, R. – DEVA VIKRAM, B. R. 2009. *Fingerprint matching using multi-dimensional ANN* [online]. In: Engineering Applications of Artificial Intelligence 23, 2010, p. 222 – 228. Dostupné na:
<http://www.sciencedirect.com/science/article/pii/S0952197609001626>