

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY**

Evidenčné číslo: FEI-5382-74404

**MOŽNOSTI VYUŽITIA NEURÓNOVÝCH SIETÍ
V BIOMETRICKÝCH SYSTÉMOCH PRACUJÚCICH
S ODTLAČKAMI PRSTOV**
BAKALÁRSKA PRÁCA

2015

Ondrej Hoferica

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY**

Evidenčné číslo: FEI-5382-74404

**MOŽNOSTI VYUŽITIA NEURÓNOVÝCH SIETÍ
V BIOMETRICKÝCH SYSTÉMOCH PRACUJÚCICH
S ODTLAČKAMI PRSTOV**
BAKALÁRSKA PRÁCA

Študijný program: Aplikovaná informatika

Číslo študijného odboru: 2511

Názov študijného odboru: 9.2.9 Aplikovaná informatika

Školiace pracovisko: Ústav informatiky a matematiky

Vedúci záverečnej práce: Ing. Pavol Marák

Bratislava 2015

Ondrej Hoferica



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Ondrej Hoferica**
ID študenta: 74404
Študijný program: Aplikovaná informatika
Študijný odbor: 9.2.9. aplikovaná informatika
Vedúci práce: Ing. Pavol Marák
Miesto vypracovania: Ústav informatiky a matematiky

Názov práce: **Možnosti využitia neurónových sietí v biometrických systémoch pracujúcich s odtlačkami prstov**

Špecifikácia zadania:

Rozpoznávanie identity osôb podľa špecifických vzorov odtlačkov prstov je doposiaľ najrozšírenejšou a najpreskúmanejšou biometrickou technológiou. V niektorých oblastiach využitia je už takmer neoddeliteľnou súčasťou systému informačnej bezpečnosti. Pokroky výpočtovej techniky umožňujú biometrické rozpoznávanie identity osôb realizovať rôznymi výpočtovými modelmi. Umelé neurónové siete sú vhodným prostriedkom na rozpoznávanie zložitých biometrických vzorov. Neurónové siete môžu v niektorých fázach biometrického systému dosahovať lepšie výsledky kvôli: princípu adaptívneho učenia sa z príkladov, modelovaniu komplexných vzťahov a možnosti paralelizácie výpočtov. Výhodou neurónových sietí oproti iným tradičným technikám rozpoznávania biometrických vzorov je určitá tolerancia voči odchýlkam, ktorá je pri odtlačkoch prstov alebo dlaní bežným javom napokoľko v praxi dochádza k značnej vnútrotriednej variabilite. Oblastou, ktorá si vyžaduje vyšší záujem je vyhodnotenie úspešnosti a vhodnosti neurónových sietí pri rozpoznávaní vzorov prítomných v papilárnom teréne odtlačku na rôznej úrovni identifikačnej hodnoty: od schopnosti rozpoznať globálne vzory až po najmenšie charakteristické detaily, ktorých využitie je v praxi zaužívané najmä vo sfére kriminalistiky. Cieľom práce je aplikovať neurónové siete do rôznych fáz spracovania odtlačku (klasifikácia globálneho vzoru, rozpoznávanie detailov, porovnanie odtlačkov) a vyhodnotiť ich úspešnosť v porovnaní s konvenčnými technikami.

Úlohy teoreticko-analytickej časti práce:

1. Opíšte vo všeobecnosti biometrické rozpoznávanie pomocou odtlačkov prstov, podrobnejšie analyzujte problematiku využitia neurónových sietí v biometrických systémoch pracujúcich s odtlačkami.
2. Charakterizujte konkrétné metódy využitia neurónových sietí pri rozpoznávaní identity odtlačkami prstov dostupné v literatúre (extrakcia, klasifikácia podľa globálneho vzoru, identifikácia).
3. Spracujte problematiku rozlišovania resp. extrakcie troch hlavných úrovni charakteristických detailov daktylскопických vzorov, ktoré sú využité v jednotlivých fázach spracovania biometrickým systémom.

Úlohy praktickej časti práce:

1. Špecifikujte, ktoré vstupné údaje bude softvér extrahovať, navrhnite model/postup riešenia, zvoľte vhodnú architektúru neurónovej siete.
2. Softvérovo implementujte rozpoznávanie špecifikovaných vzorov na jednotlivých úrovniach charakteristických detailov + vizualizujte výstupy.
3. Testujte implementované riešenie na rôznych vstupných dátach (rôzne vzory, kvalita, veľkosť, zahrnutí aj vzory dlaní).
4. Interpretujte dosiahnuté výsledky vo vzťahu k vytýčeným cieľom a porovnajte ich s výsledkami dostupnými v literatúre.

Zoznam odbornej literatúry:

1. Jain, A. – Maio, D. – Maltoni, D. *Handbook of Fingerprint Recognition, Second Edition*. London, UK: Springer, 2009. 496 s. ISBN 978-1-84882-253-5.
2. El-Feghi, I.; Tahar, A.; Aboasha, H.; Zhijie Xu. Efficient features extraction for fingerprint classification with multi layer perceptron neural network. 8th International Multi-Conference on Systems, Signals and Devices (SSD), 2011, pp.1-4, 22-25 March 2011
3. YONG-XIA, L. et al. A New Detection Method of Singular Points of Fingerprints Based on Neural Network. University of Electronic Science and Technology of China. 2010. 5 s

Riešenie zadania práce od: 22. 09. 2014
Dátum odovzdania práce: 22. 05. 2015



Ondrej Hoferica
študent

prof. RNDr. Otokar Grošek, PhD.
vedúci pracoviska

prof. RNDr. Gabriel Juhás, PhD.
garant študijného programu

SÚHRN

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Študijný program:

Aplikovaná informatika

Autor:

Ondrej Hoferica

Bakalárská práca:

Možnosti využitia neurónových sietí v biometrických systémoch pracujúcich s odtlačkami prstov

Vedúci záverečnej práce:

Ing. Pavol Marák

Miesto a rok predloženia práce:

Bratislava 2015

Hlavným cieľom tejto práce je návrh a vytvorenie aplikácie schopnej automatizovane, s využitím neurónovej siete, extrahovať daktyloskopické markanty, teda znaky určujúce jedinečnosť odtlačkov prstov. Úspešnosť extrakcie závisí na kvalite spracovávaného odtlačku, s ktorou sa vie neurónová sieť pri klasifikácii lepšie vysporiadáť ako existujúce techniky. S rozširujúcimi sa možnosťami aplikácií biometrických systémov, silnie potreba vývoja automatizovaných metód spracovania odtlačkov. Problémom súčasných metód je strata mnohých charakteristických znakov počas predspracovania a výpočtová náročnosť extrakcie komplexných markantov. V práci tento problém riešime implementovaným softvérom, ktorý za pomoci neurónovej siete dokáže extrahovať tieto markanty. Dôležitou časťou je opis neurónových sietí, ich konštrukcie a výhod oproti iným prístupom. Navrhli sme postup extrakcie, skladajúci sa z dvoch fáz: učenia neurónovej siete a extrakcie markantov neurónovou sietou. Učenie siete prebiehalo pomocou vzorových dát, predstavujúcich typy rozpoznávaných markantov. Extrakcia bola vykonávaná na základe zasielania blokov obrazu neurónovej sieti a následnej analýze jej odpovede. Prínosom tejto práce je dokumentácia postupu pri tvorbe vhodných trénovacích údajov a konfigurácie neurónovej siete na rozpoznávanie požadovaných tvarov odtlačku. Implementované riešenie prešlo viacerými experimentami, ktoré demonštrujú úspešnosť rozpoznávania zložitejších daktyloskopických tvarov pri rôznej vstupnej obrazovej kvalite.

Kľúčové slová: odtlačky prstov, daktyloskopické markanty, umelé neurónové siete, extrakcia markantov

ABSTRACT

SLOVAK UNIVERSITY OF TECHNOLOGY IN BRATISLAVA
FACULTY OF ELECTRICAL ENGINEERING AND INFORMATION TECHNOLOGY

Study Programme:	Applied Informatics
Author:	Ondrej Hoferica
Bachelor Thesis:	Possibilities of application of neural networks in the field of fingerprint biometric systems
Supervisor:	Ing. Pavol Marák
Place and year of submission:	Bratislava 2015

The main purpose of this thesis was to propose and create an application for extraction of fingerprint minutiae, i.e. features determining uniqueness of fingerprints, with the use of artificial neural network, in an automatized manner. Success of extraction of the mentioned features is strongly dependent on the quality of processed fingerprints. Neural networks can handle low quality images during classification better than existing methods. Due to the increasing number of possibilities of biometric systems application, the need for development of automatized methods of fingerprint processing, is constantly growing. One problem of the methods currently available is a loss of numerous features in the course of preprocessing and the difficulty in complex minutiae extraction, in terms of time. The present thesis endeavors to overcome this problem by implementation of software that is able to extract such minutiae with the use of artificial neural networks. An important part is the description of artificial neural networks, their creation and advantages compared to other methods. We designed a method of extraction, comprising two stages: training of artificial neural network and minutiae extraction performed by neural networks. Training of the network was carried out with the help of sample data constituting types of recognized minutiae. Extraction was performed based on sending blocks of the neural network and subsequent analysis of its response. The contribution of this thesis is a documentation of creating suitable training data and configuration of neural network for recognition of required fingerprint features. The implemented solution was tested during multiple experiments, which demonstrate successful recognition of complex dactyloscopic features with various quality of input images.

Keywords: fingerprints, fingerprint minutiae, neural networks, minutiae extraction

Vyhľásenie autora

Podpísaný Ondrej Hoferica čestne vyhlasujem, že som bakalársku prácu Možnosti využitia neurónových sietí v biometrických systémoch pracujúcich s odtlačkami prstov vypracoval na základe poznatkov získaných počas štúdia a informácií z dostupnej literatúry uvedenej v práci.

Uvedenú prácu som vypracoval pod vedením Ing. Pavla Maráka.

Bratislava, dňa 22.5.2015

.....

podpis autora

Podčakovanie

Na tomto mieste chcem úprimne podčakovať vedúcemu mojej bakalárskej práce Ing. Pavlovi Marákovi za významnú pomoc, návrhy a prípomienky. Vďaka jeho odbornému vedeniu a poskytnutým študijným materiálom bolo možné túto prácu vypracovať do súčasnej formy.

Taktiež chcem podčakovať rodine a priateľom za morálnu podporu, pomoc a trpeznosť v období tvorby tejto práce.

Ondrej Hoferica

Obsah

Úvod	13
1 Teoretické východiská a analýza problematiky	14
1.1 Formulácia skúmaného problému a ciele práce	14
1.1.1 Odtlačky a súčasné výzvy pri procese rozpoznávania	14
1.1.2 Predmet skúmania a jeho popis	14
1.1.3 Plán a metodika riešenia problému	15
1.1.4 Motivácia práce	16
1.1.5 Hlavné ciele bakalárskej práce	16
1.2 Koncepty a využitie biometrie	18
1.2.1 Charakteristika biometrie	18
1.2.2 Biometrické systémy a ich využitie	19
1.3 Biometrické systémy na báze odtlačkov prstov	22
1.3.1 Odtlačky prstov: postupný vývoj a súčasnosť	22
1.3.2 Spôsoby získavania odtlačkov	23
1.3.3 Predspracovanie, filtrovanie a úprava odtlačkov	25
1.4 Charakteristika úrovňí detailov odtlačkov	28
1.4.1 Význam klasifikácie detailov odtlačkov prstov	28
1.4.2 Úrovne daktyloskopických vzorov	29
1.4.3 Detaily 2. úrovne	31
1.4.4 Používané metódy extrakcie markantov	34
1.5 Daktyloskopické systémy a neurónové siete	37
1.5.1 Princípy neurónových sietí	37
1.5.2 Architektúra neurónových sietí	38
1.5.3 Učenie neurónovej siete	42
1.5.4 Viacvrstvová perceptrónová sieť	42
1.6 Aplikácie neurónových sietí v biometrii	44
1.6.1 Výhody použitia neurónových sietí pri spracovaní odtlačkov prstov .	44
1.6.2 Nasadenie neurónových sietí pri spracovaní odtlačkov prstov .	45
2 Návrh riešenia	47
2.1 Fázy riešenia zadania práce	47
2.2 Proces extrakcie markantov	49
2.2.1 Detekcia základných tvarov markantov	49

2.2.2	Navrhnutá neurónová sieť a jej trénovanie	50
2.2.3	Extrakcie markantov neurónovou sieťou	52
2.3	Prostriedky využité pri implementácii riešenia	53
3	Zhodnotenie dosiahnutých výsledkov	55
3.1	Splnenie cieľov teoretickej časti práce	55
3.2	Splnenie cieľov praktickej časti práce	55
3.2.1	Funkcionalita	56
3.2.2	Možnosti užívateľskej interakcie	56
3.2.3	Dosiahnuté výsledky extrakcie markantov	64
Záver		71
Zoznam použitej literatúry		73
Prílohy		I
A	Demonštrácia extrakcie komplexných daktyloskopických markantov	II
B	Obsah priloženého DVD	III

Zoznam obrázkov a tabuľiek

Obrázok 1	Schéma základných procesov biometrického systému	19
Obrázok 2	Blokové schémy verifikačných a identifikačných biometrických systémov	20
Obrázok 3	Príklady použitia snímačov odtlačkov v súčasnosti	21
Obrázok 4	Použitie odtlačkov pri platobných kartách	22
Obrázok 5	Príklady snímkov odtlačkov prstov	24
Obrázok 6	Jednotlivé časti obrazového predspracovania snímky odtlačku	25
Obrázok 7	Gaborov filter	26
Obrázok 8	Binarizácia	27
Obrázok 9	Skeletonizácia	27
Obrázok 10	Papilárne línie a priehlbiny medzi nimi	29
Obrázok 11	Typy singulárnych bodov s vyznačenými jadrami	30
Obrázok 12	Základné klasifikačné triedy podľa Henry(1900)	30
Obrázok 13	Jednotlivé Level-3 detaily	31
Obrázok 14	Spracovanie okolia bodu metódou Crossing Number	35
Obrázok 15	Príklad smerovej mapy odtlačku	36
Obrázok 16	Model umelého neurónu	39
Obrázok 17	Priebeh sigmoidy	39
Obrázok 18	Priebeh hyperbolického tangensu	40
Obrázok 19	Priebeh skokovej funkcie	40
Obrázok 20	Schéma doprednej siete	40
Obrázok 21	Schéma rekurentnej siete	41
Obrázok 22	Schéma Kohonenovej siete	41
Obrázok 23	Schéma MLP siete	43
Obrázok 24	Schéma modulov programu	47
Obrázok 25	Schéma procesov navrhnutého softvérového riešenia	49
Obrázok 26	Základné markanty	50
Obrázok 27	Množina dát pre proces učenia	52
Obrázok 28	Detekcia markantov - zobrazenie zvoleného odtlačku	57
Obrázok 29	Detekcia markantov - aplikovanie Crossing Number	58
Obrázok 30	Učenie neurónovej siete	59

Obrázok 31	Učenie neurónovej siete - príklad konfigurácie	60
Obrázok 32	Príklad dát pre učenie neurónovej siete	61
Obrázok 33	Extrakcia NS	61
Obrázok 34	Extrakcia NS - zobrazenie výstupu	62
Obrázok 35	Schéma odporúčaného postupu pri práci s aplikáciou	63
Obrázok 36	Použité neurónové siete	64
Obrázok 37	Všeobecná konfigurácia použitej NS	65
Obrázok 38	Extrakcia základných markantov	67
Obrázok 39	Extrakcia - prerušenie	70
Obrázok 40	Extrakcia - premostenie	70
Obrázok 41	Extrakcia - protiahľné rozdvojenie	70
Obrázok A.1	Vyznačené komplexné markanty	II
Tabuľka 1	Rozdelenie markantov a ich popis	33

Zoznam skratiek a značiek

AFIS - Automatic Fingerprint Identification Systems

CN - Crossing Number

FANN - Fast Artificial Neural Network

MLP - multilayer perceptron net

NIST - National Institute of Standards and Technology

NS - neurónová siet

Úvod

Technológia rozpoznávania identity osôb na základe odtlačkov prstov je v súčasnosti najznámejšou a najpoužívanejšou metódou v rámci biometrie. Ako pri svojich počiatkoch, tak i teraz nachádzajú odtlačky prstov svoje najväčšie využitie vo forenznej oblasti, avšak vďaka neustálemu vývoju sa postupne rozpoznávanie čoraz viac stáva neodmysliteľnou súčasťou biometrických systémov i samotnej informačnej bezpečnosti. Úlohou biometrických systémov je získať obraz odtlačku prstu, extrahovať z neho charakteristické vlastnosti, ktoré je možné porovnať s reprezentáciami iných odtlačkov, na základe čoho je možné vyvodíť záver o rozpoznaní identity. Sledovanými charakteristickými vlastnosťami tejto práce sú daktyloskopické markanty, ktorých tvar, pozícia a orientácia sú združením jedinečnosti každého odtlačku, aj keď o stave tohto tvrdenia neexistujú objektívne vedecké dôkazy. Markantami nazývame lokálne nepravidelnosti na papilárnych liniách.

Cieľom teoretickej časti tejto bakalárskej práce je objasniť pozadie problému rozpoznávania odtlačkov prstov, priblížiť špecifické a charakterizujúce vlastnosti odtlačkov, spôsoby ich odhalovania a získavania vo všeobecnosti. Dôležitou časťou tejto práce je predstavenie problematiky neurónových sietí, ich princípu fungovania, spôsobov konštrukcie a hlavne ich možných spôsobov využitia v oblasti automatizovaného rozpoznávania odtlačkov prstov. Pozornosť je zameraná na extrakciu markantov pomocou neurónovej siete. Táto práca je pokusom o predstavenie nového prístupu k automatizovanej extrakcii komplexných markantov z odtlačkov prstov.

Praktickou časťou tejto bakalárskej práce je aplikácia, pri vytváraní ktorej boli implementované postupy a princípy opísané v teoretickej časti. Táto aplikácia je schopná z odtlačku extrahovať zvolené markanty, pričom rozhodovacie jadro tvorí neurónová sieť. V implementačnej fáze riešenia sa kládol špecifický dôraz na automatizované rozpoznávanie vzorov, ktoré sú tvarovo komplexné a výskytom veľmi zriedkavé a neexistujú všeobecne známe algoritmy, ktoré by ich extrakciu realizovali na požadovanej úrovni presnosti. Existuje predpoklad, že neurónová sieť svojimi vlastnosťami ponúka efektívnejší prístup k extrakcii týchto komplexných tvarov, čo sa následne experimentami aj potvrdilo. V práci je uvedený aj popis postupu pri návrhu a implementácii jednotlivých súčastí, pričom jednotlivé postupy sú sprevádzané vizualizáciami.

Záver práce tvorí zhodnotenie dosiahnutých výsledkov v teoretickej i praktickej časti. Na koniec uvádzame možnosti ďalšieho vylepšenia a vývoja aplikácie a samotného riešenia problematiky.

1 Teoretické východiská a analýza problematiky

1.1 Formulácia skúmaného problému a ciele práce

1.1.1 Odtlačky a súčasné výzvy pri procese rozpoznávania

Odtlačky prstov a ich rozpoznávanie tvoria dôležitú súčasť informačnej bezpečnosti, napokolko sú pomerne efektívny a spoľahlivým prístupom k rozpoznávaniu osôb. Treba však povedať, že automatizované rozpoznávanie osôb s využitím odtlačkov prstov zatiaľ nie je v súčasnosti natoliko spoľahlivé, aby mohlo nahradit manuálne rozpoznávanie vykonávané odborníkmi v oblasti daktyloskopie. Preto v tejto oblasti neustále prebieha výskum rôznych nových prístupov spracovania odtlačkov a práce s nimi. Hlavným cieľom tejto práce je teda teoreticky analyzovať a navrhnúť riešenie problematiky automatizácie extrakcie charakteristických znakov odtlačkov. V spomínamej oblasti sa využívajú mnohé odlišné prístupy a metódy. Pomerne novým prístupom však je použitie neurónových sietí, a preto sme sa v tejto práci zamerali práve na využitie neurónových sietí v procese extrakcie charakteristických znakov. Význam využitia tejto metódy rastie s neustále stúpajúcimi nárokmi biometrických systémov na rýchlosť a spoľahlivosť spracovania biometrických údajov, v tomto prípade odtlačkov prstov.

1.1.2 Predmet skúmania a jeho popis

Základným predmetom nášho záujmu je odtlačok prsta, jeho vlastnosti a znaky. Odtlačok môže predstavovať stopu prsta zanechanú na nejakom povrchu, pričom túto stopu nazývame aj latentný odtlačok, alebo môže ísť o obraz zosnímaný priamo z bruška prsta. Odtlačok je tvorený papilárnymi líniami, ktoré vytvárajú pomerne zložitý komplexný vzor. Špecifické znaky, ktoré tento vzor obsahuje sú základnými kameňmi rozpoznávania a udávajú odtlačku jedinečnosť. Tieto znaky sú tvorené rôznymi nepravidelnostami a tvarovými deformáciami papilárnych línii. Nazývame ich detaľy 2. úrovne alebo markanty a sú to práve tie prvky, na základe ktorých sú jedinci identifikovaní.

Prvým krokom pred samotným porovnávaním týchto znakov je ich lokalizácia v odtlačku. Tento proces sa nazýva extrakcia markantov. Je možné ju vykonať viacerými postupmi, ktoré sa odlišujú v prístupe k spracovaniu vstupu. Spoločne však zdieľajú závislosť úspešného spracovania od kvality vstupného obrazu. Najmä v prípade latentných odtlačkov je kvalita pomerne nízka a častokrát nie sú odtlačky úplné. Ani pri snímaných odtlačkoch nie sú podmienky ideálne, a tak vznikajú rôzne odchýlky, ktoré sa

v závislosti od použitej metódy prejavia do určitej miery aj na kvalite výstupu.

Druhým krokom je určenie typu markantu. Každý tento znak sa vyskytuje v odtlačkoch populácie s určitou frekvenciou, na základe tohto je teda možné určiť vzácnosť daného znaku. Ojedinelosť výskytu konkrétneho markantu je možné využiť pri porovnávaní odtlačkov, záleží však či ide o kvantitatívny prístup alebo kvalitatívny. Pri kvantitatívnom prístupe sa zohľadňuje počet odpovedajúcich zhodných markantov, kvalitatívny prístup práve vyššie spomínanú vzácnosť markantu. Súčasné systémy pre identifikáciu sa spoliehajú na kvantitatívnu metódu, čím zanedbávajú jednu zo silných vlastností odtlačkov – variabilitu vzorov. Aby bolo možné začať využívať kvalitatívny prístup v automatizovanom spracovaní, je potrebné vyriešiť problémy okolo extrakcie a určenia typov markantov.

1.1.3 Plán a metodika riešenia problému

Pri návrhu riešenia problematiky, teda extrakcie markantov za pomoci neurónových sietí, sme sa snažili nájsť riešenie problémov, ktoré boli spomenuté v predchádzajúcej sekcií. Hlavnou oblasťou záujmu bolo navrhnúť a implementovať systém, ktorý by pomocou neurónovej siete extrahoval markanty. Snahou bolo extrahovať nielen základné dva znaky – ukončenie a rozdvojenie, ktoré sú jedinými rozpoznávanými znakmi druhej väčšiny algoritmov – konvenčných i tých, ktoré využívajú neurónové siete, ale pokúsiť sa o extrakciu aj niektorých komplexných markantov. Popis týchto markantov sa nachádza v teoretickej časti tejto práce. Nakolko zatial o probléme extrakcie komplexných markantov za pomoci neurónovej siete neexistuje vo svete uspokojivé množstvo vedeckých prác, je táto bakalárska práca pokusom zistiť možnosti a schopnosti neurónových sietí v oblasti.

Kedže sme nemali k dispozícii možnosť automatizovaného porovnania získaných výsledkov s výsledkami iných metód publikovaných v literatúre, pristúpili sme k manuálnemu porovnaniu výsledkov s výstupmi poskytnutými odborníkom, ktorý manuálne v odtlačkoch vyznačil pozície a typy markantov.

Táto práca je rozdelená na 2 časti. Prvá časť sa venuje teoretickým znalostiam problematiky. Poskytuje popis biometrie, biometrických systémov, jej význam a dôležité postavenie v informačnej bezpečnosti, ale i bežnom živote. Predstavuje základné procesy biometrického overovania identity, jednotlivé kroky a moduly procesu verifikácie a identifikácie. Pre zdôraznenie dôležitosti odtlačku prstu na poli biometrie je časť práce ve-

novaná histórii a postupne rastúcemu významu odtlačkov až po súčasnú dobu. Následne sú uvedené informácie o jednotlivých krokoch popisujúcich získavanie odtlačkov rôznymi metódami i predspracovanie a filtráciu získaných odtlačkov. Zvlášť je pozornosť venovaná markantom, ich úrovniom a špecifikám na každej úrovni. Stručným prieskumom metód publikovaných v literatúre sme poskytli príklady konvenčných metód extrakcie markantov. Veľký dôraz je kladený na sekciu využitia neurónových sietí v oblasti odtlačkov prstov, ktorá tvorí jadro tejto práce. Prvá časť práce teda predstavuje oblasť biometrie, odtlačky, neurónové siete a dôležitosť riešenia problémov spájajúcich tieto oblasti.

Druhú časť tvorí popis postupu pri návrhu softvérového riešenia, predstavenie použitých prostriedkov a metód, pomocou ktorých bola problematika implementovaná. Záver tejto časti je tvorený predstavením dosiahnutých výsledkov, zhodnením a naznačením možností pokračujúceho vývoja v budúcnosti.

1.1.4 Motivácia práce

Význam a dôležitosť neustáleho vývoja a výskumu v oblasti automatizovaného spracovania odtlačkov bol vysvetlený v predchádzajúcich častiach textu. Motiváciou pri tvorbe tejto práce bola skutočnosť, že neurónové siete sú v oblasti spracovania odtlačkov stále pomerne novým prístupom a v súčasnej dobe nie je tento prístup ešte dostatočne preskúmaný a overený. Prvotné predpoklady naznačujú, že práve neurónové siete by mohli byť riešením mnohých problémov konvenčných metód, ktoré už boli spomenuté v úvodnej časti dokumentu a budú ďalej podrobnejšie popísané.

1.1.5 Hlavné ciele bakalárskej práce

Nasledovný zoznam uvádza ciele práce v teoretickej a praktickej časti, ktoré sme si určili:

Teoretická časť práce:

- Popísat teoretické základy problematiky, analyzovať aktuálny stav v oblasti biometrie a odtlačkov prstov
- Analyzovať problematiku využitia neurónových sietí v biometrických systémoch
- Charakterizovať konkrétnie metódy použitia neurónových sietí v procese spracovania odtlačkov (extrakcia, klasifikácia podľa globálneho vzoru, identifikácia)
- Definovať a analyzovať problematiku extrakcie troch úrovní charakteristických de-

tailov daktyloskopických vzorov

- Opísat postup návrhu a princíp algoritmov použitých v implementačnej časti
- Zhodnotiť získané výsledky, načrtnúť smer a cieľ ďalšieho vývoja

Praktická časť práce:

- Špecifikovať vstupné dátá pre vytváraný softvér, navrhnúť model riešenia
- Zvoliť vhodnú architektúru neurónovej siete
- Softvérovo implementovať rozpoznávanie špecifikovaných vzorov, vytvoríť vizualizáciu výstupu
- Testovať implementované riešenie na rôznych vstupných dátach
- Interpretovať vstupné dátá, porovnať výsledky s literatúrou

1.2 Koncepty a využitie biometrie

1.2.1 Charakteristika biometrie

Biometria alebo biometrické rozpoznávanie zjednodušene predstavuje využitie anatomických znakov(prípadne povahových črt) pre automatizované rozpoznanie identity osôb a ich verifikáciu. Je založená na princípe jedinečnosti jednotlivých sledovaných biometrických prvkov, či už ide o odtlačok prstov, proporcie tváre, sietnicu oka, dúhovku, prípadne hlas a mnohé ďalšie. Tieto prvky sú do istej miery jedinečné a existuje len veľmi malá možnosť, že sa nájde viac osôb s rovnakými biometrickými znakmi. Vďaka tejto vlastnosti a faktu, že je pomerne náročné sfalšovať alebo odcudziť tieto identifikátory, je biometria vhodnejšia a spoľahlivejšia forma overenia identity osôb oproti klasickým formám identifikácie a verifikácie. Tým sú mysené rôzne formy kľúčov, prístupových kariet, metódy založené na znalosti hesla, PIN-u.

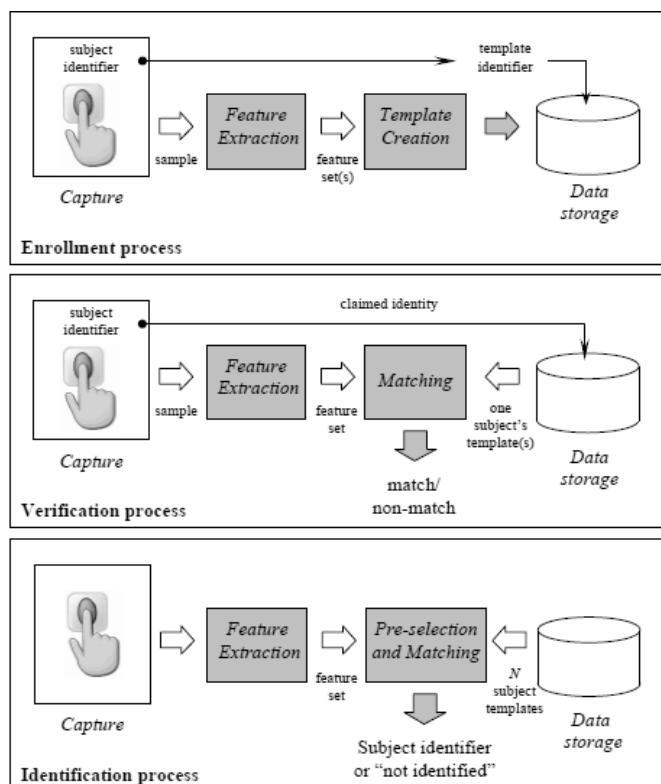
Biometria alebo inak povedané – identifikácia osôb na základe biometrických prvkov teda poskytuje vyššiu mieru spoľahlivosti, či už je to spoľahlivosť voči sfalšovaniu, alebo odcudzeniu prístupového prvku. Ďalšou výhodou oproti tradičným spôsobom identifikácie osôb je vyššia efektivita a v neposlednom rade aj zjednodušenie overovacieho procesu. Biometrické rozpoznávanie taktiež eliminuje problém straty prístupového prvku(karty, kľúča), prípadne zabudnutie prístupového hesla. Vďaka spomenutým vlastnostiam je biometria vhodným kandidátom pred oblasť informačnej bezpečnosti a kriminalistiky, kde je identifikácia osôb kľúčová.

Biometria je pomerne mladá avšak rýchlo sa rozvíjajúca veda, najmä z dôvodu neustále rastúcich nárokov v oblasti informačnej bezpečnosti. Počiatky biometrie sa objavujú hlavne v kriminalistike a forenznej vede. V roku 1893 vo Veľkej Británii úrady oficiálne akceptovali, že žiadni dvaja jedinci nemajú rovnaké odtlačky prstov (Maltoni, D. et al., 2009, str. 1), čím sa vlastne odštartovalo využívanie odtlačkov prstov pre identifikáciu osôb policajnými zložkami. Následne sa začalo so získavaním a archiváciou odtlačkov prstov páchateľov priamo z miesta činu a tým sa začala biometria využívať i vo forenznej oblasti. Výskum v tejto oblasti bol podporovaný najmä políciou, avšak mohutný rozvoj technológií v posledných rokoch a s tým spojená rastúca potreba zabezpečenia, spôsobili, že výskum a rozvoj v oblasti biometrie sa presunuli aj do komerčných oblastí.

1.2.2 Biometrické systémy a ich využitie

Ako už bolo spomenuté, rastúca potreba zabezpečenia rôznych systémov spôsobila, že do popredia sa dostal problém rýchlosť a spolahlivosti identifikácie a rozpoznávania. Dlhú dobu boli odtlačky prstov skúmané a porovnávané manuálne, pričom táto metóda je veľmi časovo náročná a málo efektívna. Snahou preto bolo a stále aj je, vyvinúť systémy, ktoré by umožnili automatizáciu tohto procesu, čo by prinieslo obrovskú úsporu času i ľudskej práce. Výsledkom tejto snahy je v oblasti kriminalistiky najmä systém *AFIS* (Automatic Fingerprint Identification Systems), ktorý bol do súčasnej formy vyvíjaný posledných 40 rokov. Jedným z prvých používateľov biometrických systémov je teda opäť polícia, prípadne príbuzné agentúry, avšak v posledných rokoch sa biometrické systémy objavujú v čoraz viac oblastiach súkromného sektora.

Biometrický systém je vo všeobecnosti spojenie rôznych metód a postupov vedúcich od získania sledovanej charakteristickej vlastnosti, digitalizácie informácie, úpravy a samotného rozpoznávania až k identifikácii konkrétnej osoby.



Obrázok 1: Schéma základných procesov biometrického systému
(Maltoni, D. et al., 2009, str. 4)

Základnými procesmi biometrického systému sú registrácia odtlačku, verifikácia a identifikácia.

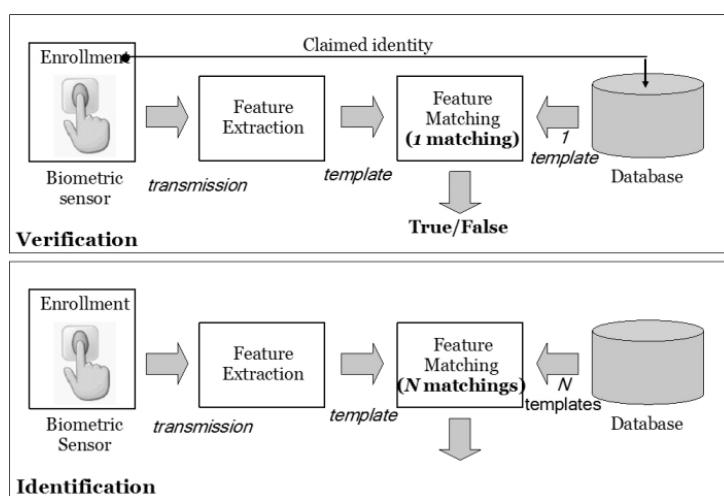
V prvej časti obrázku je blokovou schémou znázornený proces registrácie odtlačku, kedy je odtlačok zosnímaný a digitalizovaný, následne sú extrahované dôležité črty odtlačku potrebné pre rozpoznávanie (poloha a orientácia markantov). Tieto informácie sú uložené do databázy spolu s identifikačnými údajmi dotyčnej osoby.

Druhá časť predstavuje schému verifikácie identity osoby, kedy je overované, či predložená informácia (heslo) je spárovaná so zosnímaným odtlačkom.

V tretej časti sa nachádza schéma identifikácie, kedy je získaný odtlačok spracovaný a v databáze je vyhľadávaná zhoda medzi práve extrahovanými údajmi a záznamami.

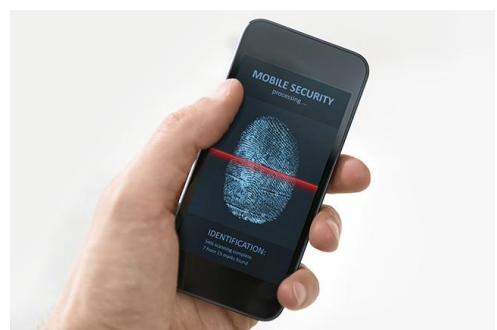
Treba podotknúť, že v závislosti od okolností/kontextu použitia systému, je možné rozdeliť biometrické systémy do 2 skupín:

- *verifikačné systémy* - overujú identitu na základe porovnania práve zosnímaného biometrického prvku a prvku, ktorý bol vložený do systému v minulosti ako vzor pre konkrétnego jedinca, dochádza teda k porovaniu 2 vzoriek. Výstupom takéhoto systému je buď zamietnutie alebo potvrdenie identity jedinca
- *identifikačné systémy* - ako bolo spomenuté vyššie, rozpoznanie jedinca prebieha porovnávaním získaného biometrického prvku s celou databázou, dochádza teda k porovaniu jednej vzorky s mnohými z databázy a výstupom je v prípade nájdenia zhody potvrdenie, že daný jedinec sa nachádza v databáze



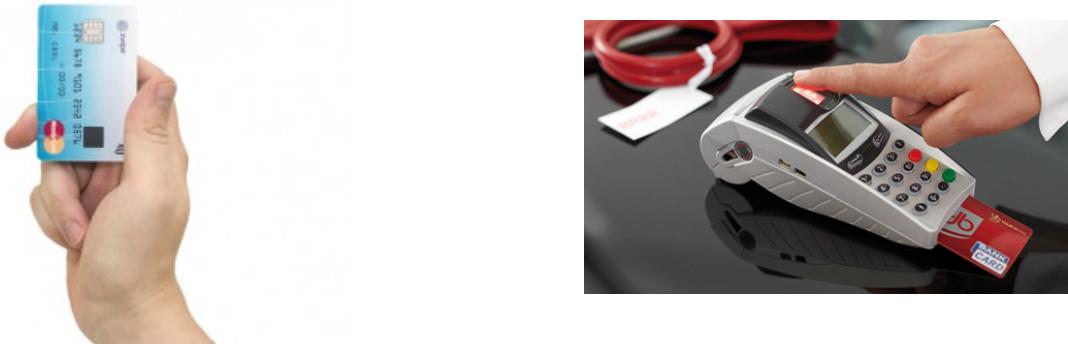
Obrázok 2: Blokové schémy verifikačných a identifikačných biometrických systémov

Biometrické systémy nájdu v súčasnej dobe uplatnenie v mnohých oblastiach týkajúcich sa bezpečnosti, či už ide o prístup do rôznych vyhradených priestorov, overenie identity pre prístup k informačným systémom alebo uzamykanie samotných zariadení proti neoprávnenému použitiu. Snímanými biometrickými prvkami môžu byť odtlačky prstov, snímky očnej sietnice, dúhovky, odtlačky dlaní, snímky cievneho riečiska dlane, záznamy hlasu, snímky tváre/hlavu a mnohé ďalšie. Najpoužívanejšími sú práve odtlačky prstov, ktoré majú spomedzi biometrických črt dominantné postavenie, nielen kvôli tomu, že sú sledované a skúmané najdlhšie, čo sa týka história, ale hlavne pre ich jedinečnosť, anatomickú stálosť a v súčasnosti aj pomerne jednoduchý spôsob ich získavania (Marák, P., 2012, str. 22).



Obrázok 3: Príklady použitia snímačov odtlačkov v súčasnosti

V poslednej dobe sa zabezpečenie na princípe odtlačkov prstov rozšírilo aj do oblasti zabezpečenia platobných kariet a ich používania ako takého. Príkladom môže byť systém Zwipe predstavený v októbri 2014, kde sa snímač odtlačku prstov nachádza priamo na platobnej karte a operácie s kartou je možné vykonávať bez použitia akéhokoľvek hesla, verifikáciu zabezpečuje spomenutý snímač.



Obrázok 4: Použitie odtlačkov pri platobných kartách

1.3 Biometrické systémy na báze odtlačkov prstov

1.3.1 Odtlačky prstov: postupný vývoj a súčasnosť

V priebehu histórie sa objavovali zmienky o odtlačkoch prstov už od roku 200 pred Kristom, avšak až do konca 19. storočia neboli odtlačkom prstov pripisovaný väčší význam. V samotnom 19. storočí boli odtlačky prstov alebo dlaní používané ako forma podpisu na rôznych dokumentoch, čím sa autor chránil pred zneužitím alebo sfalšovaním podpisu. Až v roku 1888 sa Sir Francis Galton začal venovať štúdiu odtlačkov prstov ako prostriedku k identifikácii osôb. V roku 1892 bol prvýkrát použitý odtlačok prstu k identifikácii páchateľa trestného činu. Zaslúžil sa o to Juan Vucetich, ktorý vychádzal práve z poznatkov Francisa Galtona. Ten v tom istom roku publikoval knihu *Fingerprints*, v ktorej poukazoval na jedinečnosť a stálosť odtlačkov a zaviedol prvý systém klasifikácie. Galton určil na odtlačkoch črty, podľa ktorých môžu byť identifikované. Niektoré z nich sa používajú dodnes a sú nazývané ako Galtonove detaily.

Začiatkom 20. storočia bolo vo Veľkej Británii schválené používanie odtlačkov prstov v oblasti kriminalistiky, ako náhrada za značne nepresný Bertillionov systém antropometrických mier. V roku 1901 bolo založené Oddelenie odtlačkov prstov v Scotland Yard-e a vedúcim tohto oddelenia sa stal Sir Edward Richard Henry, ktorý publikoval knihu *The Classification and Use of Fingerprints*. V priebehu niekoľko rokov sa využívanie odtlačkov rozšírilo aj do USA, kde ich začali používať policajné oddelenia, armáda,

ministerstvo spravodlivosti. V roku 1924 bola založená divízia identifikácie FBI, ktorá mala už v roku 1946 k dispozícii vyše 100 miliónov identifikačných kariet s odtlačkami, pričom do roku 1971 toto číslo naráslo na 200 miliónov. S príchodom automatizovaného systému identifikácie odtlačkov prstov (tzv. *AFIS* – „automated fingerprint identification system“) boli záznamy rozdelené, pričom tie kriminálne boli digitalizované.

1. augusta 1977 sa v New Orleans konala konferencia Medzinárodnej asociácie pre identifikáciu (IAI), kde bol odsúhlásený prvý medzinárodný certifikačný program pre expertov v oblasti odtlačkov prstov. V súčasnosti je držiteľ tohto certifikátu považovaný odborníkmi za špičku v tejto oblasti.

V súčasnosti je celosvetovo najväčšou databázou biometrický systém *AADHAAR*, spravovaný Unique Identification Authority of India, ktorý dosiahol v máji 2015 už takmer 850 miliónov zaregistrovaných osôb a obsahuje záznamy odtlačkov prstov, snímkov tváre a dúhovky.

1.3.2 Spôsoby získavania odtlačkov

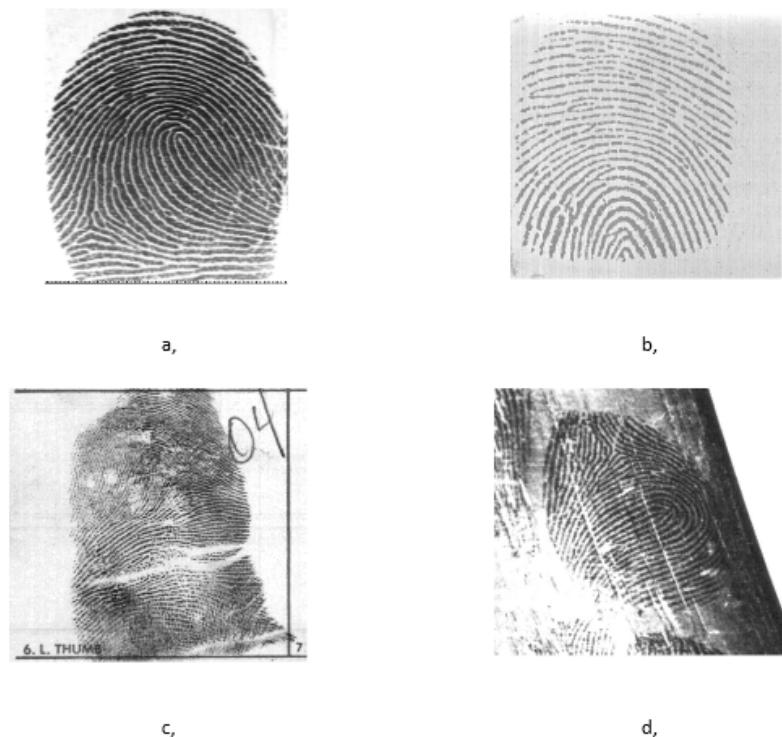
Pre získanie odtlačkov sa v dnešnej dobe používajú dve základné techniky a podľa použitého spôsobu snímky nazývame buď takzvané off-line alebo live-scan. Pri off-line ide o nanesenie farbiacej látky na končeky prstov a následné odtlačenie prstov na papier. Ten je následne skenovaný, prípadne je zhotovená fotografia s vysokou kvalitou a tým je získaná digitálna kópia odtlačku. Táto forma získavania odtlačkov je obzvlášť dôležitá v kriminalistike. Ide hlavne o takzvané latentné odtlačky prstov, ktoré sa nachádzajú na miestach činov. Tým, že koža človeka je do istej miery mastná a vlhká, je na povrchu objektov, ktorých sa človek dotkne, zanechaná stopa – latentný odtlačok, ktorý sa dá za pomoci rôznych techník získať a uchovať pre ďalšie využitie.

Druhý spôsob je bežne rozšírený v civilnom využití biometrických systémov a taktiež čoraz viac bezpečnostných zložiek a vyšetrovateľov využíva live-scan techniku. Ide o zo-snímanie odtlačku priamo z jedného či viacerých prstov s pomocou senzora. Táto metóda je rýchlejšia, ekonomickejšia a v závislosti od použitého senzora aj presnejšia ako metóda off-line spomenutá v predchádzajúcom odseku. Najčastejšie používané senzory je možné zaradiť do troch kategórií: optické, „solid-state“ a ultrazvukové.

1. *optické* senzory sú najstaršou a najpoužívanejšou formou live-scan techniky. Využívajú sa 3D vlastnosti povrchu prstu, kedy je povrch osvetlený svetlom a CMOS, prípadne CCD senzor, zachytáva odrazené svetlo. Línie v štruktúre povrchu prstu do istej miery pohltia/rozptýlia svetlo a na výslednom snímku sa prejavia ako tmavé

časti, čím je vytvorený obraz odtlačku. Nakolko tieto senzory snímajú 3D povrch, nie je ľahké ich oklamať napríklad snímaním odtlačku vytlačeného na papieri

2. takzvané *solid-state* senzory, inak nazývané aj silikónové, nevyužívajú optické prvky, princípom snímania odtlačkov je premenlivá veľkosť elektrického náboja na povrchu prsta, rozdielne úrovne náboja potom kódujú obraz – kapacitné, tepelné, piezoelektrické senzory
3. *ultrazvukové* senzory využívajú zvukové vlny a ich odraz na získanie odtlačku. Zvukový signál je využívaný na zistenie vzdialosti jednotlivých oblastí prstu od snímača. Táto technika získavania odtlačkov poskytuje veľmi vysokú kvalitu výsledných snímkov, avšak používané komponenty sú veľmi drahé a snímanie trvá niekoľko sekúnd, teda zatiaľ nie je vhodná pre hromadné využitie



Obrázok 5: Odtlačky prstov získané: a, live-scan optický skener; b, live-scan kapacitný skener; c, off-line atramentový odtlačok; d, latentný odtlačok
(Maltoni, D. et al., 2009, str. 37)

Pri odtlačkoch je dôležité spomenúť parametre, ktoré určujú kvalitu obrázku. Jedným z najdôležitejších parametrov je rozlíšenie, ktoré určuje počet bodov/pixelov na palec

(dpi). FBI stanovila vo svojich normách (IAFIS) ako najnižšiu prípustnú hranicu rozlíšenie 500 dpi, pričom táto hodnota je bez problémov splnená aj väčšinou komerčne používaných zariadení. Tieto zariadenia sú však postupne nahradzane 1000 dpi skenermi, s rastúcim záujmom o detaily ako sú napríklad potné pory. S rozlíšením úzko súvisí aj počet pixelov, ktoré tvoria snímanú oblasť. Tieto dva parametre určujú do akej miery sú detaily v obrázku rozpoznateľné.

1.3.3 Predspracovanie, filtrovanie a úprava odtlačkov

Nakolko pri snímaní odtlačku nie je možné zabezpečiť dokonale čisté prostredie a ideálne podmienky, častokrát sú aj pri maximálnom úsilí výsledné obrázky kvalitatívne znehodnotené a je potrebné ich nejakým spôsobom upraviť, aby boli zachované jedinečné a charakteristické znaky odtlačku. Pokiaľ by k tomuto procesu úpravy nedochádzalo, systém by nemusel označiť odtlačky pochádzajúce z jedného prsta ako totožné.

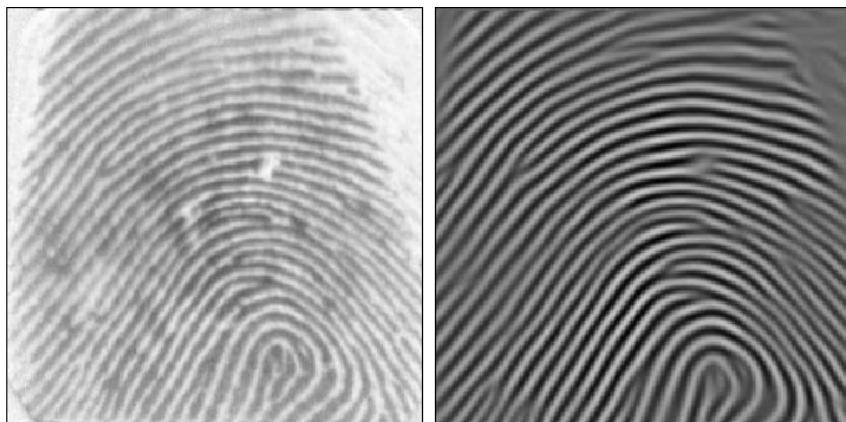
Najčastejšími príčinami zníženia kvality papilárnych línii sú nečistoty na povrchu snímača alebo prsta, deformácie kože, nevhodná vlhkosť kože, nevhodný tlak prstu na snímacie zariadenie, nekompletnosť odtlačku. Všetky tieto faktory degradujú kvalitu odtlačkov a zvyšujú nejednoznačnosť pri rozpoznávaní. Obrazové predspracovanie je teda súhrn techník, ktoré majú odstrániť znehodnotenie informácií obsiahnutých v odtlačku a zároveň zvýrazniť jedinečné prvky v maximálnej možnej miere. Posledným krokom býva transformácia odtlačku do takej formy, aby bolo čo najjednoduchšie odhaliť a rozlísiť daktyloskopické markanty. Medzi tieto techniky patrí napríklad aplikácia Gaborovho kontextového filtra, korekcia histogramu či binarizácia farieb. Je však potrebné myslieť na to, aby nebol odtlačok modifikovaný natoľko, že budú jedinečné znaky potlačené.



Obrázok 6: Jednotlivé časti obrazového predspracovania snímky odtlačku
(Marák, P., 2012, str. 75)

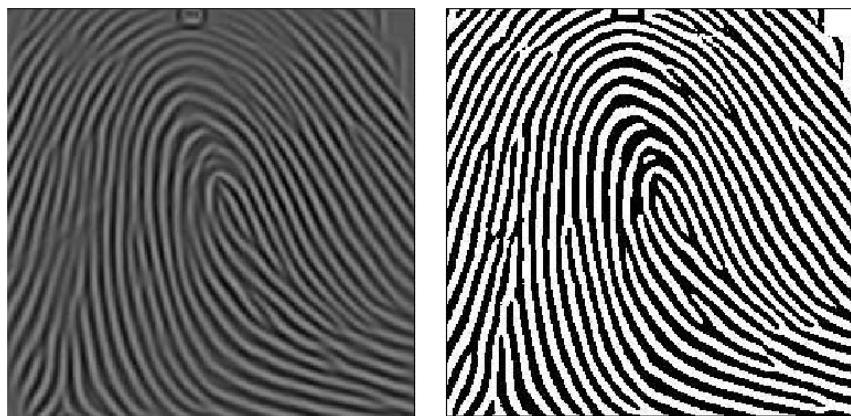
Prvým krokom predspracovania býva väčšinou segmentácia, teda oddelenie pozadia od samotného vzoru odtlačku. Výstupom tohto procesu je časť obrázku, ktorá je tvorená len papilárnymi líniemi, teda časť obsahujúca len užitočné informácie. Nasledujúcim krokom je odstránenie oblastí odtlačku, ktoré sú znehodnotené a majú vysokú mieru neistoty pokiaľ ide o nachádzanie markantov. Použitím sa môže takzvaná koherenčná mapa, ktorá graficky vyznačuje miesta, ktoré sú smerovo konzistentné a tie, ktoré nemajú dominantný smer (Marák, P., 2012, str. 46). Ďalším krokom je normalizácia histogramu odtlačku, teda upravenie rozloženia farieb v histograme, aby bol dosiahnutý dostatočne veľký kontrast medzi svetlými a tmavými časťami odtlačku. Najmä vďaka nadmernému tlaku a nevhodnej vlhkosti môže byť kontrast medzi papilárnymi líniemi malý a je teda problematické určiť obrys a rozlísiť jednotlivé línie. Normalizácia by mala byť aplikovaná lokálne, nakoľko každá časť odtlačku môže vyžadovať inú úpravu histogramu.

Na normalizovaný odtlačok sa aplikuje *Gaborov filter*. Ide o kontextový filter, pretože jeho parametre sú odvodené od lokálneho grafického kontextu obrazca odtlačku (Marák, P., 2012, str. 49). Jeho úlohou je eliminácia obrazových defektov a zvýraznenie toku papilárnych línií. Tento filter je aplikovaný po obrazových bodoch a je teda schopný obnoviť aj kvalitu malých detailov.



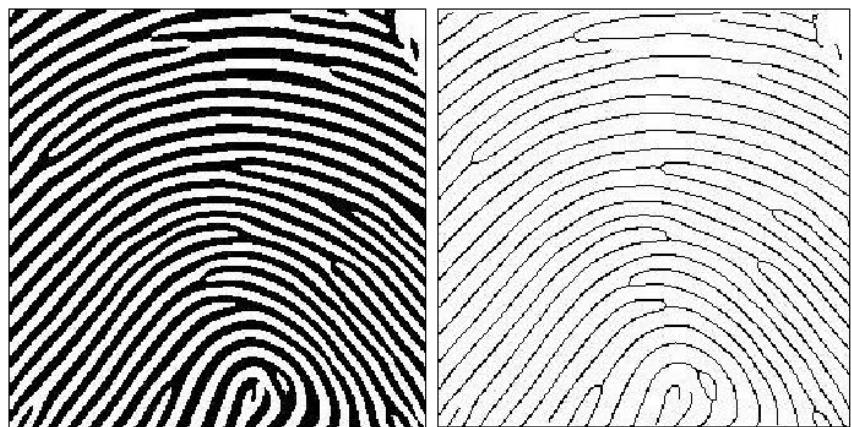
Obrázok 7: Aplikácia Gaborovho filtra – pred aplikáciou(naľavo), po aplikácii(napravo)

Posledným krokom predspracovania býva *binarizácia*, teda transformácia obrázku z 256 odtieňov šedej do čiernej a bielej. Čierna farba predstavuje línie, biela pozadie. Problémom býva správne určenie či bod patrí do pozadia alebo naopak je to papilárna línia. Použitie globálnej prahovej hodnoty nie je vhodný prístup a je teda potrebné používať adaptívnu binarizáciu, ktorá berie do úvahy lokálny priemer intenzity farieb.



Obrázok 8: Binarizácia – pred úpravou(naľavo), po úprave(napravo)

Na koniec obrazového predspracovania sa ešte aplikuje zúženie hrúbky papilárnej línie, takzvaná *skeletonizácia*, až na 1 pixel. Takto upravený odtlačok sa nazýva kostra a je pripravený na extrakciu a lokalizáciu markantov a ďalších dôležitých charakteristických znakov. Tento krok je veľmi citlivý na predchádzajúce kroky a akékoľvek defekty, ktoré neboli predošlými úpravami odstránené, prípadne vznikli počas úprav, sa prejavia a sú natoľko viditeľné, že môžu byť vo fáze extrakcie falošne označené ako markanty.



Obrázok 9: Skeletonizácia - pred úpravou(naľavo), po úprave(napravo)

1.4 Charakteristika úrovní detailov odtlačkov

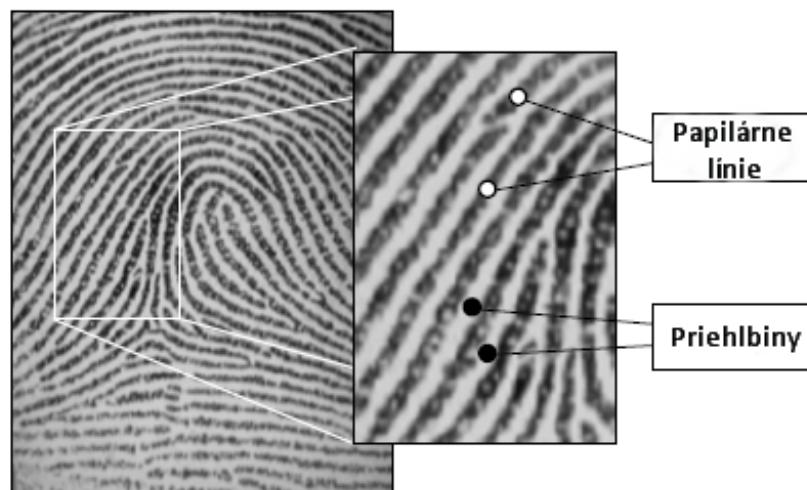
1.4.1 Význam klasifikácie detailov odtlačkov prstov

Pri rozpoznávaní a porovnávaní odtlačkov prstov sa objavuje otázka aké množstvo informácií je potrebné na jednoznačné a spoľahlivé rozpoznanie jedinca. Najrozšírenejším zdrojom informácií pri rozpoznávaní v AFIS systémoch sú charakteristické tvary odtlačku – *markanty*, pričom do úvahy sa neberie len ich tvar, ale aj poloha a orientácia. Jedinečnosť odtlačku nebola v globálnej miere doposiaľ dokázaná, a teda objavuje sa otázka do akej miery je isté, že sa rovnaká konfigurácia znakov nevyskytne u viacerých jedincov. Podľa jedného zo zahraničných výskumov (Pankanti, S. et al., 2002, str. 1010) je pravdepodobnosť, že sa dva rôzne odtlačky s 36 markantmi zhodujú v 12, vyčíslená na hodnotu $6,10 \times 10^{-8}$ (Marák, P., 2012, str. 29). Odtlačky prstov obsahujú veľké množstvo špecifických dát, avšak používané metódy snímania nie vždy umožňujú zaznamenať ich. Súčasná biometria dôveru v jedinečnosť odtlačku zakladá na ojedinelosti výskytu jednotlivých typov charakteristických znakov, nakoľko každý z nich má inú frekvenciu výskytu a niektoré sú v populácii veľmi vzácné (napr. roztrojenie – 0,07 %). Pri porovnávaní sa sledované odtlačky musia zhodovať v minimálnom potrebnom počte znakov a navyše súčet koeficientov týchto znakov musí presiahnuť určenú hraničnú hodnotu. Každý znak ma koeficient, ktorý určuje ojedinenosť výskytu. Čím je frekvencia výskytu markantu nižšia, tým je koeficient vyšší. Treba však podotknúť, že väčšina biometrických systémov využíva na porovnanie len 2 základné znaky a to *vidlica* a *ukončenie*. Vzácnejšie markanty sa neberú do úvahy a tým dochádza k strate charakteristických informácií.

Kriminalistická daktyloskopia na Slovensku využíva kvantitatívny model, je potrebná zhoda aspoň 10 markantov, aby bola osoba pozitívne identifikovaná. Čoraz viac presadzujúcim sa trendom je využitie kvalitatívneho modelu, ktorý využíva už spomínané ohodnocovanie markantov na základe ich výskytu v populácii. Tento model môže zvýšiť presnosť pri rozpoznávaní, pretože analyzuje odtlačok na viacerých úrovniach a tým poskytuje väčšie množstvo jedinečných informácií.

1.4.2 Úrovne daktyloskopických vzorov

Základným stavebným kameňom odtlačku prstu sú papilárne línie a priehlbiny medzi nimi. Šírka papilárnych línií sa pohybuje v rozpätí 100 až 300 μm , pričom priemerná šírka papilárnej línie spolu s priehlbinou je približne 500 μm (Maltoni, D. et al., 2009, str. 97).

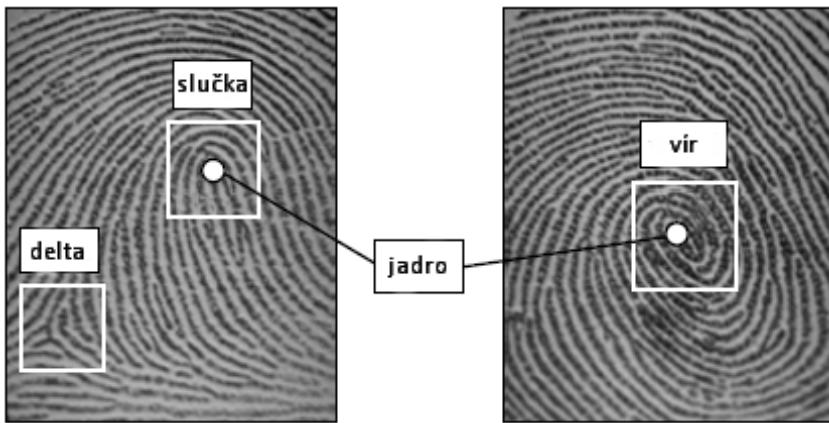


Obrázok 10: Papilárne línie a priehlbiny medzi nimi
(Maltoni, D. et al., 2009, str. 97)

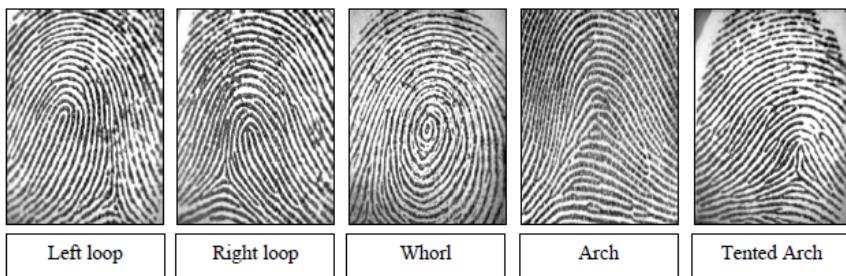
Detailly a tvar papilárnych línií i celého odtlačku sa popisuje na troch rôznych úrovniach:

Level 1 – globálny vzor – väčšinu plochy odtlačku tvoria súbežné papilárne línie, ktoré sú však v niektorých bodoch narušené a sformované do špecifického tvaru (vysoké zakrivenie, vysoká hustota ukončení). Tieto body sa nazývajú singularity (Maltoni, D. et al., 2009, str. 98) a môžu byť klasifikované do troch skupín: slučka, delta, vír. Ďalším dôležitým bodom, ktorý je úzko spojený so singularitami je jadro. Je to stred vzoru odtlačku a často zároveň predstavuje aj stred najdominantnejšej singularity. Body singularity sa bežne používajú pre klasifikáciu odtlačkov do tried na základe typov singularít, ktoré obsahujú. Cieľom tohto procesu je urýchlenie a zjednodušenie vyhľadávania.

Samotný globálny vzor nie je postačujúci na jednoznačnú identifikáciu.



Obrázok 11: Typy singulárnych bodov s vyznačenými jadrami
(Maltoni, D. et al., 2009, str. 98)

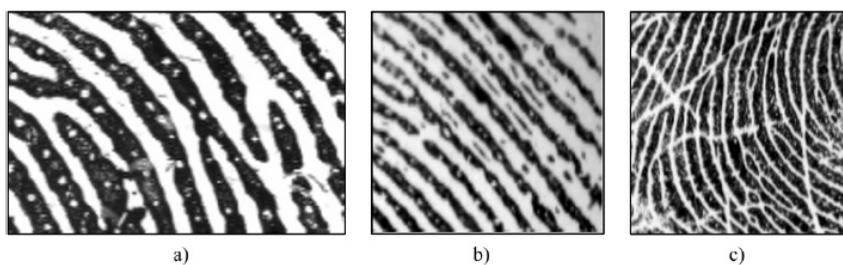


Obrázok 12: Základné klasifikačné triedy podľa Henry(1900)
(Maltoni, D. et al., 2009, str. 98)

Level 2 – markanty, v anglickej literatúre nazývané aj *minutiae* – sú základným prvkom Level-2 detailov odtlačkov, pričom súčasná biometria sa pri určovaní jedinečnosti opiera práve o tieto znaky. Markant je anomália vyskytujúca sa na papilárnej líni, či už ide o náhle ukončenie línie, prípadne jej rozdvojenie alebo o inú tvarovú deformáciu. Týchto anomálií existuje niekoľko typov a prvý kto ich kategorizoval bol Sir Francis Galton. Zároveň počas svojho výskumu zistil, že markanty sa počas života človeka nemenia a zostávajú nezmenené (Maltoni, D. et al., 2009, str. 99). Podrobnejšie sa markantom bude venovať kapitola 1.4.3.

Level 3 – detaile papilárneho terénu – ide o geometrické vlastnosti línií – teda šírka, tvar, obrys, ďalej rozmiestnenie potných pórov v papilárnej líni, jazvy a ďalšie drobné detaile. V oblasti kriminalistiky sú vyvinuté dve analytické disciplíny, ktoré skúmajú 3. úroveň detailov: poroskopia a obryskopria (Marák, P., 2012, str. 37). Poroskopia sa zaobráva rozmiestnením potných pórov a ich využitím pri identifikácii. Každá papilárna línia je po celej svojej dĺžke posiata potnými pórmami. Veľkosť pórov

sa pohybuje v rozmedzí od 60 do 250 μm , pričom pozorovaním bolo zistené, že počet pórov na 1 centimeter línie sa pohybuje od 9 do 18 (Maltoni, D. et al., 2009, str. 101). Podľa Davida Ashbaugh-a postačuje na jednoznačné identifikovanie osoby 20 – 40 zhodných pórov (Maltoni, D. et al., 2009, str. 101). Detaily 3. úrovne majú vysokú informačnú hodnotu, avšak len málo súčasných senzorov spĺňa požiadavky potrebné na zachytenie týchto detailov (1000 dpi). Taktiež neexistujú dostatočne presné automatizované algoritmy na vyhľadávanie a porovnávanie detailov 3. úrovne. Ide však o nádejnú oblast biometrie do budúcnosti.



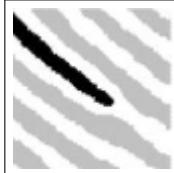
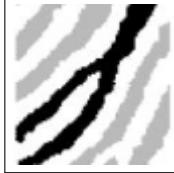
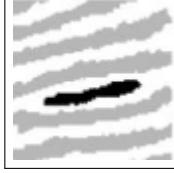
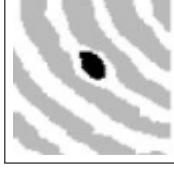
Obrázok 13: Jednotlivé Level-3 detaily

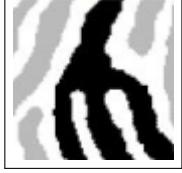
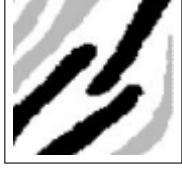
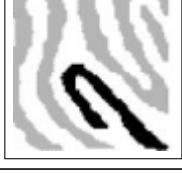
(Maltoni, D. et al., 2009, s. 101)

V ľavej časti obrázku je možné vidieť časť odtlačku prstu v rozlíšení 1000 dpi, potné póry predstavujú biele body v papilárnych líniach, taktiež je viditeľná rôzna hrúbka línií. Časť v strede zobrazuje tzv. *vmedzerené línie*, tieto nedosahujú hrúbky klasických papilárnych línií a neobsahujú potné póry. Pravá časť obrázka znázorňuje jazvy a škrabance napriek papilárnym líniám.

1.4.3 Detaily 2. úrovne

Markantom, teda charakteristickým detailom 2. úrovne, sa bude venovať celá nasledujúca kapitola, pretože práve markantami a ich extrakciou pomocou neurónových sietí sa táto práca zaoberá. Ako už bolo spomenuté v kapitole 1.2.2, markant predstavuje anomáliu v priebehu papilárnej línie, ktorá narúša súbežný tok papilárnych línií. Ide o rôzne typy rozvetvenia, ukončenia, kríženia a ďalšie tvarové nepravidelnosti. Nasledujúca tabuľka predstavuje známe typy markantov, pričom pri každom je uvedený aj stručný popis a frekvencia výskytu v populácii SR. Pri niektorých z uvedených markantov je použitý anglický názov, nakolko je zložité nájsť vhodný slovenský ekvivalent.

Názov markantu	Tvar markantu	Frekvencia výskytu v SR(v %)	Stručný popis
Ukončenie		35,9	Prirodzené ukončenie papilárnej línie
Rozdvojenie		43,0	Jedna papilárna línia sa rozdelí na dve
Fragment		6,9	Krátká papilárna línia s dĺžkou od 2 do 10 pórov
Bod		2,8	Krátká papilárna línia obsahujúca jedený pór
Jazero		3,6	Rozdvojenie papilárnej línie, ktoré sa po maximálne 10 póroch spojí do jednej línie
Prerušenie		2,7	Konce dvoch papilárnych línií vzdialené max. 5 pórov od seba (nie je to výsledok zranenia)
"Crossbar"		0,7	Dve papilárne línie prerušené tretou, križujúcou líniou

Prekrytie		3.2	Prekrytie dvoch papilárnych línií, do dĺžky max. 10 pórov
Premostenie		0,8	Veľmi krátka papilárna línia spájajúca dve susedné línie
Protilahlé rozdvojenia		0,17	Dve rozdvojenia s opačnou orientáciou, začínajúce v spoločnom bode
Roztrojenie		0,07	Rozdelenie papilárnej línie v jednom bode na 3 samostatné línie
Ukotvenie		0,13	Ukončenie papilárnej línie medzi dvomi líniami, s dĺžkou presahu max. 10 pórov
Otočenie		-	Otočenie a ukončenie papilárnej línie, ktoré nie je súčasťou stredu vzoru odtlačku (jadra)
Háčik		-	Výbežok z papilárnej línie s dĺžkou max. 10 pórov

Tabuľka 1: Rozdelenie markantov a ich popis

Uvedené dĺžkové údaje rôznych výbežkov a prekrývajúcich sa častí boli prevzaté z diplomovej práce Ing. Pavla Maráka, kde bola za jednotku vzdialenosť stanovená vzdialenosť medzi 2 susednými potnými pórmami (približne $250 \mu\text{m}$).

Samotná extrakcia vyššie uvedených markantov nie je jednoduchá záležitosť, nakoľko problémom býva častokrát kvalita odtlačku a taktiež neexistujúce spoľahlivé algoritmy, ktoré by bolo možné použiť pri plne automatizovanej extrakcii markantov. Väčšina automatických systémov porovnávajúcich odtlačky prstov pracuje na princípe porovnávania markantov, a preto je ich správna a spoľahlivá extrakcia extrémne dôležitou úlohou.

1.4.4 Používané metódy extrakcie markantov

Extrakciu je možné realizovať dvomi spôsobmi: automatizované alebo manuálne. Zatiaľ však neexistujú úplne spoľahlivé algoritmy a to z dôvodu extraholovania falošných markantov. Tento neželaný jav je spôsobený nekvalitou sledovaných odtlačkov a taktiež chybami a umelými elementami, ktoré sú do odtlačku vnášané počas procesu predspracovania. Aj z tohto dôvodu je zatiaľ manuálny spôsob skúmania papilárnych línií považovaný za najspoľahlivejší a to najmä v kriminalistike a forenznej oblasti. Výhodou je teda jeho presnosť a spoľahlivosť, avšak je časovo veľmi náročný. Odborník dokáže pružne reagovať na kvalitu odtlačku a objektívne posúdiť či ide o skutočný alebo falošný markant, táto schopnosť zatiaľ aktuálne používaným algoritmom chýba. A práve v tomto by sa mohli ukázať neurónové siete ako vhodné riešenie.

Jednotlivé techniky extrakcie – teda lokalizácia a určenie tvaru markantu, používané pre svoju činnosť rôzne reprezentácie samotného odtlačku. Taktiež výpočtová zložitosť je pri každej metóde iná. Metódy, ktoré budú v tejto kapitole popísané, využívajú rozdielne lokálne informácie povrchu odtlačku. Ide najmä o topológiu odtlačku a smerové mapy.

Extrakcia metódou Crossing Number Štruktúra odtlačku prstu a jej vyšetrovanie je základom väčšiny najpoužívanejších metód extrakcie. V určitých prípadoch sa kvôli zjednodušeniu nesledujú papilárne línie, ale medzery medzi nimi, ktoré majú taktiež výpovednú hodnotu o markantoch a ich polohách (Marák, P., 2013, str. 20). Pri samotnom skúmaní štruktúry sa používa kostra odtlačku, teda obraz odtlačku, kde sú papilárne línie zúžené na hrúbku jedného obrazového bodu. Zužovanie (tzv. *skeletonizácia*) je citlivý proces, ktorý so sebou prináša riziko vytvorenia umelých falošných markantov vo výslednom obrazu. Tento proces súvisí s binarizáciou, výsledná kostra teda obsahuje len obrazové body s hodnotami 0 alebo 1.

Metóda Crossing Number spočíva v prechádzaní všetkými bodmi obrazu, pričom v prípade, že ide o bod ležiaci na papilárnej línií, okolie tohto bodu sa vyhodnotí. Vyhodnotenie okolia bodu predstavuje spočítanie prechodov z hodnoty 0 do 1 a opačne – teda počet prechodov z papilárnej línie do medzery a naspäť. Hodnota

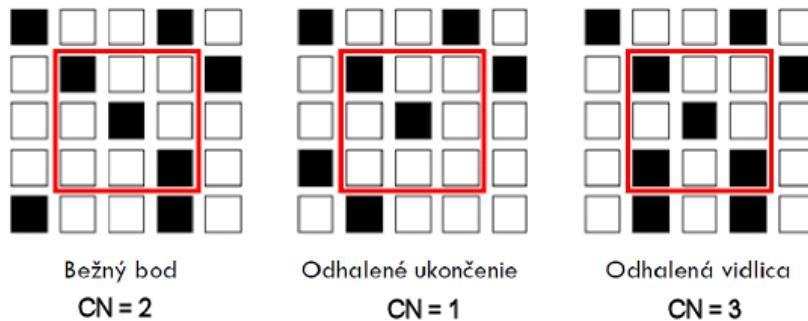
CN pre pixel p je definovaná ako polovica súčtu prechodov medzi 8 susednými pixelymi pixelu p (Maltoni, D. et al., 2009, str. 149). Matematické vyjadrenie je dané nasledujúcim vzťahom:

$$CN(p) = \frac{1}{2} \sum_{i=1..8} |val(p_{i \text{ mod } 8}) - val(p_{i-1})| \quad (1)$$

Rozlišujeme nasledovné výstupy vyššie uvedeného vzťahu:

- $CN = 0$ – izolovaný bod
- $CN = 1$ – ukončenie papilárnej línie
- $CN = 2$ – priebežný bod papilárnej línie
- $CN = 3$ – rozdvojenie papilárnej línie
- $CN > 3$ – z hľadiska metódy ignorované body

Nasledujúci obrázok znázorňuje príklady bodov spracovávaných metódou Crossing Number. Sledovaný bod sa nachádza v strede matice orámovanej červenou čiarou.

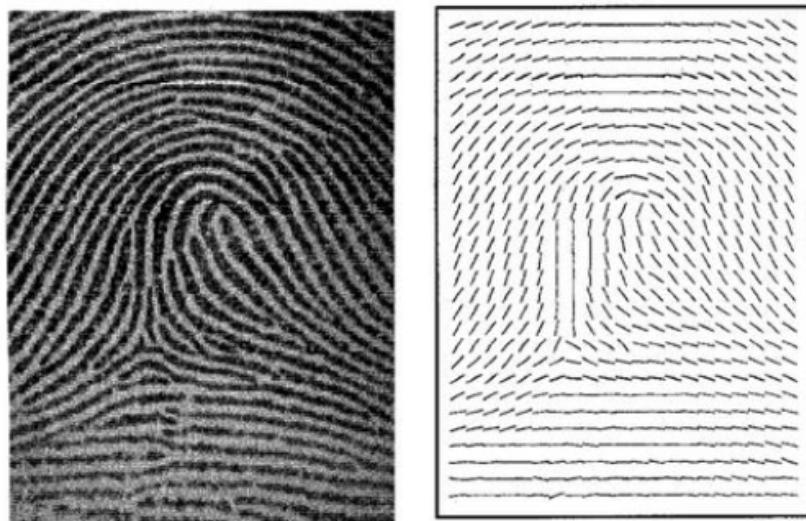


Obrázok 14: Spracovanie okolia bodu metódou Crossing Number

(Marák, P., 2013, str. 21)

Použitie metódy Crossing Number je pomerne nenáročný a presný spôsob na nájdanie základných markantov ukončenia a rozdvojenia. Taktiež výpočtová zložitosť tejto metódy je pomerne nízka. Nevýhodou tejto metódy je však absencia odhalenia falošných markantov, a teda spolieha sa na prácu s odtlačkami vysokej kvality alebo použitie filtra na potlačenie šumu.

Extrakcia markantov v originálnom obraze v odtieňoch šedej Automatizované systémy sa pri extrakcii zameriavajú na 2 základné markanty – ukončenie, rozdvojenie, nakoľko ide o tvarovo najliahšie detektovateľné znaky. Avšak ani v ich prípade nie je spoľahlivá softvérová extrakcia úplne vyriešený problém. Kritickou časťou je práve proces spracovania a úpravy obrazu do formy, v ktorej je možné aplikovať metódu extrakcie. Nízka kvalita a vnášanie falošných markantov pri procese redukcie hrúbky papilárnych línii znižujú spoľahlivosť a dôveryhodnosť danej metódy. Preto boli navrhnuté a vyvinuté metódy, ktoré by sa čo najviac vyhli procesom úpravy spomínaným v úvode tejto časti. Snahou bolo extrahovali markanty z pôvodného obrazu, ktorý by bol transformovaný zo stupňov šedej do binárnej formy. V roku 1997 navrhli Maltoni a Maio metódu, ktorej hlavnou myšlienkou je sledovanie papilárnych línii v obraze v odtieňoch šedej a vyhodnocovanie lokálnej informácie na nájdenie ukončenia a rozdvojenia. Motívaciou autorov bolo eliminovať stratu informácií, ku ktorej dochádza počas binarizácie, ktorá je navyše časovo náročná. Základnou myšlienkou je sledovanie papilárnej línie v smere získanom zo smerovej mapy. Príklad smerovej mapy je uvedený na nasledujúcim obrázku.



Obrázok 15: Príklad smerovej mapy odtlačku
(Marák, P., 2013, str. 22)

Odhad smeru pri smerovej mape je počítaný na základe gradientu, ktorý určuje zmenu intenzity obrazových bodov v určených smeroch. Na základe klesania a stúpania hodnôt intenzity je možné určiť smer línii.

Algoritmus prechádza líniou až kým nenarazí na koniec alebo napojenie na inú papilárnu líniu. Hlavnou ideoou je, aby algoritmus prešiel každou líniou práve jeden krát. Počas prechodu papilárnej líniou je sledované maximum intenzity obrazových bodov a spájaním týchto maxím je vytváraná polygonálna approximácia línie.

Samotná detekcia markantov prebieha na základe interpretácie dosiahnutia ukončovacích podmienok stopovacieho algoritmu. V prípade napojenia sledovanej línie na inú, už prejdenú líniu, sa v danom mieste napojenia nachádza rozdvojenie. Ukončenie je identifikované v miestach, kde dochádza k extrémnemu zakriveniu sledovanej papilárnej línie, ktoré je neprirodzené pre papilárne línie na malej ploche. Táto prudká zmena smeru indikuje prerušenie spojitosti línie a teda ide o ukončenie.

Na základe porovnaní a štatistického vyhodnotenia výsledkov autori došli k záveru, že táto metóda je odolnejšia voči falosným markantom ako iné metódy. Výsledky boli porovnávané s metódami využívajúcimi rôzne varianty Crossing Number, ktorá je opísaná vyššie.

1.5 Daktyloskopické systémy a neurónové siete

1.5.1 Princípy neurónových sietí

Zdrojom informácií pri tvorbe tejto kapitoly bol dokument *Využitie neurónových sietí pri biometrickom rozpoznávaní osôb odtlačkami prstov* od Ing. Pavla Maráka.

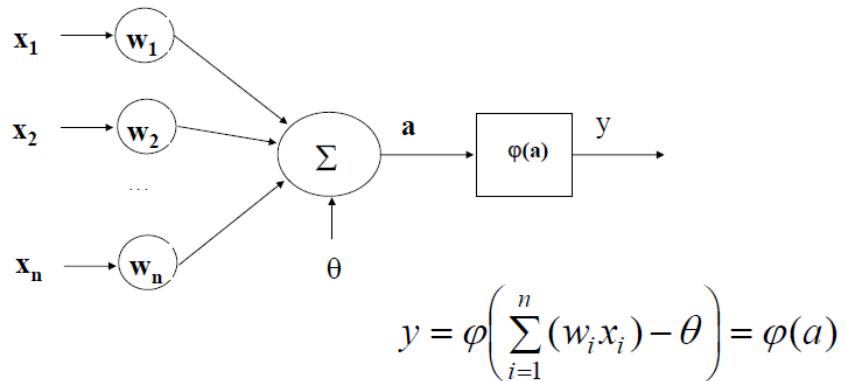
Neurónové siete ako výpočtové modely sú inšpirované štruktúrou a fungovaním centrálnej nervovej sústavy živých organizmov. Sú schopné rozpoznávať rôzne komplexné vzory a dokážu sa strojovo učiť. Ich štruktúra sa skladá z množiny elementov, ktoré sú poprepájané a navzájom si medzi sebou predávajú informácie. Práve ich vnútorná štruktúra a vzájomný spôsob komunikácie odlišuje neurónové siete od tradičných výpočtových systémov.

Jadrom práce neurónových sietí je aktivácia vstupných elementov na základe vstupnej informácie. Táto informácie je aktivovanými prvkami prenášaná hlbšie do siete, k ďalším elementom, pričom spôsob ich prepojenia simuluje spojenie neurónov v mozgu. Sila týchto prvkov, nazývaná váha sa nastavuje počas šírenia informácie a na základe parametrov zadaných tvorcom neurónovej siete. Vďaka schopnosti učiť sa, je neurónová sieť schopná approximovať ľubovoľnú funkciu, čo predstavuje hlavnú výhodu voči ostatným formám systémov. Pozorovaním – učením sa, sú nastavené váhy a vnútorné parametre na hodnoty, ktoré umožňujú neurónovej sieti rozpoznávať vzory, na ktoré sa počas učenia prispôsobila.

Najmä kvôli schopnosti rozpoznávať komplexné vzory a vďaka miere tolerancie sú neurónové siete vhodným prostriedkom pre biometriu. Napriek neustálemu výskumu a vývoju v oblasti automatizovaného rozpoznávania odtlačkov prstov, dodnes nebolo nájdené uspokojivé a dostatočne spoľahlivé riešenie. Plne automatizované rozpoznávanie tak stále ostáva nevyriešeným problémom, očakáva sa však, že práve neurónové siete by mohli byť vhodným riešením. Výhodu pred ostatnými prístupmi ma neurónová sieť vďaka určitej miere tolerancie voči odchýlkam, ktoré sú spôsobované počas snímania odtlačku alebo počas úpravy obrazu. Čo sa týka rozpoznávania globálneho vzoru, boli neurónové siete úspešne testované a popísané prácami mnogých autorov. Oblast rozpoznávania markantov na lokálnej úrovni nie je ešte v súčasnosti dostatočne preskúmaná, a preto ostáva otázkou efektívnosť neurónových sietí v tomto smere. Princíp a použitie týchto sietí je možné využiť aj pri porovnávaní dvoch odtlačkov.

1.5.2 Architektúra neurónových sietí

Neurónová sieť, tak ako aj mozog, ktorý sieť simuluje, je zložená z navzájom prepojených elementov – *neurónov*. Váhy predstavujú silu väzieb medzi neurónmi a tvoria tak „poznatky“ neurónovej siete, ktoré získala počas fázy učenia. Nakoľko neuróny obsahujú nelineárne aktivačné funkcie, sú neurónové siete schopné modelovať nelineárne vzťahy medzi vstupnými údajmi a výstupným rozhodnutím siete, čoho ukážkou je napríklad deformácia pokožky, ktorá vytvára viacnásobnú reprezentáciu rovnakého prsta, avšak s požadovanou klasifikáciou do rovnakej triedy. Vďaka možnosti upravovať a prispôsobovať svoje parametre je sieť schopná adaptovať sa na rôzne podmienky a poskytuje toleranciu voči odchýlkam vstupných dát. Pokial obsahujú skryté vrstvy neurónovej siete dostatočný počet neurónov, je sieť schopná aproximovať ľubovolnú spojitú funkciu. Základnou stavebnou a výpočtovou jednotkou neurónovej siete je neurón. Nasledujúci obrázok znázorňuje model neurónu.



Obrázok 16: Model umelého neurónu

x_i - vstupy neurónu	a - vnútorná aktivita neurónu
w_i - váhy synaptických spojení	φ - aktivačná funkcia neurónu
θ - prah – citlivosť neurónu	y - výstup neurónu

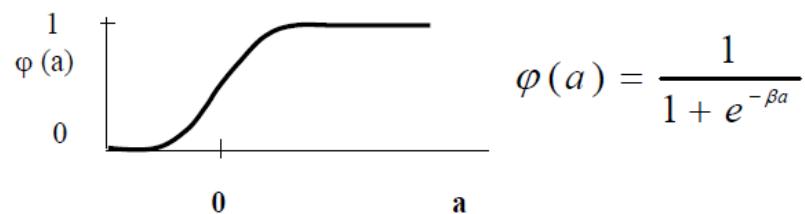
Sumovaný vstup do neurónu – vnútorná aktivita neurónu

$$a = \sum_{j=0}^p w_{k,j} x_j \quad (2)$$

Medzi najpoužívanejšie aktivačné funkcie patria:

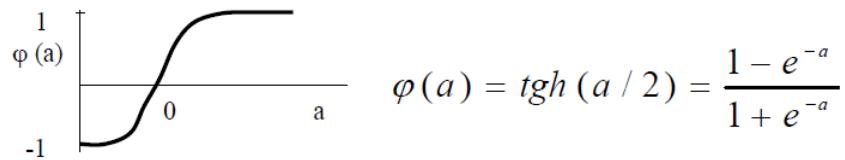
- *sigmoida*

- parameter a predstavuje strmost funkcie – mení tvar krvky



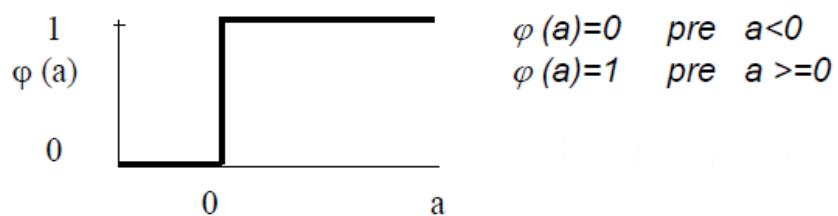
Obrázok 17: Priebeh sigmoidy

- hyperbolický tangens



Obrázok 18: Priebeh hyperbolického tangensu

- skoková funkcia

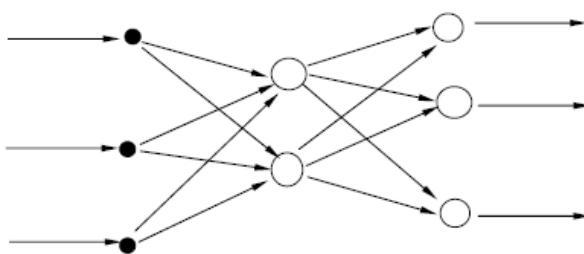


Obrázok 19: Priebeh skokovej funkcie

Spomedzi spomenutých sa však v konštrukciách neurónových sietí používa najčastejšie práve *sigmida*.

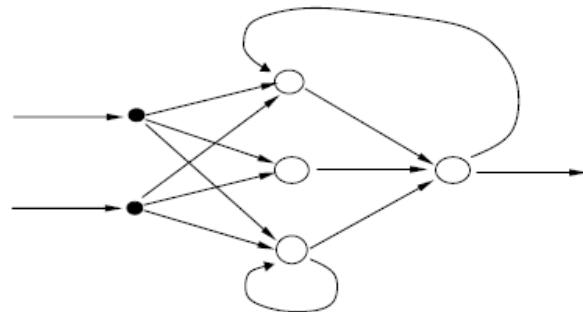
Existuje niekoľko typov architektúr neurónových sietí, ktoré sa navzájom odlišujú prepojením neurónov a šírením informácií v rámci siete.

1. *Dopredné siete* – neuróny sú usporiadané vo vrstvách, pričom obsahujú vstupnú a výstupnú vrstvu, môžu obsahovať aj skryté vrstvy, informácie sú šírené len v smere od vstupnej vrstvy k výstupnej



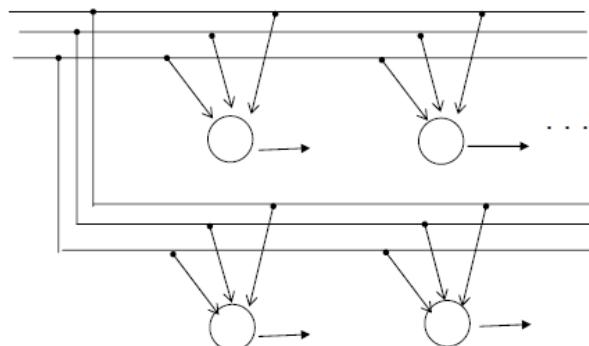
Obrázok 20: Schéma doprednej siete

2. *Rekurentné siete* – obsahujú aspoň jednu spätnú väzbu v rámci tej istej vrstvy alebo v rámci rôznych vrstiev



Obrázok 21: Schéma rekurentnej siete

3. *Kohonenova sieť* (mriežková štruktúra) – skladajú sa z dvoj alebo viacozmerného poľa neurónov, vstupný signál je privádzaný na vstup všetkých neurónov



Obrázok 22: Schéma Kohonenovej siete

1.5.3 Učenie neurónovej siete

Učenie je proces prispôsobovania parametrov siete na základe vstupov a očakávaných výstupov. Ide o zmenu váh synaptických prepojení neurónov na základe korekcie odchýlky. Matematický predpis úpravy jednotlivých váh v krokoch:

$$w_{k,j}(n+1) = w_{k,j}(n) + \Delta w_{k,j}(n) \quad (3)$$

Učenie je možné klasifikovať do viacerých kategórií:

a) podľa miery vplyvu učiteľa

- učenie s učiteľom
- známkované učenie
- samoorganizácia

b) podľa typu učenia

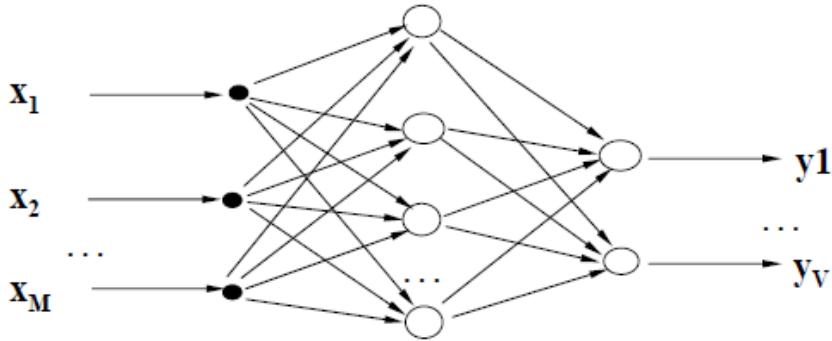
- učenie korigujúce chybu – *back propagation error*
- sútažné učenie
- Hebbovo učenie

Pri učení s učiteľom sú sieti poskytované správne odpovede, aby vedela podľa toho korigovať svoje parametre. Známkované učenie ohodnocuje výstupy a podľa týchto ohodnení si sieť koriguje parametre. Pri samoorganizácii sa sieť modifikuje sama reakciou na vstupné dátá bez akéhokolvek učiteľa.

Pri vytváraní neurónovej siete nie je možné podľa nejakého predpisu presne určiť optimálne množstvo neurónov. Hľadanie tohto optimálneho počtu preto prebieha formou viacnásobného testovania neurónovej siete s rôznym počtom neurónov.

1.5.4 Viacvrstvová perceptronová sieť

Najviac používaným typom neurónovej siete (pokiaľ ide o biometriu) je viacvrstvová perceptronová sieť tiež označovaná aj ako MLP (multilayer perceptron net). Ide o doprednú sieť s aspoň jednou skrytou vrstvou a úplným prepojením vrstiev. Pri ich učení sa využíva učenie s učiteľom, pričom sa používa spätné šírenie chyby (tzv. *back-propagation error*). Každý neurón obsahuje nelineárnu aktivačnú funkciu (sigmoidu) a je napojený na všetky neuróny v nasledujúcej vrstve. Táto sieť dokáže klasifikovať aj lineárne neseparovateľné problémy.



Obrázok 23: Schéma MLP siete

Algoritmus spätného šírenia chyby

Kedže ide o algoritmus učenia s učiteľom, každá trénovacia vzorka má k sebe prislúchajúci očakávaný výstup neurónu $d_j(n)$, skutočný výstup z neurónu je $y_j(n)$. Potom odchýlku na výstupe k-teho neurónu je možné vyjadriť ako

$$e_k(n) = d_k(n) - y_k(n) \quad (4)$$

Okamžitá hodnota kvadratickej chyby pre neurón je

$$\frac{1}{2} e_k^2(n) \quad (5)$$

Výsledkom sčítania chýb všetkých výstupných neurónov je suma okamžitých hodnôt kvadratických chýb pre n-tú iteráciu

$$\varepsilon(n) = \frac{1}{2} \sum_{k=1}^V e_k^2(n) \quad (6)$$

Globálnu chybu siete je teda možné vyjadriť nasledovne

$$E = \sum_{p=1}^N \varepsilon = \sum_{p=1}^N \frac{1}{2} \sum_{k=1}^V e_k^2(n) \quad (7)$$

pričom N – počet vzoriek trénovacej množiny, V – počet neurónov výstupnej vrstvy.

Hlavným cieľom učenia je minimalizovať globálnu chybu siete E . Trénovanie (*parametrizácia*) prebieha vo viacerých cykloch, tzv. epochách. V každej epoche sa postupne cez neurónovú sieť prešíri celá postupnosť trénovacích vzoriek, skutočné výstupy sa porovnávajú s očakávanými a podľa odchýlok sa upravujú parametre siete – váhy.

1.6 Aplikácie neurónových sietí v biometrii

Odtlačok prsta predstavuje komplexný obrazový vzor obsahujúci množstvo lokálnych charakteristických znakov (markantov). Globálne vzory sú ľahko rozpoznateľné aj pri nižšej kvalite snímku, čo však neplatí pre lokálne znaky, pre ktoré s klesajúcou kvalitou obrazu stúpa náročnosť ich detekcie. Ďalšou prekážkou v úspešnom a spoľahlivom rozpoznaní odtlačkov je jedinečnosť a drobné rozdiely v obrazoch odtlačkov spôsobené procesom snímania. Odtlačky jedného prsta sa preto automatizovanému systému nemusia javiť ako totožné.

Neurónové siete sú vďaka princípu fungovania silným nástrojom na rozpoznávanie komplikovaných vzorov, a preto sa používajú v biometrii na riešenie vyššie spomínaných problémov. Vďaka schopnosti tolerovať odchýlky do istej miery sú ideálnym nástrojom na klasifikáciu.

1.6.1 Výhody použitia neurónových sietí pri spracovaní odtlačkov prstov

Odtlačok prsta má kvôli fyziologickým zákonostiam na úrovni globálneho vzoru len nízku mieru variability. Globálny vzor teda nadobúda len určitý počet známych tvarov. Na lokálnej úrovni je však už miera variability pomerne vysoká, nakoľko existuje 14 rôznych typov markantov (Marák, P., 2012, str. 39), ktoré sú navyše v odtlačku rôzne orientované a umiestnené. To je dôvodom veľkého nárastu náročnosti porovnávania markantov pre konvenčné metódy. Snaha o zníženie náročnosti vedie k znižovaniu kvality obrazu, čo spôsobuje výskyt falosných znakov a pokles spoľahlivosti. Tomuto problému sa neurónová sieť vyhýba tým, že pracuje s odtlačkom ako celkom.

Schopnosť neurónových sietí učiť sa a prispôsobovať umožňuje pri procese porovnávania správne priradiť aj odtlačky, ktoré sú rôznym spôsobom tvarovo alebo kvalitatívne deformované. Tým, že je neurónovej sieti počas procesu učenia poskytnutá dostatočne rozmanitá vzorka odtlačkov s deformáciami, je sieť pripravená akceptovať aj drobné odchýlky spôsobené procesom snímania či nízkou kvalitou.

Na rozdiel od konvenčných prístupov, pri ktorých je potrebné pri každom porovnávaní aplikovať na porovnávané odtlačky množstvo úprav a normalizácií, použitie neurónovej siete pri porovnávaní je veľmi rýchle. Kritickým a zdĺhavým bodom však je učenie neurónovej siete, kedy je potrebné poskytnúť sieti dostatočne veľkú a rozmanitú vzorku trénovacích dát.

1.6.2 Nasadenie neurónových sietí pri spracovaní odtlačkov prstov

Neurónové siete je možné pri spracovaní odtlačkov aplikovať na niekoľko fáz. Konkrétnie aplikácie budú v nasledujúcej časti popísané tak, ako chronologicky nasledujú v procese spracovania a porovnávania odtlačkov. Ide o 3 fázy: klasifikácia globálneho vzoru, extrakcia zvolených vlastností odtlačku a porovnávanie odtlačkov.

Klasifikácia odtlačkov do tried podľa Level-1 znakov Klasifikácie do tried je veľmi efektívny proces, najmä pri porovnávaní odtlačkov, kedy je výrazne znížený čas prehľadávania databázy. Najčastejšie sa odtlačky klasifikujú podľa globálneho vzoru, teda zaradujú sa podľa Henryho klasifikácie do 5 kategórií: pravá slučka, ľavá slučka, vír a oblúk s deltou a oblúk bez delty. Tieto vzory sú neurónovou sieťou pomerne ľahko rozpoznávané vďaka singulárnym bodom – deltám a jadrám, ktoré sú výrazné vzhľadom na celý odtlačok prstu.

Napríklad Alshemmary, E. N. A. v dokumente *Classification of Fingerprint Images Using Neural Networks Technique* klasifikuje odtlačky podľa Henryho klasifikácie, pričom pri určovaní konkrétneho typu využíva počet a umiestnenie singulárnych bodov. Polohu singulárnych bodov odvodzuje zo smerovej mapy vytvorenej na odtlačku. Autor vykonal trénovanie na 277 vzorkách vybraných z databázy NIST-4, pričom dosiahnutá presnosť klasifikácie do 5 tried dosahovala 92,7 %.

Extrakcia zvolených vlastností odtlačku Extraktia markantov predstavuje popis odtlačku podľa zvolenej množiny znakov, ktoré definujú unikátnosť každého odtlačku. Tieto znaky tvoria väčšinou polohy rozličných usporiadanií a deformácií priebehu papilárnych línii (markanty). Na ich určenie sa používa pomerne komplikovaný systém analýzy odtlačku, ktorý musí brať do úvahy pomerne rozsiahlu variabilitu týchto usporiadanií. Ide o výpočtovo i časovo náročný proces. Neurónové siete sa týmto problémom vyhýbajú, nakoľko rozpoznávanie prebieha na základe vopred naučených podobných vzorov.

Prvým krokom je učenie neurónovej siete na dostatočne rozmanitej vzorke obrazov markantov, ktoré má neurónová sieť rozpoznávať. Dostatočne rozsiahla a variabilná databáza obrazov markantov zaručuje vyššiu citlosť a spoľahlivosť. S rastúcim počtom trénovacích dát samozrejme rastie aj časová náročnosť procesu učenia. Po naučení a adaptácii je sieť pripravená na extrakciu/rozhodovanie. Neurónovej sieti sú posielané bloky požadovanej veľkosti z obrazu odtlačku a tá určuje príslušnosť

markantu k jednej z naučených tried. Príslušnosť je znázorňovaná mierou, s akou sa spracovávaný blok-markant podobá vzorom z danej triedy. Táto miera je reprezentovaná desatinným číslom a práve táto schopnosť určovať mieru je zdrojom tolerancie neurónovej siete voči odchýlkam. Tu je možné vidieť podobnosť neurónových sietí a *fuzzy logiky*, pričom máme na mysli určovanie príslušnosti objektov k triedam.

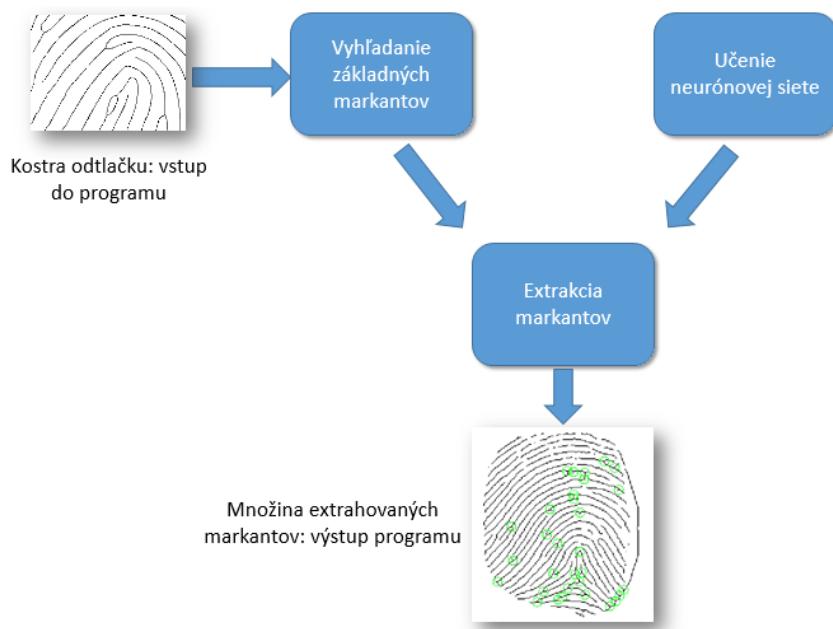
Porovnávanie odtlačkov Pri porovnávaní zhody 2 odtlačkov poskytuje neurónová siet špeciálny systém rozhodovania, na rozdiel od konvenčných prístupov, kde prebieha rozhodovanie na základe pevne stanovených pravidiel. Rozhodovanie neurónových sietí záleží od kvality adaptácie siete na trénovaciu vzorku a od stavu vnútorných parametrov.

Vstupnými dátami pri porovnávaní zhody 2 odtlačkov môžu byť nielen samotné nájdené markanty, ale aj ich poloha vzhľadom na ostatné znaky v odtlačku, ich vzájomná vzdialenosť alebo orientácia. Vychádza sa teda z predpokladu, že markanty už sú z odtlačku extrahované a porovnávanie využíva už zistené informácie. Využitie týchto dodatočných informácií sa obzvlášť hodí pokiaľ sú porovnávané odtlačky neúplné či poškodené.

2 Návrh riešenia

2.1 Fázy riešenia zadania práce

Proces extrakcie charakteristických znakov odtlačkov prstov je komplexný proces po- zostávajúci z viacerých krokov a úloh. Tento proces je veľmi úzko prepojený s procesom predspracovania, pretože úspešnosť extrakcie je do istej miery závislá na kvalite obrazu odtlačku. Táto práca sa však zameriava iba na samotnú extrakciu s využitím neurónových sietí, a preto neobsahuje proces predspracovania a predpokladom pre uspokojivé výsledky sú vstupné dátá – odtlačky prstov v dostatočnej kvalite. Poradie úloh, z ktorých sa samotná extrakcia skladá, sme zvolili na základe rozboru požiadaviek jednotlivých úkonov na vstupné a výstupné dátá. Postupnosť jednotlivých krokov spracuje kostru odtlačku, ktorá je prvotným vstupom do celého procesu, vyhľadá základné markanty, ktorých súradnice sú poskytované natrénovanej neurónovej sieti. Tá následne v miestach určených súradnicami vyhľadáva a rozhoduje o existencii charakteristických znakov. Výstupom je množina súradníc, na ktorých bol zistený určený typ markantov. Zároveň sú tieto nájdené markanty vyznačené v pôvodnom vstupnom obraze odtlačku a vizuálne zobrazené. Na nasledujúcim obrázku je znázornená schéma jednotlivých krokov a ich postupnosť.



Obrázok 24: Schéma modulov programu

Charakteristika jednotlivých krokov procesu extrakcie:

a) **Vyhľadanie základných markantov**

Na detekciu základných charakteristických znakov bol použitý algoritmus *Cross-ing Number*, ktorý je bližšie popísaný v sekcii 1.4.4 a ktorého úlohou bolo nájsť vo zvolenom odtlačku markanty ukončenia a rozdvojenia. Z týchto dvoch znakov je možné zostaviť komplexné markanty, a preto slúžia súradnice ukončení a rozdvojení ako odrazový bod pre neurónovú sieť. Pre lepšiu viditeľnosť sú získané údaje vizuálne zobrazené na zdrojovom odtlačku.

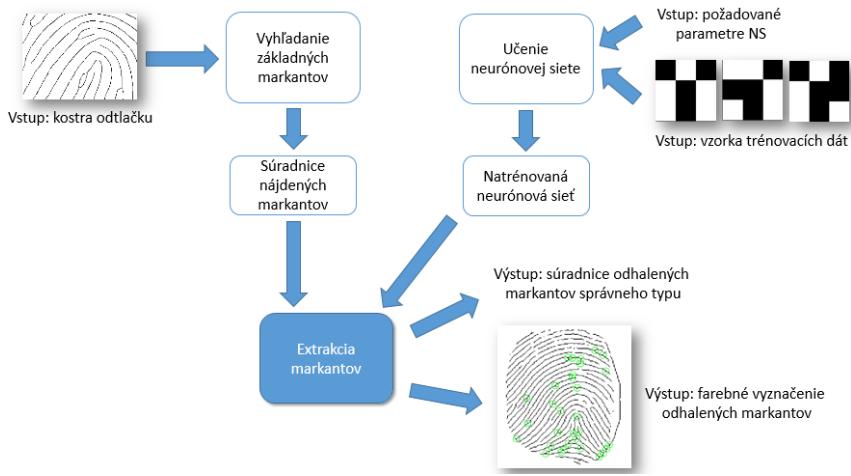
b) **Učenie neurónovej siete**

Ďalším krokom je vytvorenie a trénovanie neurónovej siete na vzorke trénovacích dát zvoleného markantu. Pri tomto kroku sme využili informácie a metódy uvedené v sekcii 1.4, ktoré slúžili ako základ pre nastavenie parametrov neurónovej siete pri jej vytváraní. V tomto kroku si volíme konkrétny typ markantu, ktorý bude neurónová siet vyhľadávať, a tiež množinu dát, na ktorých bude neurónová siet trénovaná. Výstupom tohto kroku je natrénovaná neurónová sieť, pripravená na extrakciu určeného markantu.

c) **Extrakcia markantov**

Ide o finálny krok, kde dochádza k spracovaniu výstupných údajov predchádzajúcich krokov – teda natrénovaná neurónová siet, s využitím súradníc poskytnutých prvým krokom, spracuje vstupnú kostru odtlačku a rozhodne na akých miestach sa hľadaný markant nachádza, prípadne nenachádza. Výstup je opäť pre prehľadnosť vizuálne znázornený.

Program je riešený ako aplikácia s grafickým rozhraním, hlavným spúšťacím súborom je *exe* súbor. Grafické rozhranie je vytvorené s dôrazom na prehľadnosť a vizuálne zobrazenie prebiehajúcich procesov. Pre zvýšenie prehľadnosti je každý z vyššie spomenutých funkčných blokov umiestnený na samostatnú záložku, aby bolo jednoznačne vidieť v akom stave sa program aktuálne nachádza. Vstupom programu je teda kostra odtlačku, na ktorej sú nájdené základné markanty. Následne je podľa zvolených parametrov vytvorená neurónová siet, ktorá je natrénovaná pre určený typ markantu. V ďalšom kroku je takto vytvorená a naučená siet využitá na určenie výskytu hľadaného markantu. Výstupom programu je množina súradníc nájdených markantov a zobrazenie ich umiestnenia priamo v odtlačku. Celkovú architektúru programu je možné vidieť na nasledujúcom obrázku.



Obrázok 25: Schéma procesov navrhnutého softvérového riešenia

Postup pri návrhu riešenia jednotlivých častí zadania je popísaný v kapitole 2.2. Táto kapitola je chronologickým a logickým popisom postupu pri návrhu a vytváraní samotnej implementácie. Vysvetlenie podstatných častí zdrojového kódu je uvádzané priebežne k odpovedajúcim fázam návrhu.

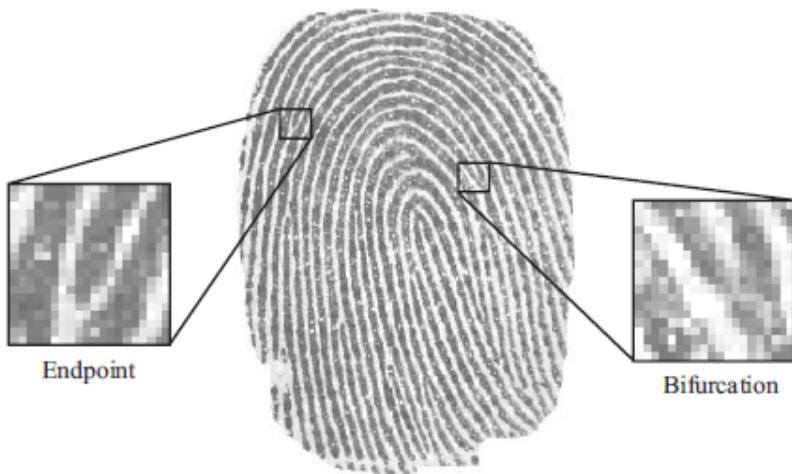
2.2 Proces extrakcie markantov

2.2.1 Detekcia základných tvarov markantov

Pri samotnej extrakcii charakteristických znakov pomocou neurónovej siete nie je fáza vyhľadania markantov ukončenia a rozdvojenia špeciálne potrebná. Dôvod zaradenia tohto kroku na začiatok celého procesu je čo najväčšie možné urýchlenie a optimalizácia procesu extrakcie. Pre vyhľadanie ukončenia a rozdvojenia bol zvolený algoritmus Crossing Number, ktorý je podrobne popísaný v kapitole 1.4.4 pričom na základe týchto informácií bola spomínaná metóda implementovaná. Po načítaní odtlačku postupne algoritmus prechádza každým pixelom ležiacim na papilárnej línií (teda daný pixel je čierny). Následne prebieha kontrola susedných bodov pixelu, výpočet sa riadi vzorcom uvedeným pri popise CN. Výsledok sa vyhodnotí a v prípade, že ide o jeden zo základných markantov, je súradnica pixelu spolu s označením typu markantu uložená do dátovej štruktúry vektor, ktorú bude neskôr neurónová sieť využívať. Po prejdení celého obrazu odtlačku sú podľa uložených súradníc v pôvodnom obraze zvýraznené nájdené markenty. Myšlienkom celého tohto kroku je zredukovať počet blokov obrazu, ktoré bude neurónová sieť spracovávať. Algoritmus CN je rýchly a spoľahlivý spôsob detektie jednoduchých charakteristických znakov, jeho nasadením je významne urýchlená práca neurónovej siete, ktorá tak nemusí kontrolovať každý obrazový bod odtlačku. Vychádzame z predpokladu, že komplexné

markanty je možné zostaviť z markantov ukončenia a rozdvojenia a vhodne zvolenou veľkosťou bloku je možné v okolí základného markantu zachytiť markant komplexný.

Implementácia vyššie popísaného postupu sa nachádza vo funkciách *on_findBtn_clicked()* a *crossingNum(Mat matica)*, pričom parametrom funkcie *crossingNum* je vstupný obraz odtlačku vo forme dátového typu *Mat*, ktorý zabezpečuje knižnica *OpenCV*.



Obrázok 26: Základné markanty
(Bazen, A., 2002, str. 60)

2.2.2 Navrhnutá neurónová sieť a jej trénovanie

Táto fáza programu nijakým spôsobom neovplyvňuje krok vyhľadávania základných markantov, ani na ňom nezávisí, teda nemajú navzájom spoločné vstupy alebo výstupy. Krok vytvorenia a trénoania neurónovej siete je však klúčový pre fungovanie celého programu. Pri návrhu a konštrukcii neurónovej siete sme vychádzali z poznatkov a informácií uvedených v sekcií 1.4. Pre prácu s neurónovými sietami sme použili knižnicu *FANN 2.2.0* (Fast Artificial Neural Network), ktorá umožňuje konfiguráciu a ovládanie mnohých parametrov pri tvorbe a trénovaní. Pri počiatočnom nastavení parametrov neurónovej siete sme vychádzali z poznatkov autorov nasledujúcich vedeckých prác: *Minutiae Extraction from Fingerprint with Neural Network and Minutiae based Fingerprint Verification* a *Neural Network based Minutiae Extraction from Skeletonized Fingerprints* od autora Bartunek, J.S. a *The Study of Adoption of Neural Network Approach in Fingerprint Recognition* od Divyakant, T.M..

Ako hlavná architektúra siete bola zvolená viacvrstvová perceptronová dopredná sieť

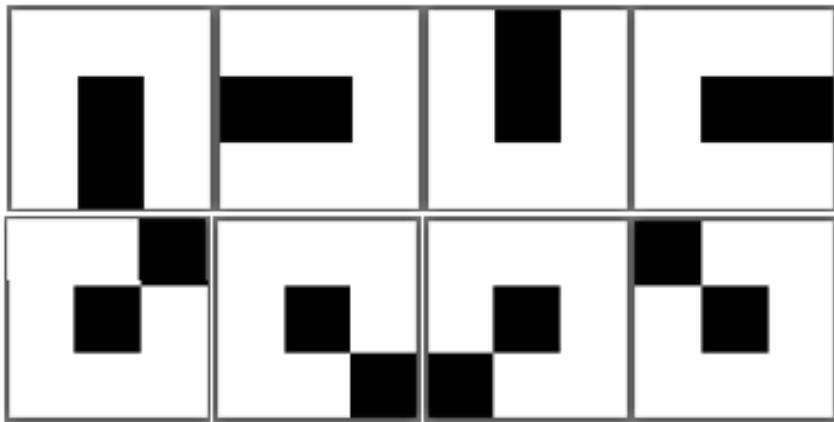
(tzv. *MLP* – Multi Layer Perceptron). Pri voľbe architektúry siete sme vychádzali z poznatkov autorov Guobin Ou a Yi Lu Murphey, ktorí v článku *Multi-class pattern classification using neural networks* popisujú dôvody výberu neurónovej siete typu MLP. Podrobný popis aj s náčrtom architektúry tejto siete je uvedený v kapitole 1.4.4. Za algoritmus učenia bol zvolený algoritmus spätného šírenia chyby (tzv. *Back-propagation error*), ktorého popis a princíp fungovania je taktiež uvedený v kapitole 1.4.4.

Prvým krokom pri konštrukcii neurónovej siete je výber markantu, na ktorý chceme neurónovú sieť naučiť. Každému markantu sme pevne priradili veľkosť bloku, ktorá určuje rozmery testovacích dát, čo ma priamy vplyv na počet neurónov vstupnej vrstvy. Vyčádzame z myšlienky, že každý neurón vstupnej vrstvy predstavuje 1 pixel spracovávaného obrazu. Teda hodnota veľkosti bloku znamená, že vstupná vrstva bude mať (veľkosť bloku)² neurónov. V prípade markantov ukončenia a rozdvojenia je veľkosť bloku 3, z toho vyplýva, že vstupná vrstva bude mať 9 neurónov.

Ďalším krokom je výber počtu vrstiev/skrytých vrstiev neurónovej siete. V tejto práci uvažujeme a používame len neurónové siete s jednou alebo dvomi skrytými vrstvami. Počet neurónov skrytej vrstvy nie je ničím obmedzovaný a jeho hodnota závisí na používateľovi. Odborníci nedokážu presne určiť vhodný počet neurónov, nakoľko to silne závisí na konkrétnej situácii, existuje však niekoľko akceptovaných spôsobov výpočtu. V tejto práci využívame tzv. *Kolmogorov teorém*, ktorý hovorí, že počet neurónov skrytej vrstvy by mal byť $(2^*N + 1)$, pričom N predstavuje počet neurónov vstupnej vrstvy 9 (Honglong, Ch., 2012, str. 409).

Posledné dva parametre – požadovaná maximálna chyba a maximálny počet epoch trénovania predstavujú ukončovacie podmienky algoritmu trénovania. V prípade splnenia aspoň jednej z týchto dvoch podmienok je proces trénovania ukončený.

Pred samotným trénovaním je ešte potrebné vybrať umiestnenie dát, na ktorých bude neurónová sieť trénovaná. Tieto dáta sú tvorené množinou obrazov, ktoré obsahujú zvolený typ markantu v rôznych jeho tvarových variáciách a orientáciách. Na nasledujúcich obrázkoch je znázornená množina dát pre markant ukončenia.



Obrázok 27: Množina dát pre učenie NS na markant ukončenia

Ako sme už spomínali, konkrétnie markant ukončenia je možné jednoznačne určiť na bloku veľkosti 3×3 pixely. V prípade komplexnejších markantov je však potrebné, aby bola veľkosť bloku oveľa väčšia. V našom prípade bola veľkosť bloku určená vzhľadom na vzorky dát, ktoré sa podarilo získať výrezom jednotlivých markantov z odtlačkov prstov. Treba zdôrazniť, že pri tejto práci sme pracovali so snímkami v rozlíšení 1000 dpi.

Zvolená množina dát je postupne načítavaná a prevádzaná do formátu, s ktorým dokáže neurónová sieť s podporou FANN knižnice pracovať. Po ukončení procesu vytvárania súboru pre trénovanie, je neurónová sieť, s využitím funkcií poskytovaných knižnicou FANN, trénovaná a po skončení procesu je táto sieť uložená vo forme konfiguračného súboru na pevný disk.

Vyššie opísaný postup je implementovaný v niekoľkých funkciách. Hlavnými funkciami sú *fann_create_standard()*, ktorá zabezpečuje vytvorenie neurónovej siete podľa zadaných parametrov, *fann_train_on_data()*, ktorá uskutočňuje trénovanie neurónovej siete. Obe spomenuté funkcie sú súčasťou FANN knižnice.

2.2.3 Extraktie markantov neurónovou sieťou

Táto fáza programu predstavuje jadro celej práce a na svoju činnosť využíva výstupy predchádzajúcich dvoch častí. Teda vstupom tejto fázy je zvolený odtlačok prstu, súradnice základných markantov na tomto odtlačku a sieť natrénovaná na typy markantov, ktoré požadujeme extrahovať.

Prvým dôležitým procesom tejto fázy je načítanie natrénovanej neurónovej siete, ktorá je výsledkom predchádzajúcej fázy. Treba zdôrazniť, že výber konkrétnej neurónovej siete záleží na zvolenom type markantu. Pre načítanie siete sme využili funkciu, ktorú

poskytuje FANN knižnica - *fann_create_from_file()*, atribútom tejto funkcie je názov konfiguračného súboru neurónovej siete. Po úspešnom zostavení siete podľa konfiguračného súboru, sú na základe súradníc získaných z prvej fázy, postupne zo vstupného obrazu odtlačku prstu vyberané bloky. Veľkosť týchto blokov závisí na type markantu, na ktorom bola neurónová sieť trénovaná. Teda napríklad v prípade markantu ukončenia ide o blok veľkosti 3x3 pixely. Treba poznamenať, že jednotlivé súradnice vždy predstavujú stred konkrétneho bloku. Samotné súradnice sú ešte pred získaním bloku filtrované na základe typu sledovaného znaku. Ako príklad môžeme uviesť komplexný markant jazero, ktoré je tvorené len 2 markantami rozdvojenia, a teda ukončenia nie sú pri získavaní blokov vôbec využívané.

Po určení bloku sú hodnoty jeho pixelov postupne načítané do vektora, ktorý je vstupom do neurónovej siete. Tá spomínaný vektor spracuje a vráti výsledok, ktorý predstavuje odpoveď siete. Odpovedou siete je určenie, do akej triedy markant nachádzajúci sa na kontrolovanom bloku patrí. V prípade, ak ide o pozitívnu odpoveď, teda bol odhalený charakteristický znak, na ktorý bola NS trénovaná, je súradnica jeho pozície uložená do štruktúry *detected_minutiae*, ktorá je výstupom celého programu. Na základe súradníc z tejto štruktúry sú v skúmanom odtlačku farebne vyznačené odhalené markanty, pričom tento proces je v aplikácii adekvátne vizualizovaný.

2.3 Prostriedky využité pri implementácii riešenia

Celé zadanie, všetky algoritmy i grafické rozhranie boli implementované vo vývojovom prostredí *Qt Creator 3.2.1*, ktoré ponúka vhodné prostriedky a možnosti pre tvorbu aplikácie s užívateľským rozhraním. Práve toto bolo motiváciou k využitiu tohto prostredia, pri tejto práci sme kládli na vizualizáciu výsledkov a čiastočných výstupov značný dôraz. Pre prácu s obrazmi odtlačkov prstov sme využívali možnosti knižnice *OpenCV 2.4.1*, ktorá je zameraná na prácu a spracovanie obrazových dát a poskytuje široké možnosti. Ako príklad môžeme uviesť triedy *Mat*, prípadne *QPixmap*, ktoré sme pri implementácii využívali.

Pre kľúčovú časť zadania, vytvorenie a ovládanie neurónovej siete, sme si zvolili knižnicu *FANN 2.2.0*, ktorej metódy a funkcie nám poskytli všetky potrebné prostriedky pre spravovanie neurónových sietí, od ich vytvorenia, trénovania, až po ich testovanie, či vytváranie vzorky dát pre trénovanie.

Obe vyššie spomínané knižnice sú napísané v jazyku C++ a aj z tohto dôvodu bol programovací jazyk C++ použitý pri implementácii a vytváraní aplikácie.

Obrázky odtlačkov, ktoré sme v tejto práci používali boli vo formáte BMP, v rozlíšení 1000 dpi. Motívaciou výberu tohto formátu bolo zachovanie kvality obrázkov a udržanie striktne binárnych hodnôt jednotlivých pixelov, čo by nebolo možné dosiahnuť pri niektorých kompresných formátoch.

Operačným systémom, v ktorom prebiehala implementácia i ostatné činnosti súvisiace s touto prácou bol Windows 7 Professional 64-bitová verzia.

3 Zhodnotenie dosiahnutých výsledkov

3.1 Splnenie cieľov teoretickej časti práce

Úlohou teoretickej časti tejto práce bolo oboznámenie s oblasťou biometrie, objasnenie základných pojmov a predstavenie pozadia problému, ktorému sa táto práca venuje. Časť 1.2 ponúka základné informácie o biometrii, jej súčasnou postavení v oblasti informačnej bezpečnosti a systémoch, kde je biometria týkajúca sa odtlačkov prstov používaná. Ďalej je v časti 1.2 stručne zhrnutá história a vývoj odtlačku prstu, metódy pre získavanie odtlačkov a taktiež spôsoby úpravy obrazu za účelom zlepšenia kvality. Časť 1.3 sa bližšie venuje charakteristickým znakom, ktoré môžeme v odtlačkoch prstov nájsť a ktoré sú pre proces rozpoznávania identity osôb klúčové. Špeciálne sme sa zamerali na charakteristické znaky 2. úrovne, inak nazývané aj markanty, ktorých hľadanie v odtlačkoch prstov je motiváciou tejto práce. Sekcia 1.4.4 obsahuje popis algoritmu CN pre vyhľadávanie základných markantov, pričom tento algoritmus sme využili aj v implementačnej časti tejto práce. Našu pozornosť sme sústredili na neurónové siete, ktorých popis sa nachádza v časti 1.5. Táto sekcia obsahuje charakteristiku neurónových sietí, popis štruktúry a základných stavebných prvkov, vysvetluje princípy učenia neurónovej siete. Pozornosť ďalej sústredujeme na postavenie a využitie neurónových sietí v biometrii a ich výhody voči konvenčnému prístupom. V závere sekcie 1.5 sa venujeme rôznym spôsobom využitia NS v rôznych fázach spracovania odtlačkov prstov. Princípy a metódy popísané v tejto časti boli základom pri implementovaní riešenia.

Kapitola 2 uvádzá podrobný popis krokov návrhu a implementácie riešenia. Časť 2.1 rozdeľuje riešenie zadania na 3 fázy, ktoré sú následne v časti 2.2 podrobne popísané. V tejto sekcií sú vysvetlené dôvody zvoleného postupu a výber použitých metód. Posledná časť tejto kapitoly, sekcia 2.3 je venovaná popisu prostriedkov, ktoré sme pri tejto práci využili a taktiež odôvodňuje použitie zvolených nástrojov.

3.2 Splnenie cieľov praktickej časti práce

Výsledkom praktickej časti zadania tejto práce je implementovaný softvér – aplikácia s grafickým rozhraním, ktorej úlohou je s využitím neurónovej siete vyhľadať v odtlačku prstu jednotlivé markanty podľa výberu. Vytvorená aplikácia sa skladá z 3 častí, ktoré sú v programe vizuálne odlišené. Úlohou prvého modulu je v kostre odtlačku prstu lokalizovať jednoduché markanty a ich súradnice pozícií zaznamenať. Kostra odtlačku je tvorená len čiernymi a bielymi pixelmi, kde čierne čiary predstavujú papilárne línie

zúžené na hrúbku 1 pixel. Činnosťou druhého modulu je vytvorenie, konfigurácia a učenie neurónovej siete na vzorke poskytnutých dát. Učenie neurónovej siete sa zameriava na konkrétny markant podľa výberu. Tento modul produkuje veľmi dôležitý prvok – neurónovú sieť naučenú na špecifikovaný charakteristický znak. Tretí modul zabezpečuje extrakciu zvoleného markantu, pričom využíva výstupy z predchádzajúcich modulov. Metódy a postupy, ktoré sme použili sú popísané v častiach 1.4 a 1.5. Detaily implementácie popisuje časť 2.2.

3.2.1 Funkcionalita

Vytvorená aplikácia ponúka nasledujúce možnosti:

- načítanie a vizualizácia zvoleného obrázku
- detekcia základných markantov pomocou CN, vizualizácia výstupu
- konfigurácia parametrov neurónovej siete
- výber databázy trénovacej vzorky
- učenie neurónovej siete
- testovanie NS na zvolenom odtlačku
- vizualizácia výstupov

3.2.2 Možnosti užívateľskej interakcie

Pri vytváraní aplikácie a jej grafického rozhrania sme kládli dôraz na prehľadnosť a vizualizáciu výsledkov. Snahou bolo navrhnúť rozloženie jednotlivých komponentov grafického rozhrania tak, aby bol význam každého ovládacieho prvku jednoznačný a pre používateľa zrozumiteľný.

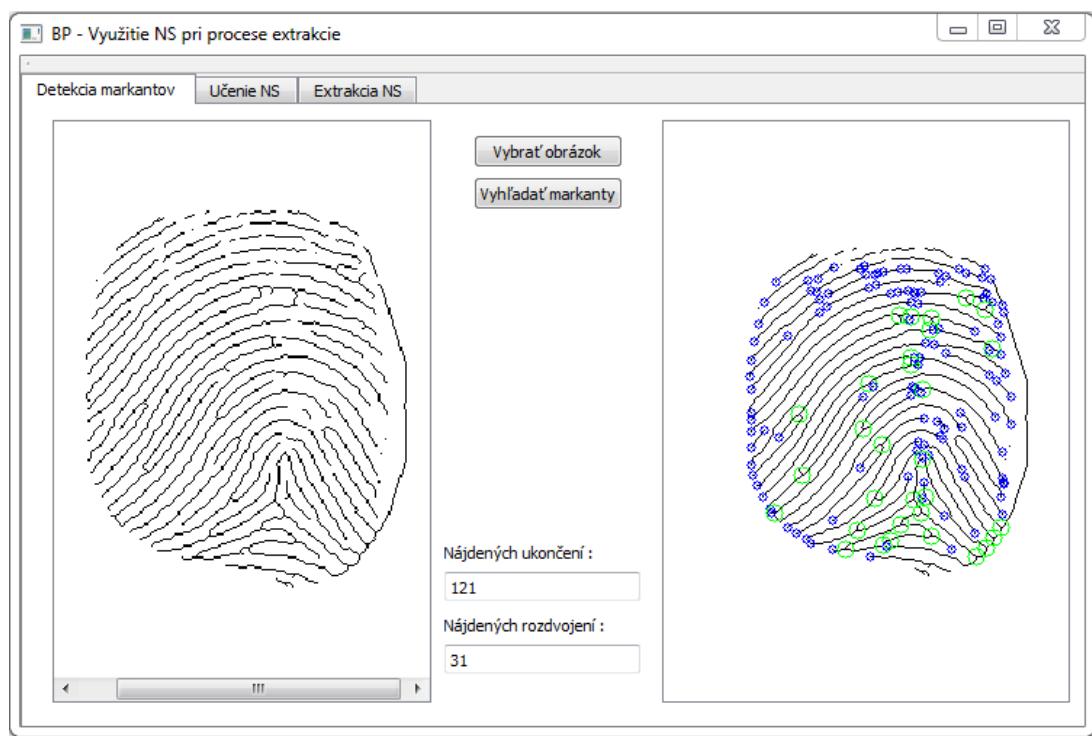
Ako sme už spomínali v predchádzajúcich kapitolách, činnosť aplikácie delíme na 3 hlavné procesy, ktoré sú viditeľne oddelené aj v rozhraní, pričom každý krok sa nachádza na samostatnej záložke. V nasledujúcej časti predstavíme grafické rozhranie a popíšeme jeho ovládacie prvky.

Prvou záložkou je ***Detekcia markantov***.



Obrázok 28: Detekcia markantov - zobrazenie zvoleného odtlačku

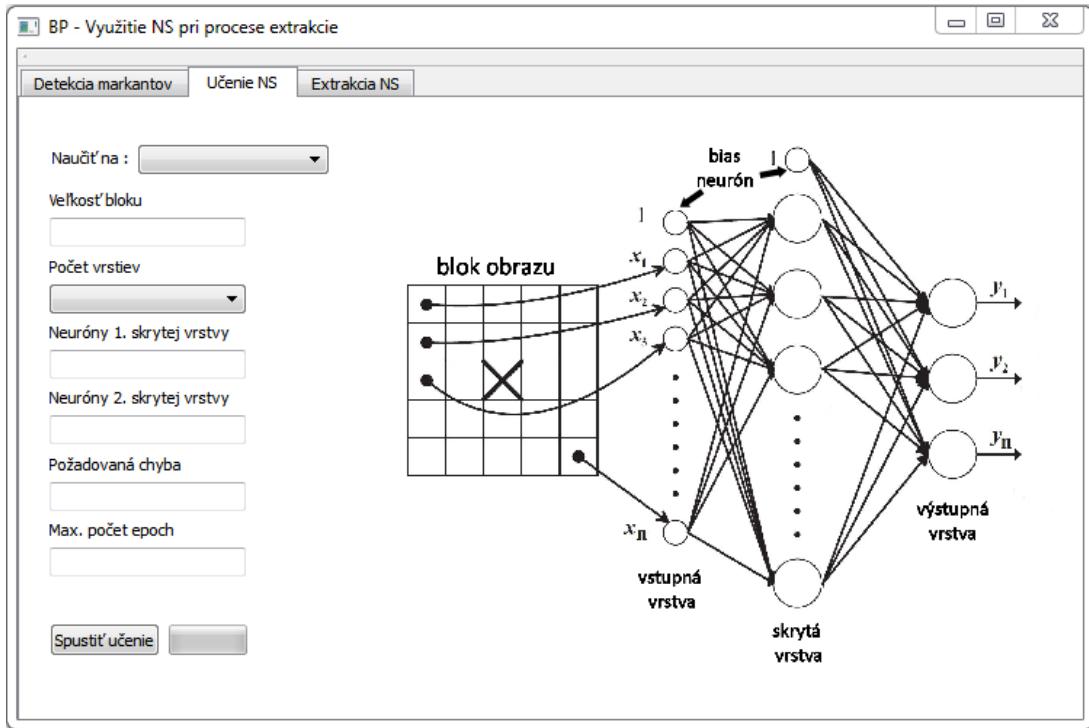
Na predchádzajúcom obrázku môžme vidieť ako vyzerá úvodné okno aplikácie. V ľavom hornom rohu je umiestnené prepínanie medzi jednotlivými krokom procesu extrakcie. Tejto záložke dominujú dva boxy pre zobrazenie odtlačkov prstov, pričom box naľavo slúži na zobrazenie odtlačku, ktorý z umiestnenia na pevnom disku zvolil používateľ. V pravom boxe sa zobrazuje totožný odtlačok, v ktorom sú však graficky zvýraznené identifikované základné markanty. V strednej časti medzi boxami sú v hornej časti umiestnené dve tlačidlá. Tlačidlo *Vybrať obrázok*, ako už názov napovedá, slúži na výber odtlačku. Po stlačení tohto tlačidla sa zobrazí klasické okno prehliadača obsahu pevného disku, ktoré umožňuje vybrať a potvrdiť súbor odtlačku. Pri prehliadaní obsahu pevného disku sú zobrazované iba akceptovateľné typy súborov, teda len s príponou BMP. Stlačením tlačidla *Vyhľadať markanty* je na zvolenom odtlačku aplikovaný algoritmus Crossing Number. Výstupom tohto kroku je vizualizácia nájdených základných markantov v pravom boxe, pričom v spodnej časti stredového panelu je zobrazený ich počet.



Obrázok 29: Detekcia markantov - aplikovanie Crossing Number

Je potrebné poznamenať, že v oboch boxoch je možné zobrazované odtlačky ľubovoľne približovať/oddalaovať a posúvať podľa potreby.

Druhou záložkou je ***Učenie NS***.



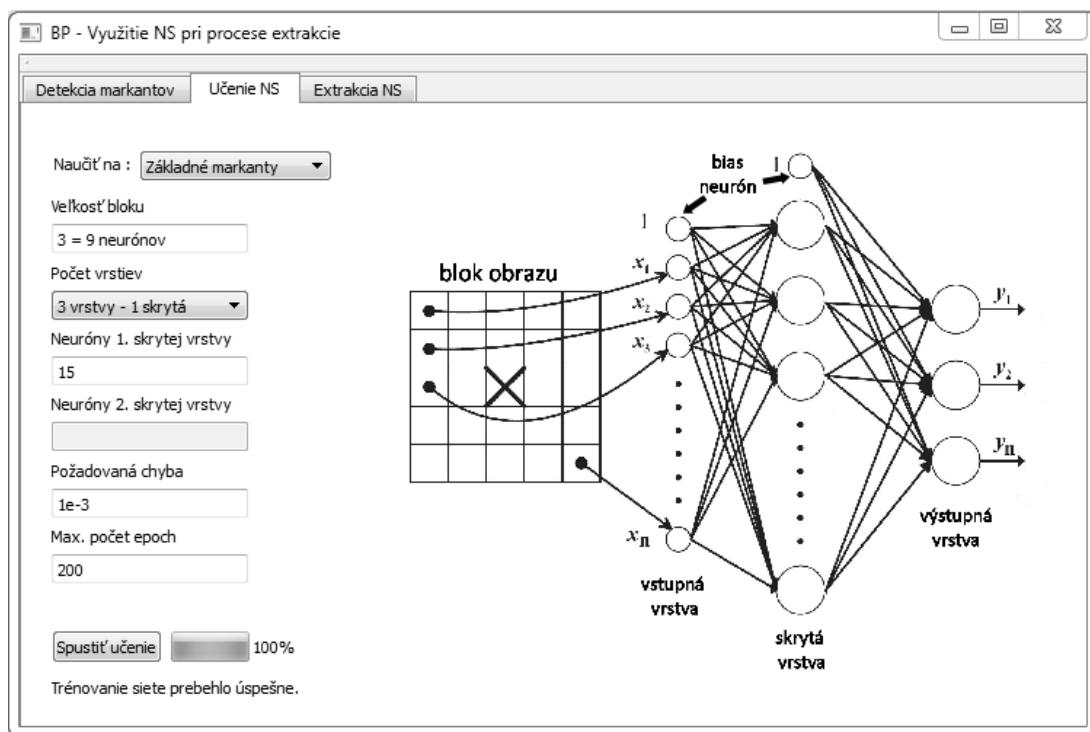
Obrázok 30: Učenie neurónovej siete

Tento modul zabezpečuje konfiguráciu, vytvorenie a učenie neurónovej siete. Ako môžeme vidieť na predchádzajúcom obrázku používateľ musí pre vytvorenie fungujúcej NS zadať 5 rôznych parametrov. Prvým z nich je výber typov markantov, na ktoré chceme neurónovú sieť učiť. Pre výber tohto parametra sme použili tzv. *ComboBox*, ktorý po kliknutí zobrazí ponuku *Základné markanty* a *Komplexné markanty*. Po výbere tohto parametra je automaticky zobrazená veľkosť bloku potrebná pre vytvorenie a učenie NS na danú skupinu markantov. V predchádzajúcich častiach práce sme vysvetlili, že pre detekciu základných markantov (rozdvojenie, ukončenie) nám postačujú bloky obrazu veľkosti 3×3 pixely. Komplexné markanty však nie je možné na bloku 3×3 rozpoznať, a preto je pre ich detekciu potrebný blok s väčšími rozmermi. Z tohto vyplýva, že pre extrakciu používame 2 rozdielne neurónové siete, jednu pre základné a jednu pre komplexné markanty.

Následne má používateľ možnosť výberu počtu vrstiev neurónovej siete. Uvažujeme len NS s 1 alebo 2 skrytými vrstvami. Podľa volby používateľa sa aktivuje/deaktivuje riadok pre zadanie počtu neurónov 2. skrytej vrstvy. Určenie počtu neurónov sme opisovali v kapitole 2.2.2, kde sme uvádzali Kolmogorov teorém, avšak testovaním sme zistili, že častokrát nie je potrebný tak vysoký počet neurónov skrytej vrstvy. Ide najmä o prípady

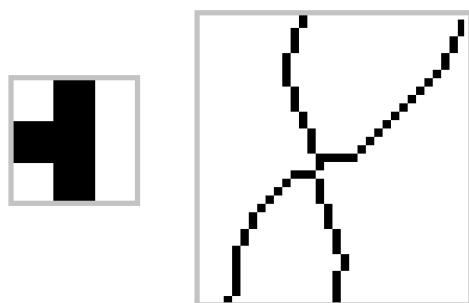
kedy pracujeme s pomerne veľkým blokom obrazu, kde napríklad pri bloku veľkosti 70x70 pixelov, dosahuje počet neurónov vstupnej vrstvy číslo 4900. Po aplikovaní teóremu by mala mať skrytá vrstva teda 9801 neurónov čo je z hľadiska časových a výpočtových nárokov skutočne vysoké číslo. Zistili sme, že dodržiavanie Kolmogorovho teóremu nemá v našom prípade vplyv na úspešnosť extrakcie, a preto sme z dôvodu optimalizácie pracovali s menším počtom neurónov skrytej vrstvy.

Posledné dva parametre predstavujú tzv. zastavovacie podmienky procesu učenia. Prvým z nich je požadovaná maximálna chyba, druhým je maximálny počet cyklov učenia - tzv. epoch.



Obrázok 31: Učenie neurónovej siete - príklad konfigurácie

Po zadaní všetkých potrebných parametrov je po stlačení tlačidla *Spustiť učenie* používateľ požiadany o určenie umiestnenia dát potrebných pre proces učenia. Po výbere priečinka prebehne vytvorenie NS a jej učenie na zvolených dátach. O úspešnosti tohto procesu je používateľ informovaný. Natréovaná NS je vo forme konfiguračného súboru uložená na pevný disk.

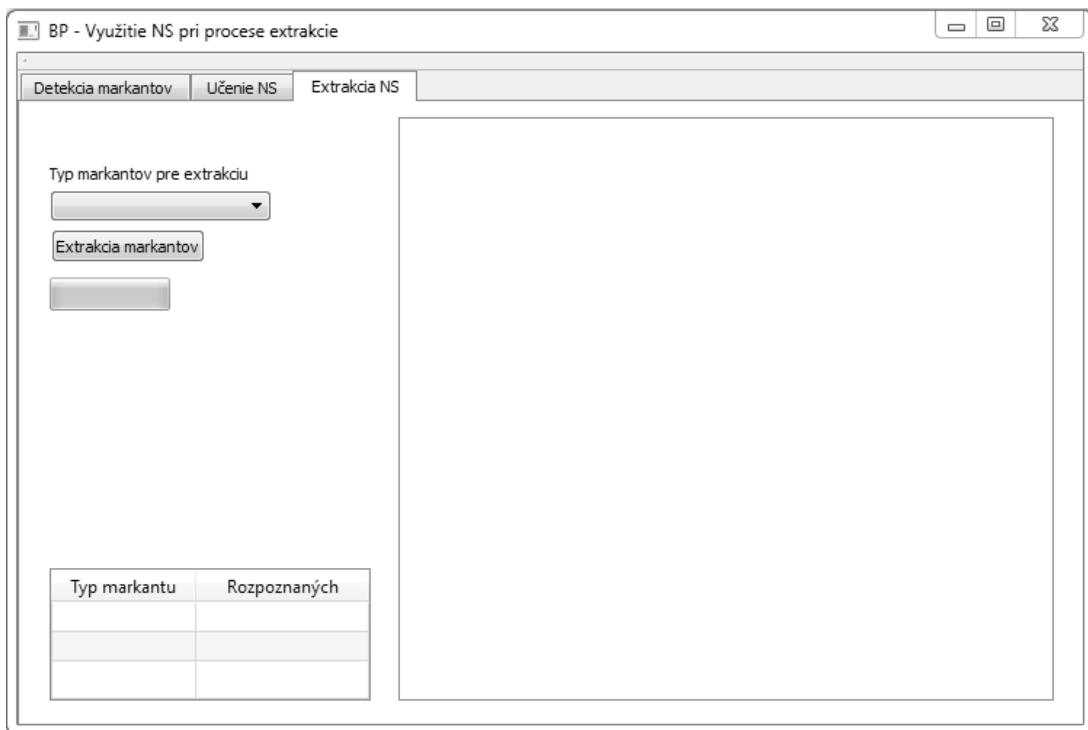


Obrázok 32: Príklad dát pre učenie neurónovej siete

Nalavo: rozdvojenie(niekolkoľoknásobne priblížené) - rozmery 3x3 pixely

Napravo: protiľahlé rozdvojenie - rozmery 35x35 pixelov

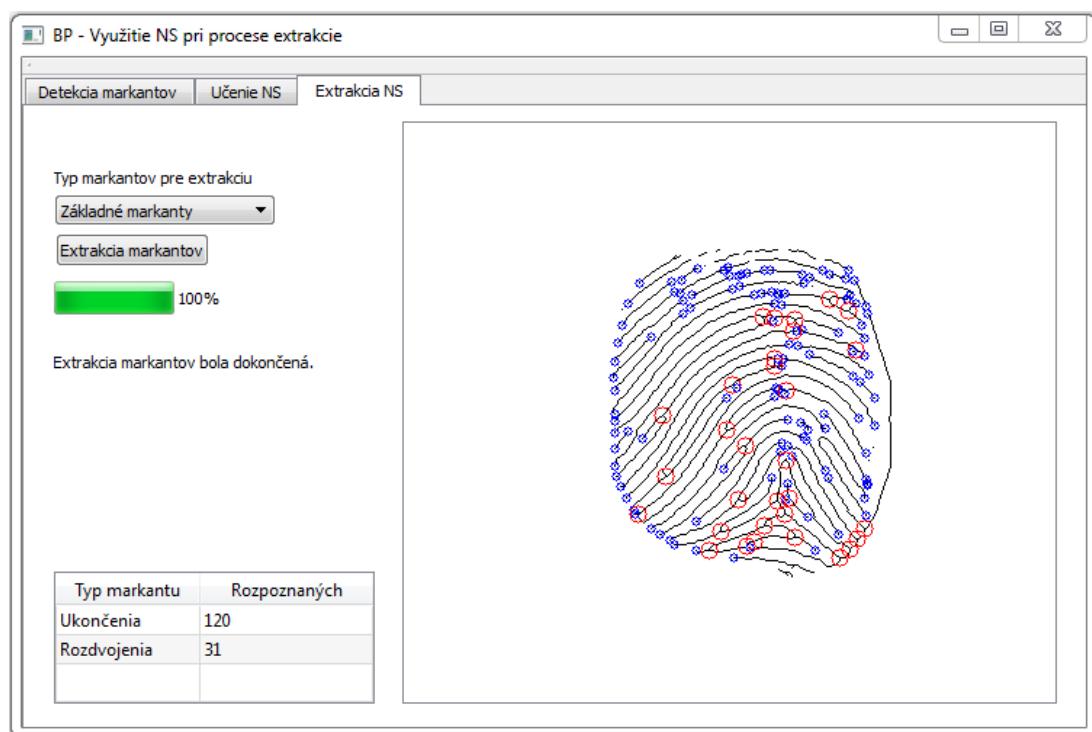
Poslednou záložkou je ***Extrakcia NS.***



Obrázok 33: Extrakcia NS

Na predchádzajúcom obrázku môžme vidieť poslednú záložku aplikácie. Tá predstavuje jadro celej práce a tým je extrakcia markantov z odtlačkov prstov pomocou neurónovej siete. V tomto kroku je od používateľa požadovaná voľba typu charakteristických znakov, ktoré chce extrahovať. Následne po stlačení tlačidla *Extrakcia markantov* prebehne proces, pričom sa použije odtlačok, ktorý bol vybraný na prvej záložke. Treba však zdôrazniť, že aby mohol tento proces prebehnúť, musí byť na prvej záložke zvo-

lený a načítaný odtlačok prstu a zároveň musí existovať NS natrénovaná na požadovaný typ markantov. V prípade nesplnenie týchto podmienok je používateľ upozornený informačnými správami a program nevykonáva žiadnu činnosť. Pokial sú obe vyššie spomenuté podmienky splnené, prebehne extrakcia, pričom používateľ je o stave tohto procesu informovaný tzv. *ProgressBar*-om. Extrahované markenty sú následne vizuálne zobrazené do pôvodného obrazu odtlačku ako môžeme vidieť na nasledujúcom obrázku.



Obrázok 34: Extrakcia NS - zobrazenie výstupu

Z predchádzajúcich odstavcov tejto kapitoly môžme vidieť, že záložky jednotlivých krokov postupu sú úmyselne chronologicky zoradené. Aj keď postupnosť prvého a druhého kroku nie je nevyhnutná, krok 3 - teda samotnú extrakciu je potrebné vykonávať až nakoniec, pretože pre správne fungovanie potrebuje výstupy zo zvyšných dvoch čiastkových procesov. Odporúčaná chronologicky zoradená postupnosť krokov je znázornená na nasledujúcej schéme.

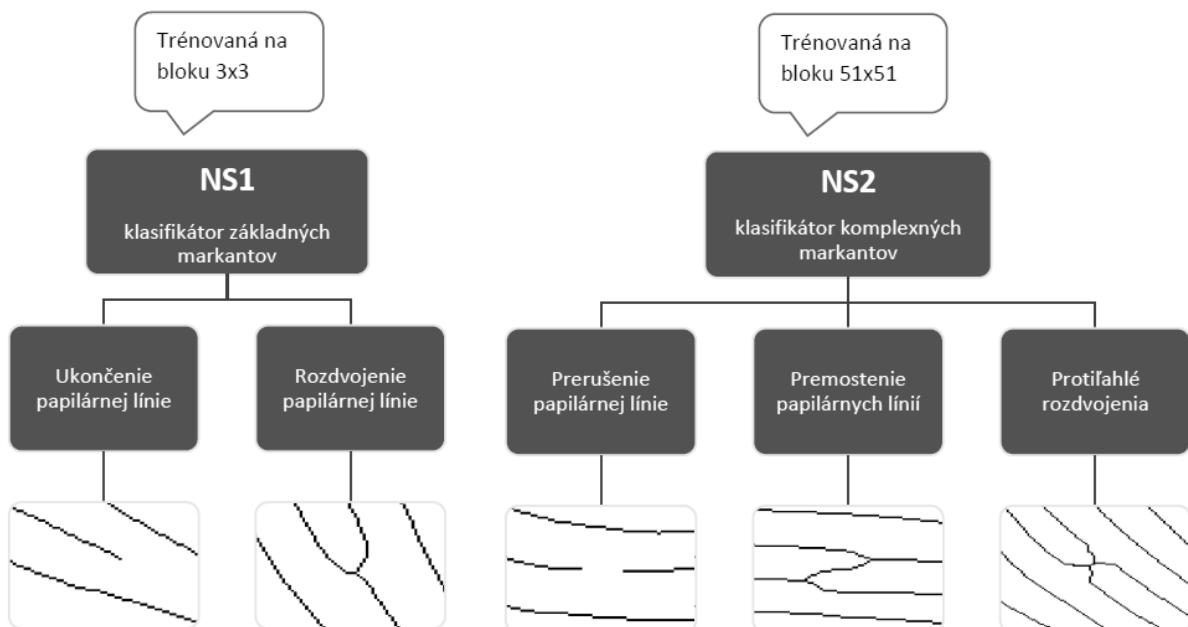


Obrázok 35: Schéma odporúčaného postupu pri práci s aplikáciou

3.2.3 Dosiahnuté výsledky extrakcie markantov

Ako sme už v predchádzajúcich častiach práce spomínali, práca s neurónovými sietami, ktorých vstupné a skryté vrstvy majú vysoký počet neurónov (v tisícoch), je časovo a výpočtovo náročná. Preto sme sa v tejto práci snažili sústrediť na komplexné markanty, ktoré je možné rozpoznať v menších blokoch. Prvým problémom pri získavaní obrazových vzoriek pre učenie siete teda bol rozmerový limit pre blok.

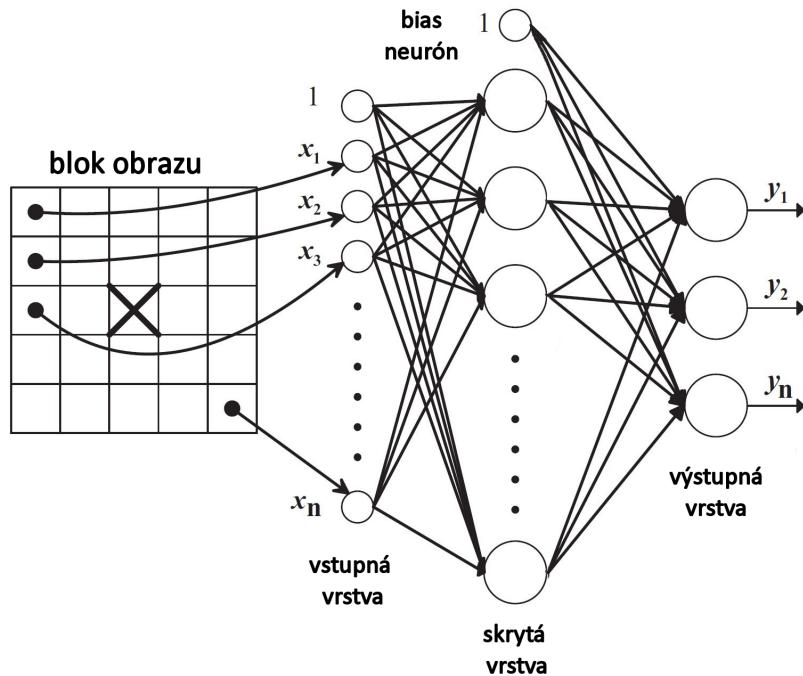
Ďalšou prekážkou pri napĺňaní databázy pre učenie bola strata charakteristických znakov pri transformácii z reálneho obrazu odtlačku do kostry. Pri tvorbe tejto práce sme kostry získvali spracovaním reálnych odtlačkov, kde boli odborníkom vopred vyznačené jednotlivé markanty. Následne sme na daných vyznačených miestach vyrezali bloky z kostry. Mnohokrát však došlo počas transformácie k odstráneniu hľadaného markantu a v kostre odtlačku teda už spomínaný znak neexistoval. Na základe tohto môžeme povedať, že samotný proces extrakcie je veľmi silno závislý a do istej miery limitovaný procesom predspracovania.



Obrázok 36: Použité neurónové siete
(s príslušnými klasifikovanými markantami)

V našom riešení sme pre extrakciu základných a komplexných markantov používali 2 samostatné neurónové siete. Jedna sieť sa používa pre základné - ukončenie a rozdrojenie, druhá pre komplexné. Tento spôsob riešenie je potrebný z dôvodu rozdielnej veľkosti blokov na vstupe neurónovej siete. Rozdiel medzi týmito dvomi sieťami je teda v počte neurónov vstupnej a skrytej vrstvy. Vznikli teda 2 rozdielne konfigurácie. Niektoré z parametrov však mali obe siete totožné. Ide predovšetkým o metódu učenia, ktorou bolo Back-Propagation a aktivačné funkcie, ktoré boli pre vstupnú i skrytú vrstvu nastavené na symetrickú sigmoidu (v našej práci označovaná aj ako hyperbolický tangens).

Výstup NS tvorí vektor hodnôt, pričom každá z nich predstavuje jednu zo skupín, do ktorých NS zatrieduje. Počas procesu učenia je ku každej vzorke priradená pre správny typ markantu hodnota 1, pre ostatné triedy je nastavená -1 . Pri vyhodnocovaní týchto výstupov sledujeme, ktorá z hodnôt vektora sa najviac blíži k 1. Kedže NS poskytuje mieru s akou patrí spracovaný vstup do konkrétnej triedy, sú výstupy väčšinou tvorené desatininnými číslami a je teda na nás, aby sme určili prah, ktorý nám určí či vstup do danej triedy patrí/nepatrí.

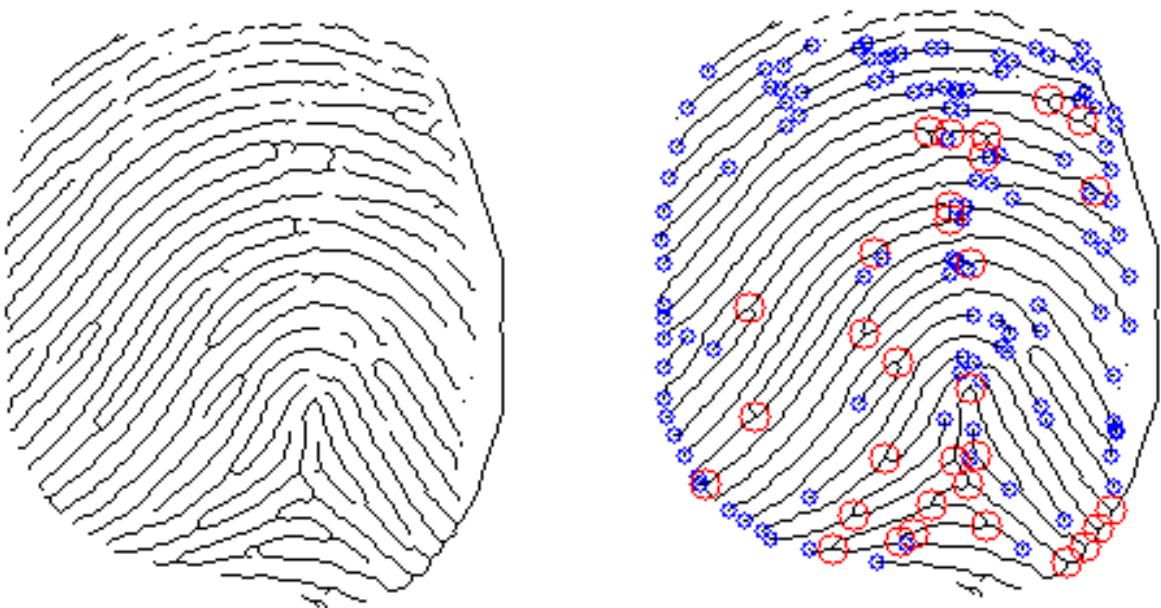


Obrázok 37: Všeobecná konfigurácia použitej NS

Neurónová sieť pre **základné markanty**

Pre extrakciu týchto markantov sme používali NS s nasledovnou konfiguráciou. Keďže vstupom bol blok s veľkosťou 3×3 , teda 9 pixelov, pričom každý pixel je privedený na samostatný neurón, vstupná vrstva obsahovala 9 neurónov. Používali sme 1 skrytú vrstvu, ktorá pozostávala z 15 neurónov. Počet týchto neurónov môže používateľ samozrejme zvýšiť, avšak počas nášho testovania nemala väčšia skrytá vrstva žiadny vplyv na výsledok. Preto sme sa aj z hľadiska optimalizácie a rýchlosťi výpočtov rozhodli pre túto hodnotu. Pokial ide o výstupnú vrstvu, tá obsahovala 2 neuróny, keďže určujeme do 2 tried - ukončenie, rozdvojenie. Celkovo teda NS pozostávala z 28 neurónov - 9 vstupných, 15 skrytých, 2 výstupné + 2 bias neuróny(po jednom vo vstupnej a skrytej vrstve). Sieť mala dohromady 182 prepojení medzi neurónmi. Môžeme si všimnúť, že toto číslo je v porovnaní s počtom prepojení druhej NS pomerne malé, práve tu sa totiž prejavuje vplyv veľkosti bloku. Parameter požadovanej maximálnej chyby sme testovaním určili na hodnotu 1.10^{-3} . Rozhodovací prah pri analýze výstupov sme pre túto sieť nastavili na hodnotu 0.9, teda ak pre nejakú triedu markantov je výstup z NS väčší ako 0.9, je vstup do tejto triedy zaradený.

Na nasledujúcich obrázkoch sú znázornené výsledky extrakcie základných markantov z odtlačku prstu. Obrázok naľavo predstavuje vstupný odtlačok, obrázok napravo zobrazuje výstup, pričom sú v ňom vyznačené neurónovou sieťou rozpoznané markanty. Modré značky predstavujú ukončenia, červené sú zas rozdvojenia. Prípadný rozdiel počtu rozpoznaných základných markantov medzi CN a neurónovou sieťou je spôsobený stavom, kedy NS nedokázala dostatočne jednoznačne určiť o aký charakteristický znak ide a teda nebola prekročená prahová hodnota výstupu. Túto situáciu by bolo možné riešiť znížením prahovej hodnoty, čo by ale mohlo hlavne v prípade komplexných markantov viesť k falošnému rozpoznaniu. Lepším riešením by mohlo byť rozšírenie databázy dát pre učenie o ďalšie možné tvarové a pozičné variácie markantov.



Obrázok 38: Extraktia základných markantov
(vľavo: skúmaný odtlačok, vpravo: extrahované markanty)

Neurónová sieť pre **komplexné markanty**

Z kategórie komplexných markantov sme sa rozhodli v tejto práci zameriť na 3 typy: prerušenie, premostenie a protiľahlé rozdvojenie. Výber práve týchto charakteristických znakov bol podmienený dvomi hlavnými prekážkami, ktoré sme museli do istej miery prekonáť.

Prvým dôvodom je pomerne náročné získanie vzoriek trénovacích dát z kostier odtlačkov. Mnohé filtre používané pri procese predspracovania odtlačkov tieto markanty vyhľadáva a odstránia, teda v kostre sa už nenachádzajú. Boli sme preto limitovaní dostupnými kostrami odtlačkov. Ďalším negatívom je nízka početnosť komplexných markantov v odtlačkoch, čo ešte viac zvyšuje ich vzácnosť výskytu v kostrách.

Druhým hlavným dôvodom je veľkosť bloku obrazu, v ktorom dokážeme tieto markanty identifikovať. Ako sme už spomínali, s rastúcou veľkosťou bloku, prudko rastie aj výpočtová a časová náročnosť. Preto bolo našou snahou vybrať tie znaky, ktoré je možné identifikovať na čo najmenšej časti odtlačku. Postupným zmenšovaním bloku a filtrovaním markantov sme usúdili, že prerušenie, premostenie a protiľahlé rozdvojenie sú detektovateľné na blokoch podobných rozmerov.

Po testovaní blokov rôznych rozmerov sme usúdili, že jeho najmenšia možná veľkosť, vzhľadom na dostupné vzorky odtlačkov, je 51×51 obrazových bodov. Nepárne číslo je zvolené z dôvodu použitia princípu, kedy je vstupná súradnica markantu centrovana na

stred bloku a okolo tohto stredu je vystrihnutý štvorec. Vzorky určené pre trénovanie i testovanie boli teda tvorené časťami odtlačku tvaru štvorca so stranou dĺžky 51 pixelov. Z tohto údaja môžme odvodiť počet neurónov vstupnej vrstvy neurónovej siete, ktorú sme použili. Vstupná vrstva teda obsahovala 2601 neurónov, čo už je pomerne vysoké číslo. Pokiaľ ide o skrytú vrstvu, použitie Kolmogorovho teorému sme kvôli obmedzeniu zo strany výpočtovej a pamäťovej sily systému nemohli uvažovať. Pre skrytú vrstvu sme po sérii testovaní určili počet neurónov na 3500. Keďže sme rozlošovali medzi 3 typmi markantov, výstupná vrstva obsahovala 3 neuróny. Celkový počet neurónov v sieti teda dosahoval číslo 6106. Keď podobne ako v prípade NS pre základné markanty, spočítame spojenia medzi neurónmi v rámci siete, dostaneme pomerne veľké číslo 9 117 503. Tento značný nárast spojení sa samozrejme prejavil aj časovej náročnosti operácií s NS. Aj pri konfigurácii tejto siete sme nastavili maximálnu povolenú chybu na 1.10^{-3} . Prahové hodnoty sme upravili a nastavili na 0.98.

Pri učení i testovaní sme jasne videli, že rozmery NS sú značne veľké. Ďalším faktorom, ktorý ovplyvnil dĺžku trvania procesu učenia, bol počet trénovacích dát. Pre porovnanie uvedieme 2 prípady. Konfigurácia NS zodpovedala popisu z predchádzajúceho odseku. Pri 56 vzorkách trénovacích dát dosiahol čas učenia hodnotu 3 minúty 54 sekúnd. Keď sme znížili počet vzoriek na hodnotu 44, čas učenia dosahoval 3 minúty 5 sekúnd. Doba extrakcie markantov sa v oboch prípadoch pohybovala v okolí 40 sekúnd.

Po aplikácii natréновanej siete na odtlačky prstov a následnej extrakcii markantov sme analýzou výsledkov dospeli k niekoľkým poznatkom. NS falošne detekovala vysoké číslo komplexných markantov. Skúmaním výstupov sme dospeli k záveru, že situácia je spôsobená 2 skutočnosťami. Prvou z nich je fakt, že komplexné markanty pozostávajú z tých základných. Teda v okolí miesta výskytu každého základného markantu, môže existovať komplexný. V prípade, ak sa okolie súradnice poskytnutej algoritmom CN, podobalo niektorému z komplexných markantov, bolo vyhodnotené ako zhoda. Dalo by sa teda povedať, že NS je akoby málo citlivá na rozdiely v okolí centra bloku. Toto častočne súvisí s druhým dôvodom. A tým je zrejme nízky počet vzoriek trénovacej databázy. Čím je vyšší počet a variabilita v databáze, tým NS citlivejšie reaguje na vstup. Tým sa však opäť dostávame k obmedzeniam, ktoré sme spomínali na začiatku tejto časti.

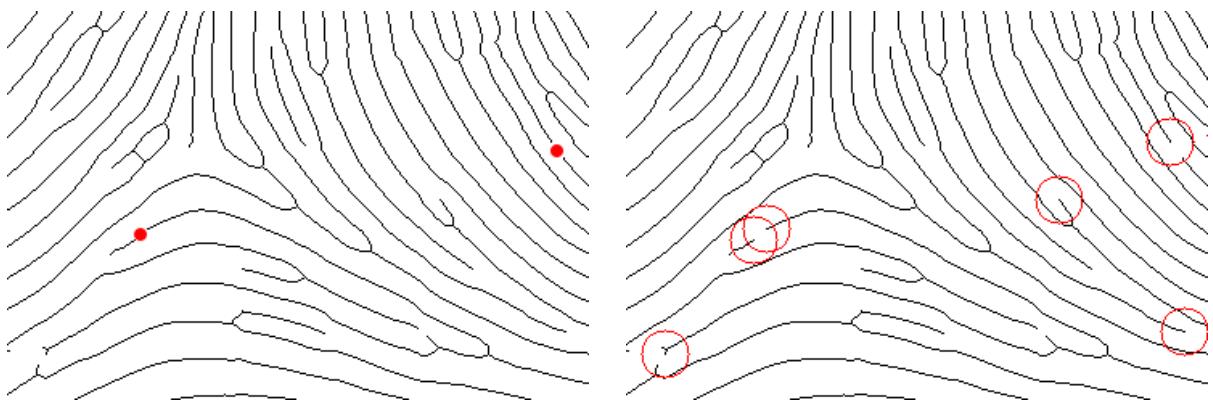
Ďalším zaujímavým zistením bolo, že jednotlivé typy trénovacích vzoriek by mali byť v databáze rovnomerne zastúpené. V našom prípade došlo k stavu, že markant prerušenia mal 28 vzoriek, premostenie 8 a protiľahlé rozdvojenie taktiež 8. Keď sme následne po trénovaní siete vykonali extrakciu, bolo vyhľadanie premostenia a protiľahlého rozdvojenia úplne potlačené a výstup obsahoval podľa NS len prerušenia. Keď sme však počet vzorov

pre jednotlivé typy vyrovnali, vo výstupe sa už objavovali aj zvyšné 2 markanty. Z tohto teda usudzujeme, že dôležitým faktorom je nielen variabilita, ale aj počet a pomer vzoriek vzhľadom k ostatným rozpoznávaným triedam.

Nasledujúce obrázky znázorňujú dosiahnuté výsledky a dokumentujú zistenia, ktoré sme opísali. Na obrázkoch výstupov z našej aplikácie sú miesta výskytu markantov farebne značené. Červená farba označuje markant prerušenia, zelená premostenie a modrá protíahlé rozdvojenie. Nakolko sa nám nepodarilo získať odtlačok kde by sa všetky sledované markanty nachádzali naraz, je ich extrakcia znázornená na viacerých odtlačkoch. Je potrebné ešte poznamenať, že značný počet červených značiek, teda detekovaných pseudoprerušení, je daný majoritným výskytom markantu ukončenia, pričom práve v jeho okolí je prerušenie vyhľadávané. Samotné prerušenie a ukončenie sú navzájom dosť podobné a zrejme to bude dôvodom falošnej detekcie veľkého počtu prerušení.

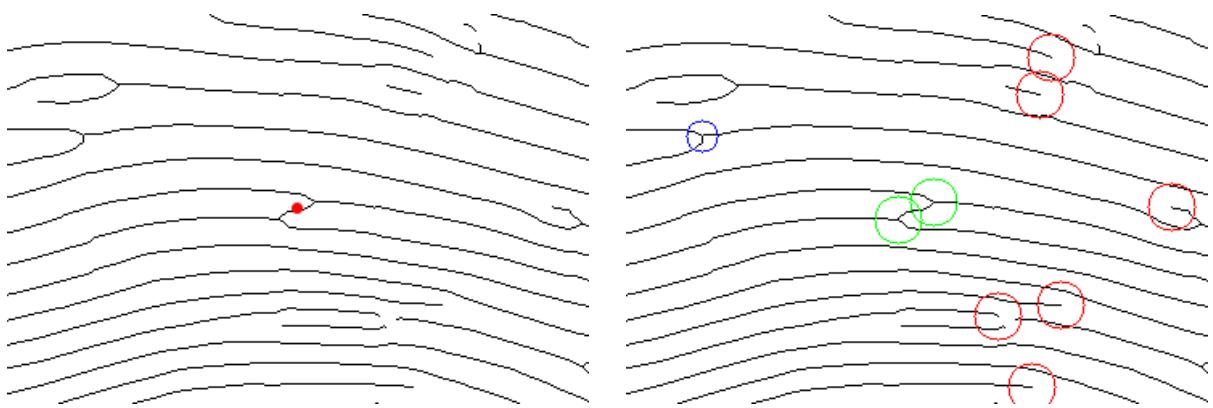
Odtlačky, ktoré sme používali ako zdroj vzorov a podklady pre extrakciu nám poskytol Ing. Pavol Marák a pochádzajú z Kriminalistického a expertízneho ústavu Policajného zboru v Bratislave.

Krúžkami sú v nasledujúcich obrázkoch značené neurónovou sieťou detekované komplexné markanty. Značky sú centrované na základný markant, v okolí ktorého bol príslušný komplexný rozpoznaný. Červené - prerušenia, zelené - premostenia, modré - protíahlé rozdvojenia. Príklad kompletného odtlačku spracovaného neurónovou sieťou, z ktorého boli predchádzajúce vystrihnuté, sa nachádza v prílohe A.



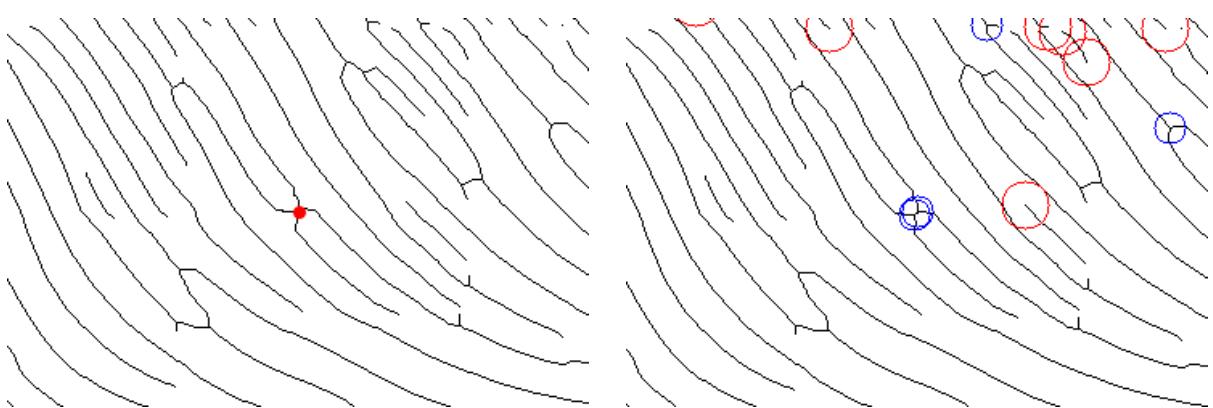
Obrázok 39: Extrakcia - prerušenie

(vľavo: skúmaný odtlačok, vyznačené prerušenie, vpravo: extrahované markanty)



Obrázok 40: Extrakcia - premostenie

(vľavo: skúmaný odtlačok, vyznačené premostenie, vpravo: extrahované markanty)



Obrázok 41: Extrakcia - protilahlé rozdvojenie

(vľavo: skúmaný odtlačok, vyznačené protilahlé rozdvojenie, vpravo: extrahované markanty)

Záver

Cieľom práce bolo priblížiť oblasť biometrie a konkrétnie rozpoznávania osôb na základe odtlačkov prstov. Predstavili sme problematiku a náročnosť automatizovaného spracovania odtlačkov, vysvetlili význam odtlačkov v súčasných biometrických systémoch.

Rozobrali sme štruktúru odtlačkov prstov, analyzovali význam ich charakteristických znakov pre jednotlivé fázy spracovania a vyhodnotenia. Taktiež sme predstavili niektoré z problémov, ktorími počas fázy predspracovania i samotnej extrakcie trpia konvenčné prístupy. V tejto práci sme sa preto zamerali na možné využitie neurónových sietí pri riešení problému extrakcie markantov z odtlačkov. Klúčovým krokom pri práci s neurónovou sieťou bol proces učenia a adaptácie. Základným elementom a zdrojom informácií bola odtlačok prstu vo forme kostry (tzv. skeleton), ktorý bol súčasťou každého procesu v tejto práci.

Podľa popísaných metód a prístupov sme navrhli a implementovali softvérové riešenie - aplikáciu s grafickým rozhraním, ktorej úlohou je extrahovať a vizuálne zobrazovať extrahované základné i komplexné markanty. Z dôvodu optimalizácie a urýchlenia procesu extrakcie sme aplikovali algoritmus Crossing Number, ktorý nám poskytol súradnice základných markantov. Okolie týchto bodov potom predstavovalo vstup neurónovej siete, ktorá rozhodovala o príslušnosti daného charakteristického znaku k sledovanému typu znaku. V tejto práci sme sa zamerali na 3 komplexné markanty: prerušenie, premostenie a protiahľadné rozdvojenie. Základným krokom nevyhnutným k použitiu neurónovej siete je jej trénovanie. Neurónovej sieti sme poskytli vzorky markantov, na základne ktorých boli nastavené vnútorné parametre - váhy a siet sa tak adaptovala. Pri samotnej extrakcii sme neurónovej sieti na vstup posielali špecifikované časti obrazu odtlačku a analýzou jej odpovedí sme potenciálne markanty zaradovali podľa typu do skupín.

Výsledky vyhodnotenia neurónovou sieťou sme porovnali s výsledkami odborníka z oblasti daktyloskopie. Na základe nášho skúmania a zistení sme usúdili, že rozdiely sú spôsobené obmedzeniami, či už ide o výpočtovú silu systému, ktorá nám neumožnovala vytvoriť rozsiahlejšiu neurónovú sieť, alebo o nízky počet testovacích vzorov, ktoré sa nám podarilo získať.

Nadobudnuté zistenia a získané informácie potvrdili predpoklad, že neurónové siete majú potenciál nájsť silné uplatnenie v oblasti automatizovaného spracovania odtlačkov prstov, avšak ich efektivita v tejto oblasti je predmetom hlbšieho a podrobnejšieho skúmania. Výsledky potvrdili naše predpoklady, že proces učenia a adaptácie je klúčový pri práci s neurónovou sieťou. Oblastami zlepšovania tohto riešenia je určite citlivosť a efektivita

neurónovej siete pri extrakcii a rozpoznaní falošných markantov, pričom predpokladáme, že značné zlepšenie by bolo možné dosiahnuť vytvorením rozsiahlejšej databázy trénovacích vzorov.

Zoznam použitej literatúry

- [1] ALSHEMMARY, E. Classification of fingerprint images using neural networks technique. *Journal of Engineering* 1, 3 (2012).
- [2] ARANTES, M., IDE, A., AND SAITO, J. A system for fingerprint minutiae classification and recognition. *ICONIP* 5 (2002).
- [3] BARTUNĚK, J. Minutiae extraction from fingerprint with neural network and minutiae based fingerprint verification. Diploma thesis, Blekinge Tekniska Högskola, 2005.
- [4] BARTUNĚK, J., ET AL. Neural network based minutiae extraction from skeletonized fingerprints.
- [5] BAZEN, A. Fingerprint identification - feature extraction, matching, and database search, 2002.
- [6] Beňušková, L. and Navrat, P. and Bieliková, M. *Umelá inteligencia*. 1. Vydavatelstvo STU. ISBN 80-227-1645-6.
- [7] DIVYAKANT, T., KUMBHARANA, C., AND KOTHARI, A. The study of adoption of neural network approach in fingerprint recognition. *International Journal of Computer Applications* 40, 11 (2012).
- [8] HONGLONG, C., XIAOLI, Z., AND LI, B. Application of bp neural network in the fingerprint identification. *IPCSIT* 47 (2012).
- [9] JIN, A., CHEKIMA, A., DARGHAM, J., AND FAN, L. Fingerprint identification and recognition using backpropagation neural network. *SCOReD* (2002).
- [10] LIHUA, Z. A new fingerprint image recognition approach using artificial neural network. *ICEN* (2010).
- [11] Maltoni, D. et al. *Handbook of fingerprint recognition*. 2. Springer. s. 494. ISBN: 978-1-84882-253-5.
- [12] MARÁK, P. Využitie neurónových sietí pri biometrickom rozpoznávaní osôb od-tlačkami prstov.
- [13] MARÁK, P. Automatizované spracovanie charakteristických vlastností odtlačkov prstov. Diplomová práca, Slovenská technická univerzita, 2012.

- [14] MARÁK, P. Metódy extrakcie charakteristických znakov odtlačkov prstov a dlaní, 2014.
- [15] NETO, H., AND BORGES, D. Fingerprint classification with neural networks.
- [16] OU, G., AND MURPHEY, Y. Multi-class pattern classification using neural networks. *The journal of the pattern recognition society* 40 (2007).
- [17] SINGH, K. Application of neural networks in fingerprint identification. Diploma thesis, Thapar university, 2010.
- [18] WILSON, C., WATSON, C., AND PAEK, E. Effect of resolution and image quality on combined optical and neural network fingerprint matching. *The journal of the pattern recognition society* 33 (2000).
- [19] ZHU, E., YIN, J., ZHANG, G., AND HU, C. Fingerprint ridge orientation estimation based on neural network. *WSEAS* (2006).

Prílohy

A	Demonštrácia extrakcie komplexných daktyloskopických markantov	II
B	Obsah priloženého DVD	III

A Demonštrácia extrakcie komplexných daktyloskopických markantov

Extrakcia komplexných markantov na vzorovom odtlačku prstu



Obrázok A.1: Vyznačené komplexné markanty
(červená - prerušenia, zelená - premostenia, modrá - protiahľné rozdvojenia)

B Obsah priloženého DVD

DVD obsahuje nasledujúce časti:

- bakalárska práca v PDF verzii
- priečinok so zdrojovými kódmi
- priečinky obsahujúci potrebné obrázky kostier odtlačkov (pre trénovanie NS i testovanie)
- priečinok s inštalačnými súbormi potrebných knižníc a programov

Štruktúra disku:

```
\Bakalarska_praca.pdf
\project1
\skeletons2
  \db
  \fingerprints
\software3
  \FANN-2.2.0-Source.zip
  \opencv-2.4.10.exe
\train_data4
  \basic_minutiae
  \breaks_more_examples
  \complex_minutiae
```

¹Priečinok obsahujúci zdrojové súbory

²Priečinok obsahujúci testovacie obrázky odtlačkov prstov

³Priečinok obsahujúci zdrojové súbory externých knižníc

⁴Priečinok obsahujúci trénovacie vzorky neurónovej siete